

分类号 TN911.7
密 级 公开
学 号 171634



硕 士 学 位 论 文

(学 术 型)

题 目 异常变化检测的排列熵改进算法研究

作 者 康欢

指 导 教 师 张小凤 教授

一级学科名称 信息与通信工程

二级学科名称 信号与信息处理

提 交 日 期 二〇二〇年六月

摘要

异常变化是自然界和人类社会中一种常见的由环境或机体自身状态改变而引起个体脱离原存在状态的一种现象。异常变化出现的原因在很大程度上是长期作用的结果，且一般无法直观发现，进而它所带来的后果往往是始料未及的。因此，做好异常变化的检测对于防范未知风险的发生具有极其重要的实际意义。

排列熵算法是 Bandt 等人提出的用于分析时间序列复杂性的一种方法，由于它概念简单、对噪声的鲁棒性好而被学者所广泛运用。众多研究表明，在信号的异常检测方面，排列熵算法具有显著优势。但是，随着研究的深入，排列熵及其衍生算法的不足也日益显现出来。本文以改善排列熵算法对异常变化的检测性能为研究目标，从宏观和微观两方面着手，提出了三种排列熵优化算法。主要工作和创新点如下：

1. 将相位信息引入到排列熵算法中，提出了相位排列熵。利用标准模型 logistic 映射，对比了排列熵和相位排列熵对混沌窗的检测效果，分析了相位排列熵随数据长度、嵌入维数和时间延迟的变化规律。借助 AR 模型，研究了噪声对于相位排列熵的影响。最后，将相位排列熵用于心电信号和工程信号的异常检测分析中。实验结果表明：相比于排列熵算法，相位排列熵能改善对信号中异常变化的检测效果；通过增加嵌入维数，能提高相位排列熵对同一异常的检测性能；当嵌入维数小于等于 5 时，相位排列熵对数据长度不敏感。但是，相位排列熵相比于排列熵具有较差的噪声鲁棒性。实际信号的仿真研究表明，相位排列熵算法在生物医学和工程异常信号处理领域是一个十分有用的分析工具。

2. 基于两参数熵公式，提出了广义相位排列熵算法，验证了广义相位排列熵在检测系统动态改变时的优势，分析了参数 q, δ 选取对于系统动态改变检测的影响，探究了数据长度和噪声对于广义相位排列熵的影响，并将广义相位排列熵算法运用于异常心电信号的检测分析中。仿真结果表明：当广义排列熵和广义相位排列熵中的参数 q, δ 取值相同时，广义相位排列熵对于同一动态变化的检测效果更为显著；无论是针对 logistic 映射还是异常心电信号的动态变化检测，当 $q > 0, \delta > 0$ 时，减少 q 值或增加 δ 值，或者同时减小 q 值增加 δ 值，都能提高广义排列熵和广义相位排列熵对于动态变化的检测效果。此外，数据长度的改变对于广义排列熵和广义相位排列熵基本无影响，且两者对噪声均具有良好的鲁棒性。

3. 为优化排列熵算法中存在的细节性问题，基于二次分区，提出了编码排列熵。利用模拟信号、离散标准模型和连续标准模型，分析了编码排列熵对信号动

态变化的检测效果，研究了不同信噪比时编码排列熵的检测性能，讨论了编码排列熵的算法复杂度。仿真结果表明：相比于排列熵、加权排列熵和幅度敏感排列熵，编码排列熵能抓取信号中的微小特征信息、放大对信号中动态变化的检测效果，但是它对噪声具有较差的鲁棒性，且需要相对较高的计算花费。最后，将编码排列熵运用于轴承故障信号的检测分析中。实际信号的仿真说明，当嵌入维数取较小值时，相比于其它三种算法，编码排列熵对轴承信号中的异常脉冲具有较好的检测性能。

关键词：排列熵，异常变化检测，Logistic 映射，非线性分析

Abstract

Abnormal change is a common phenomenon in nature and human society in which the individual is separated from the original existence state by the change of the environment or the state of the organism itself. To a large extent, the causes of abnormal changes are the result of long-term effects and cannot be intuitively discovered, and so its consequences are often unexpected. Therefore, the detection of abnormal changes has great practical significance for preventing the occurrence of unknown risks.

PE algorithm, which was proposed by Bandt and Pompe, is a method of complexity measure of time series. It is widely used by scholars because of its simple concept and good robustness to noise. Many studies have shown that PE algorithm has significant advantages in anomaly detection of signal. However, with the deepening of the research, the shortcomings of PE and its derived algorithm are increasingly apparent. In order to improve the performance of PE algorithm in detecting abnormal changes, three PE optimization algorithms are proposed in this paper from macroscopic and microscopic aspects. The main work and innovations are as follows:

1. PPE algorithm which introduce phase information into PE is proposed. Using logistic map, we analyze the difference of PE and PPE in detecting the chaos window, and then the influence of data length, embedding dimension, and time delay are also be studied. Relay on the AR model, the performance of PPE algorithm when the series have different length and SNR are discussed. Finally, we apply PPE algorithm to analyze the ECG and engineering signals. The simulation results demonstrate that PPE can improve the detection effect of abnormal changes compared with PE. Increasing embedding dimension can increase the capability of detecting abnormal changes using PPE algorithm. Furthermore, PPE is not sensitive to data length when embedding dimension is less than or equal to 5 and it is more susceptible to noise than PE. The results from actual signals show that PPE can be used as an effective analytical tool in the field of biomedical and engineering signal processing.

2. Based on the formula of two-index entropy, we propose generalized phase permutation entropy algorithm, verify the advantage of $PPE_{q,\delta}$ in detecting the dynamical changes of system, analyze the influence of q, δ selection on dynamical change of system, and explore the effect of data length and noise for $PPE_{q,\delta}$. Finally,

$PPE_{q,\delta}$ is applied to analyze abnormal ECG signals. The conclusion can be obtained that $PPE_{q,\delta}$ has a more significant effect on the detection of the same dynamical changes when the value of q, δ are the same. Whether use in the logistic map or in detecting abnormal ECG signal dynamical changes, when $q > 0$ and $\delta > 0$, the effect of $PE_{q,\delta}$ and $PPE_{q,\delta}$ can be improved by decreasing q value, increasing δ value or simultaneously changing both value. Furthermore, the change in data length has no effect for $PE_{q,\delta}$ and $PPE_{q,\delta}$, and both of them are robust to noise.

3. An improved PE algorithm named CPE is proposed to optimize the trivial problem existing in PE based on the secondary partitioning. The performance of CPE algorithm for dynamical change detection is analyzed using synthetic signal, logistic map and Lorenz map. The detection ability of CPE algorithm in different SNR is studied and the algorithm complexity is discussed. The simulation results show that CPE can accurately capture minor feature information and amplify the detection results of dynamical change compared with PE, WPE and AAPE, but it has less robustness to noise and requires a higher computation cost than the others. Finally, we use CPE to analyze the rolling bearing fault signals. The simulation of actual signal illustrates that CPE performs better in detecting abnormal pulse of the rolling bearing when the embedding dimension is small.

Key words: Permutation entropy, Abnormal changes detection, Logistic map, Nonlinear analysis

目 录

摘 要.....	I
Abstract.....	III
图表索引.....	VII
符号对照表.....	XI
缩略语对照表.....	XIII
第 1 章 绪论.....	1
1.1 选题背景及研究意义.....	1
1.2 国内外研究现状.....	1
1.3 本文的研究内容及结构安排.....	5
第 2 章 熵分析的基本理论.....	7
2.1 基本的熵公式.....	7
2.2 常见的熵分析方法.....	8
2.2.1 近似熵.....	8
2.2.2 基本尺度熵.....	9
2.2.3 传递熵.....	10
2.3 排列熵及其主要衍生算法.....	11
2.3.1 排列熵.....	11
2.3.2 广义排列熵.....	12
2.3.3 加权排列熵.....	12
2.3.4 幅度敏感排列熵.....	13
2.3.5 多元排列熵.....	14
2.3.6 二维排列熵.....	15
2.4 异常变化检测的定量描述.....	17
2.5 本章小结.....	17
第 3 章 相位排列熵.....	19
3.1 相位排列熵的原理.....	19
3.2 相位排列熵的性能分析.....	20
3.2.1 动态变化检测的有效性.....	20
3.2.2 参数对 PPE 的影响.....	21
3.3 数据长度和噪声对 PPE 的影响.....	24

3.4 PPE 在实际信号中的应用.....	25
3.4.1 心电信号.....	25
3.4.2 工程信号.....	28
3.5 本章小结.....	30
第 4 章 广义相位排列熵.....	31
4.1 广义相位排列熵的原理.....	31
4.2 广义相位排列熵的性能分析.....	31
4.2.1 $PE_{q,\delta}$ 与 $PPE_{q,\delta}$ 的对比分析.....	31
4.2.2 熵参数 q, δ 对于 $PPE_{q,\delta}$ 检测动态变化的影响.....	32
4.2.3 数据长度和噪声对 $PPE_{q,\delta}$ 的影响.....	36
4.3 广义相位排列熵在异常心电信号检测中的应用.....	37
4.4 本章小结.....	39
第 5 章 编码排列熵.....	41
5.1 编码排列熵的原理.....	41
5.2 算法性能分析.....	44
5.2.1 模拟信号.....	44
5.2.2 离散标准模型.....	46
5.2.3 连续标准模型.....	47
5.2.4 噪声的鲁棒性分析.....	49
5.2.5 算法的复杂度分析.....	50
5.3 编码排列熵在轴承故障信号检测中的应用.....	52
5.4 本章小结.....	55
第 6 章 总结与展望.....	57
6.1 全文总结.....	57
6.2 未来工作展望.....	58
参考文献.....	59
致 谢.....	67
攻读硕士学位期间的研究成果.....	69

图表索引

图 2-1	排列熵和多元排列熵构造重构分量 $X_i^{m,\tau}$ 和 $X(i)$ 的对比.....	15
图 2-2	$m=3$ 时的排列模式 $F(v)$ 及其对应的排列子模式.....	15
图 2-3	二维排列熵的计算示例.....	16
图 3-1	排列熵和相位排列熵的算法流程图.....	20
图 3-2	$r(n) \in (3.5, 4)$ 时的 logistic 映射及相应的排列熵和相位排列熵的熵值结果	21
图 3-3	相位排列熵在不同嵌入维数 m 时对 logistic 映射的检测.....	22
图 3-4	相位排列熵在不同时间延迟 τ 时对 logistic 映射的检测.....	23
图 3-5	排列熵和相位排列熵在改变数据长度时的熵值对比.....	25
图 3-6	不同信噪比时的排列熵和相位排列熵.....	25
图 3-7	排列熵和相位排列熵对于心动过速信号的异常检测.....	26
图 3-8	排列熵和相位排列熵对于心室扑动信号的异常检测.....	27
图 3-9	排列熵和相位排列熵对于心室纤颤信号的异常检测.....	27
图 3-10	排列熵和相位排列熵对于工程信号的异常检测.....	29
图 3-11	输入信号和输出特征信号所对应的小波相干图.....	29
图 4-1	广义排列熵与广义相位排列熵对于 logistic 映射动态变化检测的对比..	32
图 4-2	$m=5, \tau=1, 0 < q \leq 2, \delta=1$ 时, $PE_{q,\delta}$ 与 $PPE_{q,\delta}$ 对于 logistic 映射的动态变化检 测.....	33
图 4-3	$m=5, \tau=1, -2 < q \leq 0, \delta=1$ 时, $PE_{q,\delta}$ 与 $PPE_{q,\delta}$ 对于 logistic 映射的动态变化 检测.....	34
图 4-4	$m=5, \tau=1, q=1, 0 < \delta \leq 2$ 时, $PE_{q,\delta}$ 与 $PPE_{q,\delta}$ 对于 logistic 映射的动态变化检 测.....	34
图 4-5	$m=5, \tau=1, q=1, -2 < \delta \leq 0$ 时, $PE_{q,\delta}$ 与 $PPE_{q,\delta}$ 对于 logistic 映射的动态变化检 测.....	35
图 4-6	$m=5, \tau=1$ 时, q, δ 取不同值时, $PE_{q,\delta}$ 与 $PPE_{q,\delta}$ 对于 logistic 映射的动态变化 检测.....	36
图 4-7	$m=5, \tau=1$ 时, 不同数据长度和信噪比(SNR)时的 $PE_{q,\delta}$ 与 $PPE_{q,\delta}$	36
图 4-8	$PE_{q,\delta}$ 与 $PPE_{q,\delta}$ 对比分析 $m=5, \tau=1$ 时的室性心动过速信号.....	37
图 4-9	$PE_{q,\delta}$ 与 $PPE_{q,\delta}$ 对比分析 $m=5, \tau=1$ 时的心室扑动信号.....	38
图 4-10	$PE_{q,\delta}$ 与 $PPE_{q,\delta}$ 对比分析 $m=5, \tau=1$ 时的心室纤颤信号.....	38

图 5-1	编码排列熵的算法流程图.....	42
图 5-2	排列熵和编码排列熵对一随机序列的计算过程.....	43
图 5-3	模拟信号 $y(t)$	44
图 5-4	排列熵、加权排列熵、幅度敏感排列熵和编码排列熵对于仿真信号 $y(t)$ 中的动态变化检测对比.....	45
图 5-5	排列熵、加权排列熵、幅度敏感排列熵和编码排列熵对于 logistic 映射中的动态变化检测对比.....	46
图 5-6	Lorenz 映射.....	48
图 5-7	排列熵、加权排列熵、幅度敏感排列熵和编码排列熵对于 lorenz 映射中的动态变化检测对比.....	48
图 5-8	四种算法对含不同噪声时的周期信号和混沌信号检测表现.....	50
图 5-9	m 取不同值时, 排列熵、加权排列熵、幅度敏感排列熵和编码排列熵检测轴承内圈故障信号中的异常脉冲.....	52
图 5-10	m 取不同值时, 排列熵、加权排列熵、幅度敏感排列熵和编码排列熵检测轴承滚动体故障信号中的异常脉冲.....	53
图 5-11	m 取不同值时, 排列熵、加权排列熵、幅度敏感排列熵和编码排列熵检测轴承外圈故障信号中的异常脉冲.....	54
表 3-1	不同嵌入维数 m 时相位排列熵所需的数据长度.....	22
表 3-2	不同嵌入维数 m 时相位排列熵所需的算法运行时间.....	23
表 3-3	不同时间延迟 τ 时相位排列熵所需的算法运行时间.....	24
表 3-4	排列熵和相位排列熵在分析心电信号时的差异系数.....	28
表 5-1	模拟信号 $y(t)$ 的四种排列熵算法熵值标准差和其在突变处的熵值跳变.....	45
表 5-2	logistic 映射的四种排列熵算法熵值标准差和其在突变处的熵值跳变.....	47
表 5-3	Lorenz 映射的四种排列熵算法熵值标准差和其在突变处的熵值跳变.....	49
表 5-4	对于上述三种模型, 排列熵、加权排列熵、幅度敏感排列熵和编码排列熵在不同 m 时的算法运行时间.....	51
表 5-5	不同 m 时编码排列熵相对于排列熵的算法运行时间增长率.....	51
表 5-6	排列熵、加权排列熵、幅度敏感排列熵和编码排列熵的时间复杂度.....	52
表 5-7	排列熵、加权排列熵、幅度敏感排列熵和编码排列熵在不同 m 时分析轴承内圈故障信号的熵值标准差.....	53
表 5-8	排列熵、加权排列熵、幅度敏感排列熵和编码排列熵在不同 m 时分析轴承滚动体故障信号的熵值标准差.....	54
表 5-9	排列熵、加权排列熵、幅度敏感排列熵和编码排列熵在不同 m 时分析轴承	

	外圈故障信号的熵值标准差.....	55
表 5-10	当 $m=5$ ，改变窗口长度 w ，四种算法在分析滚动体故障信号的熵值标准差.....	55

符号对照表

符号	符号名称
m	相空间重构的嵌入维数
τ	相空间重构的时间延迟
w	窗口长度（等价于熵算法中的数据长度 N ）
$F(v)$	可能的排列模式
$X_i^{m,\tau}$	排列熵中的重构分量
S_i	排列熵中的位置序列
$P_{PE}(v)$	排列熵中的概率分布函数
$H_{PE}(m), h_{PE}(m)$	排列熵及其归一化后的熵值
$P_{PPE}(v)$	相位排列熵中的概率分布函数
$H_{PPE}(m), h_{PPE}(m)$	相位排列熵及其归一化后的熵值
q	两参数熵中的熵参数
δ	两参数熵中的另一个熵参数
$S_{PE\ q,\delta}(v)$	广义排列熵的熵值
$S_{PPE\ q,\delta}(v)$	广义相位排列熵的熵值
$Me(v)$	编码排列熵中的均值序列
$Q(N-(m-1)\tau, 1+m)$	编码排列熵中的编码序列矩阵
$P_{CPE}(r)$	编码排列熵的概率分布函数
$H_{CPE}(r)$	编码排列熵的熵值

缩略语对照表

缩略语	英文全称	中文对照
PE	Permutation Entropy	排列熵
WPE	Weighted-permutation Entropy	加权排列熵
AAPE	Amplitude-aware Permutation Entropy	幅度敏感排列熵
PPE	Phase Permutation Entropy	相位排列熵
$PE_{q,\delta}$	Generalized Permutation Entropy	广义排列熵
$PPE_{q,\delta}$	Generalized Phase Permutation Entropy	广义相位排列熵
CPE	Coded permutation entropy	编码排列熵
CV	Coefficient of Variation	差异系数
SNR	Signal-to-Noise Ratio	信噪比
VT	Ventricular Tachycardia	室性心动过速
VFL	Ventricular Flutter	心室扑动
VF	Ventricular Fibrillation	心室纤颤
Std	Standard Deviation	熵值标准差
Gr	Growth Rate	算法的运行时间增长率
IRF	Inner Race Fault	轴承内圈故障
BF	Ball Fault	轴承滚动体故障
ORF	Outer Race Fault	轴承外圈故障

第1章 绪论

1.1 选题背景及研究意义

随着社会的变迁,电子设备等各种高科技器件的出现极大提升了人们的生活质量。利用这些设备,通过分析某一动态系统在一定时间内采集到的时间序列,能够轻易实现对该系统的监测以及预警。设备之所以能发出预警的原因在于,该系统所产生的时间序列中出现了与此前一段时间完全不同的特征数据,即时间序列的异常变化。

异常变化是自然界和人类社会中一种常见的由环境或机体自身状态改变而引起个体脱离原存在状态的一种现象,检测复杂系统的异常变化对于分析系统的存在状况及预防未知变化的发生具有重要意义。

对地震、台风、海啸等异常变化的监测有助于相关部门及时作出防范措施,以此来保证人民的生命安全,并减少自然灾害带来的经济损失。医学上,监测病人的各种生理指标如体温、心率、血压等能帮助医生及时了解病人的身体状况,从而诊断出确切病情,以此来减轻病症对病人带来的心理及生理伤害。工程中,监测滚动轴承的使用状况、油气管道的运输情况、大坝的水流波动等能及时发现潜在的危险状况,做到提早预防意外事故的发生。

在实际分析中,与正常的时间序列数据相比,异常数据或许只占很少的一部分,而往往这些异常数据才是关注的重中之重。造成异常变化出现的原因在很大程度上是无法直观发现的,并且是长期作用的结果,进而异常变化所带来的后果往往是始料未及的。因此,做好异常变化的检测研究对于防范未知风险的发生具有极其重要的实际意义。

1.2 国内外研究现状

异常变化检测一般是通过分析数据中出现的异常变化点及其异常变化后所对应的数据走向来实现异常变化诊断。非线性分析方法作为分析异常变化的常用方法,深受众多学者的追捧。常用的非线性分析方法有统计复杂性测量^[1-2]、分形维数^[3]、李雅普诺夫指数^[4-5]、符号动力学^[6]、熵分析^[7-11]等。分形维数是十分常用的测量信号复杂性的工具,同时,它能有效的反映信号的异常变化情况。但是,分形维数的计算对于信号长度的依赖性较强。李雅普诺夫指数同样能够有效区分出

信号的变化情况,但是它的计算效率低,抗噪能力差^[11]。相比于其他方法,熵分析因其概念简单、运算速度快、抗干扰能力强、能获取更多有用信息而被广泛运用于各个领域。

为解决复杂性测量问题,Pincus 于 1991 年提出了近似熵(Approximate entropy)^[7]。近似熵熵值越大,表示系统生成新模式的几率越大,则系统的复杂性与混沌程度越高。2000 年, Richman 等学者针对近似熵的不足,提出了通过剔除自匹配来减小近似熵中的偏差从而使结果更加准确的样本熵(Sample entropy)^[8]。2002 年, Costa 等人提出了多尺度熵(Multiscale entropy),用于研究心率变异性(Heart rate variability)信号的复杂性^[9]。该方法对原始序列进行了时间尺度下的“粗粒化”处理,再计算其样本熵,以期待获得信号在不同时间尺度下的复杂性,熵值越大意味着时间序列在该尺度下的信号不规则性越强。同年, Bandt 等人基于比较时间序列相邻值的大小提出了排列熵(Permutation entropy, PE)^[11]。排列熵是对相空间重构后的时间序列按照升序排列,取升序排列序列在原相空间重构序列中的位置索引去构成位置序列,进而进行概率求解。因此,排列熵算法具有很好的抗噪能力,同时算法简单、容易理解^[12-13]。

自 2002 年 Bandt 和 Pompe 提出排列熵算法以来,它自身众多优点使得越来越多的学者加入到研究和应用排列熵的大阵营中。在排列熵的众多应用中,非线性数据或系统的异常变化检测及分析是最为常见的一个研究领域。2004 年, Cao 等人利用排列熵去检测 logistic 映射的混沌窗和 Lorenz 映射的周期窗,实验说明了排列熵在检测标准模型异常变化时的有效性,并且他们还将排列熵运用于癫痫检测,从此开启了排列熵检测异常变化的新方向^[14]。2010 年,赵小磊等人利用排列熵对心电信号进行了非线性分析,实验结果表明在心脏活动出现不同病理状态时,排列熵的熵值会发生变化^[15]。2012 年, Yan 等人将排列熵运用到滚动轴承状态检测中,实验表明排列熵是一种极为有效的滚动轴承工作状态检测方法^[16]。2018 年, Zhang 等人利用方差贡献率(Variance dedication rate)和排列熵相结合成功实现三峡大坝泄洪结构的状态监测^[12]。

研究表明,排列熵算法中的窗口长度、相空间重构的嵌入维数和相空间重构的时间延迟都是对一维时间序列分析影响至关重要的参数^[17-19]。2007 年,陆振波等人针对混沌时间序列相空间重构 C-C 方法的三点不足^[20],提出了一种改进的 C-C 方法,改进后的 C-C 方法在确定最优时延和嵌入维数这两方面做了适量的修正。2009 年,谢忠玉等人提出了一种新的相空间重构的联合算法,该算法以时间窗口法和互信息法为基本方法,在综合考虑窗口长度的基础上,可同时确定嵌入维数和时间延迟^[21]。2014 年,饶国强等人通过对相空间重构中的嵌入维数和时间延迟

采取独立确定方法（伪邻近法用于确定嵌入维数，互信息法被用来确定时间延迟）和联合确定方法（C-C 方法），分别得到所述示例中排列熵的最佳嵌入维数和时间延迟，并将这两种方法运用于轴承异常检测中，结果表明通过选取两个参数的最优值确实能在一定程度上提升异常变化的检测效果^[22]。针对窗口长度和信号噪声，Staniek 和 Quintero-Quiroz 分别于 2007 年和 2015 年做了相应研究^[23-24]。

利用排列熵进行异常变化检测的研究，不止于上述提到的仅仅通过排列熵算法本身去开展相应的工作。在将近 20 年的发展历程中，对于异常变化检测这一方向，在众多学者的共同努力下，排列熵针对解决不同具体问题的衍生算法相继被提出。提升排列熵算法对异常变化的检测性能目前主要从以下三个方面着手：

第一，用更为广义化的熵公式取代排列熵中计算具体熵值的香农熵。香农熵作为一种最基本的衡量信息不确定性的方法，已被扩展成更为广义的熵公式，如萨利熵（Tsallis entropy）^[25]、瑞利熵（Rényi entropy）^[26]、两参数熵（The two-index entropic）^[27]等。鉴于经香农熵推广而产生的熵公式在一定程度上具有香农熵所不具备的性能，有学者提出了用上述推广后的熵公式取代排列熵中计算具体熵值的香农熵，从而产生了新的排列熵算法。2008 年，Zunino 等人根据上述思想提出了萨利排列熵（Tsallis permutation entropy）^[28]。2013 年，Zhao 等人将瑞利熵引入到排列熵中提出了瑞利排列熵（Rényi permutation entropy）^[29-30]。2015 年，Xu 等人基于两参数熵公式（The two-index entropic）提出了广义排列熵（Generalized permutation entropy, $PE_{q,\delta}$ ）^[31]。2017 年，通过用分数阶广义信息熵（The fractional order generalization of information entropy）替代香农熵，Xu 等人将排列熵扩展到分数阶^[32]。2018 年，Cánovas 等人对排列熵、萨利排列熵、瑞利排列熵在检测时间序列异常改变方面做了对比分析^[33]。

第二，修正排列熵算法本身的缺陷以达到提高异常变化检测能力的目的。排列熵算法是对时间序列按照升序排列后，取升序排列序列在原相空间重构序列中的位置索引进行概率求解，它忽略了相同位置序列在幅值上会存在一定差异的事实。这一过程中存在一个特殊情况，即，如果出现幅值相等的情况，则按照在相空间重构序列中的先后顺序去表述相应的位置会造成一定的差异。这些问题都说明仅仅通过位置序列去表征原序列的变化情况，在一定程度上存在很大误区。2009 年，Liu 等人基于李雅普诺夫指数提出了细化的排列熵（Fine-grained permutation entropy）用来克服排列熵中出现等值的情况^[34]。2012 年，通过用相同符号去表示幅值出现等值的情况，Bian 等人提出了重新定义的排列熵（Modified permutation entropy）^[35]。2013 年，考虑到排列熵忽略了具体幅值信息的差异，Fadlallah 等人通过求取相空间重构序列所对应的权值去表示概率，从而提出了加权排列熵

(Weighted-permutation entropy, WPE) [36-38]。2016 年, Azami 等人的研究表明如果两个不同的相空间重构分量只是整体相差相同的数值, 此时用权值去表示概率则不够准确, 为此, 他们提出了幅度敏感排列熵 (Amplitude-aware permutation entropy, AAPE) [39]。

第三, 将排列熵对于一维时间序列异常变化检测的研究扩展到多维或多元。在第一和第二所出现的这些研究中, 都是针对一维时间序列异常变化检测, 但是对于像图像这种二维数据, 传统的排列熵算法就显得无能为力。对于二维数据, Ribeiro 等人于 2012 年提出了二维模式下的排列熵算法, 我们称其为二维排列熵 (Two-dimensional permutation entropy) [40-43]。排列熵研究的是单一序列, 对于多元序列, 如超混沌 Henon 映射 (Hyperchaotic Henon map) 如果只研究其中的某一序列, 可能会损失系统有用信息, 从而造成错误的判断结果。针对这一问题, 2016 年, He 等人提出了多元排列熵 (Multivariate permutation entropy), 实验结果表明所提出的多元排列熵对于多元系统复杂性的测量十分有效[44]。

排列熵算法本身的优势致使对排列熵的研究不仅仅存在于异常检测方面, 对于排列熵在其他方面的探索, 接下来做一简单阐述。

受多尺度熵思想的影响, 2005 年, Aziz 和 Arif 用排列熵代替多尺度熵中的样本熵提出了多尺度排列熵 (Multiscale permutation entropy) [45]。至此, 实现了排列熵从单一尺度到多尺度的应用扩展[46-48]。

2011 年, Ribeiro 等人将排列熵计算概率的方法与复杂性熵因果平面 (Complexity entropy causality plane) 相结合实现了不同类型乐曲的区分, 这同样是排列熵在新领域的延伸[49]。

一般情况下, 排列熵所研究的数据都是实值序列, 对于二进制序列, 它就无法进行分析测量。针对这一问题, 2015 年, Liu 等人提出了二进制序列的排列熵算法, 通过将新算法与香农熵 (Shannon's entropy) 和 Lempel-Ziv 复杂性在测量随机二进制序列时作对比, 说明了新提出的算法对于检测二进制序列复杂性的准确性[50]。

排列熵算法中的时间延迟在研究同一系统时一般取的是某一固定数值, 2017 年, Little 等人提出将排列熵中的时间延迟变成一个矢量矩阵, 实验表明矢量嵌入延迟能辨别出时间延迟是固定值时的模棱两可或者模糊系统的结构[51-52]。同年, Bandt 基于不同时间延迟时潜在排列模式出现的频率与标准频率之间的平方欧氏距离构造了一种新的排列熵算法, 该算法能预测不同的睡眠阶段, 并有望被用于睡眠障碍诊断[53]。

上述这些新视角的出现, 扩展了排列熵算法的研究方向, 使得读者对于排列

熵的认识更为透彻、深入，从而加快其在不同领域的应用速度。

1.3 本文的研究内容及结构安排

本文在排列熵及其衍生算法的基础上，以系统异常变化检测作为研究的应用背景，针对已有排列熵算法在检测异常变化方面的不足，提出了三种优化算法并分别探究了三种算法的性能及其对于异常变化的检测效果，主要内容及章节安排如下：

第1章：介绍本文的研究背景和意义，详细介绍常用的非线性分析方法及各自的弊端，并全面阐述排列熵算法的基本发展及应用情况。最后，指出本文的主要研究内容及其章节安排。

第2章：简单介绍基本的熵公式及常见的熵算法，详细阐明排列熵及广泛用于异常变化检测的排列熵衍生算法的基本原理，并说明本文所使用的异常变化检测的定量描述指标。

第3章：提出相位排列熵算法，详细说明相位排列熵的原理。从检测异常变化效果的角度，及算法运行时间、数据长度和信噪比变化对相位排列熵影响的角度全面分析相位排列熵的性能。最后，将相位排列熵运用于异常心电信号和工程信号的检测分析中。

第4章：提出广义相位排列熵算法，在相位排列熵的基础上详细阐明广义相位排列熵的算法原理，对比广义相位排列熵与广义排列熵对于 logistic 映射混沌窗的检测效果，全面分析两参数熵中的参数 q 和 δ 变化对于异常变化检测效果的影响，探究了数据长度和信噪比变化对于广义相位排列熵的影响，并将广义相位排列熵运用于异常心电信号的检测分析中。

第5章：提出编码排列熵，在排列熵算法的基础上详细说明编码排列熵的算法原理，对比探究编码排列熵与排列熵、加权排列熵和幅度敏感排列熵对三个标准模型中异常变化的检测效果，分析编码排列熵在噪声情况下的检测表现，计算编码排列熵的算法运行时间。最后，将编码排列熵用于轴承故障信号的检测分析。

第6章：总结本文的实验结果与重要结论，并且指出本文存在的不足以及今后的研究方向。

第2章 熵分析的基本理论

1854年,克劳修斯(Clausius T.)提出熵的概念,他提出的熵被称为热熵,它是热力学系统的一个状态函数。热熵是系统无序性的量度,热熵越大,表明系统可能的微观状态数也就越多,从微观上看,系统就越无序。经过不断的发展,熵在其他学科中也得到了应用。1948年,香农将熵引入到信息学这一领域,提出了信息熵的概念,解决了对信息的量化度量问题^[54]。后续更多广义化熵公式的出现,使得对于信息的度量变的越来越灵活,常见的广义化的熵公式有瑞利熵、萨利熵、两参数熵等。这些熵公式中,都包含了可调节的熵参数,当这些熵参数取特定值时,广义化的熵又能退化为香农熵。随着研究的深入,越来越多的熵算法也相继被提出,它们基本都是通过构造相应概率分布函数的计算方法,诸如近似熵、样本熵、基本尺度熵、传递熵、排列熵等。本章主要介绍在信号异常检测中常用的基本熵公式和常见的熵算法,以此为后续章节提供所需的理论支撑。

2.1 基本的熵公式

对于离散时间序列 $x(i) = \{x_i, i = 1, 2, \dots, N\}$, 香农熵的定义为^[54]

$$H(x) = -\sum_{i=1} p(x_i) \log_2 p(x_i) \quad (2-1)$$

其中, $p(x_i)$ 表示时间序列 $x(i)$ 在状态 x_i 时的概率分布, $\log_2 p(x_i)$ 表示二进制码元的数据长度。 $H(x)$ 被用来表示时间序列 $x(i)$ 中所包含的信息量, 该式中信息量的度量单位为比特 (Bit)。当上式 (2-1) 中对数的底取不同值时, 信息量的度量单位也随之改变, 即, 当对数的底分别取 e 和 10 时, 对应的度量单位分别为奈特 (Nat) 和哈脱莱 (Hart)。

瑞利熵引入了熵参数 q , 致使它成为香农熵的一种广义化形式, 当 $q \geq 0$ 且 $q \neq 1$ 时, 瑞利熵的表达式为^[26]

$$R_q(x) = \frac{1}{1-q} \ln \left(\sum_{i=1} p(x_i)^q \right) \quad (2-2)$$

其中, q 是一个偏差参数, 当 $q < 1$ 时, $R_q(x)$ 更能度量稀有事件的发生; 当 $q > 1$ 时, $R_q(x)$ 更能度量频繁事件的发生; 当 q 取极限值 $q \rightarrow 1$ 时, 根据 L'Hopital 准则, 瑞利熵 $R_q(x)$ 将退化为香农熵 $H(x)$; 当 q 取极限值 $q \rightarrow \infty$ 时, $R_q(x)$ 将退化为最小熵, 即, $R_\infty(x) = -\ln(\max p(x_i))$ ^[55]。

1988年, Tsallis 提出了萨利熵。萨利熵是香农熵的一种广义化形式, 并且它

能对混杂的非可加性系统提供满意的物理学解释，它的定义如下

$$S_q(x) = \frac{1}{q-1} (1 - \sum_{i=1}^q p(x_i)^q) \quad (2-3)$$

其中，当 q 取极限即 $q \rightarrow 1$ ，萨利熵 $S_q(x)$ 退化为香农熵 $H(x)$ 。香农熵和萨利熵最大的区别在于前者满足可加性，即，对于两个独立的随机变量 X 和 Y ，香农熵的可加性可表示为 $H(X \times Y) = H(X) + H(Y)$ [56]。在萨利熵中，熵参数 q 反映了非广延性，萨利熵的伪可加性可以表示为 [57]

$$S_q(X \times Y) = S_q(X) + S_q(Y) + (1-q)S_q(X)S_q(Y) \quad (2-4)$$

当瑞利熵和萨利熵取相同参数时，两者之间的转换关系为 $R_q = (1-q)^{-1} \ln[1 + (1-q)S_q]$ ，其中， R_q 表示瑞利熵， S_q 表示萨利熵 [25]。

2013 年，Tsallis 和 Cirto 验证了黑洞熵 (Black-hole entropy)，提出了广义化的黑洞熵 (Generalized black-hole entropy)。广义化黑洞熵的表达式为 $S_\delta(x) = \sum p(x_i)(\ln p(x_i))^\delta$, $\delta > 0$ ，其中，当 $\delta=1$ 时， $S_\delta(x)$ 退化为香农熵。基于熵公式 $S_q(x)$ 和 $S_\delta(x)$ ，有学者提出了这两个熵公式的联合形式并称它为两参数熵，两参数熵的熵公式如下式 [27]

$$S_{q,\delta}(x) = \sum_{i=1}^q p(x_i) \left(\ln_q \frac{1}{p(x_i)} \right)^\delta, q \in \mathbb{R}, \delta > 0 \quad (2-5)$$

2.2 常见的熵分析方法

2.2.1 近似熵

近似熵是 Picus 于 1991 年提出的一种用来测量离散时间序列复杂性的方法，它的具体原理如下 [7]：

设一维离散时间序列 $x(i) = \{x_i, i = 1, 2, \dots, N\}$ ，以 1 为时间延迟对序列 $x(i)$ 进行相空间重构得相应的重构分量为

$$X_j^m = \{x_j, x_{j+1}, \dots, x_{j+m-1}\}, j = 1, 2, \dots, N-m+1 \quad (2-6)$$

计算重构分量 X_j^m 与其余重构分量中的 X_l^m 之间的距离

$$d_{jl} = \max |x_{j+k} - x_{l+k}|, k = 1, 2, \dots, m-1 \quad (2-7)$$

其中， d_{jl} 表示 X_j^m 与 X_l^m 对应各元素之间差值的绝对值中的最大值，此时 $j \neq l$ 。

给定阈值 r ，通常 $r \in (0.2, 0.3)$ ，对每个 X_j^m 统计 $d_{jl} \leq r \times Std$ 的数目 (Std 为序列 $x(i)$ 的标准差)，记为 $Num\{d_{jl} \leq r \times Std\}$ ，并求出其与总数之间的比值，即

$$C_j^m(r) = \frac{Num\{d_{jl} \leq r \times Std\}}{N-m} \quad (2-8)$$

将 $C_j^m(r)$ 取对数，再对所有 j 时的 $C_j^m(r)$ 求平均值，可得

$$\Phi^m(r) = \frac{1}{N-m+1} \sum_{j=1}^{N-m+1} \ln C_j^m(r) \quad (2-9)$$

将上述相空间重构中的嵌入维数 m 的取值增加 1 后, 再重复上述所有步骤, 得到相应的 $C_j^{m+1}(r)$ 和 $\Phi^{m+1}(r)$ 。

由 $\Phi^{m+1}(r)$ 和 $\Phi^m(r)$ 求得近似熵为

$$ApEn(m, r) = \lim_{N \rightarrow \infty} [\Phi^{m+1}(r) - \Phi^m(r)] \quad (2-10)$$

在实际当中, 时间序列的长度是有限的, 此时的近似熵可简写成为

$$ApEn(m, r) = \Phi^{m+1}(r) - \Phi^m(r) \quad (2-11)$$

样本熵是对近似熵的优化和改进, 具体做法为将上述式 (2-10) 和式 (2-11) 分别用下式表示, 即

$$SampEn(m, r) = -\lim_{N \rightarrow \infty} \ln \left[\frac{\Phi^{m+1}(r)}{\Phi^m(r)} \right] \quad (2-12)$$

$$SampEn(m, r) = -\ln \left[\frac{\Phi^{m+1}(r)}{\Phi^m(r)} \right] \quad (2-13)$$

2.2.2 基本尺度熵

对一离散时间序列 $x(i) = \{x_i, i = 1, 2, \dots, N\}$, 进行相空间重构如下 (N 为该序列的总长度)

$$X_j^{m, \tau} = \{x_j, x_{j+\tau}, \dots, x_{j+(m-1)\tau}\}, j = 1, 2, \dots, N - (m-1)\tau \quad (2-14)$$

其中, m 表示该相空间重构的嵌入维数, τ 表示相空间重构的时间延迟。

根据下式 (2-15), 计算每一个相空间重构分量 $X_j^{m, \tau}$ 的基本尺度 BS_j ,

$$BS_j = \sqrt{\frac{\sum_{l=1}^{m-1} (x_{j+(l-1)\tau} - x_{j+(l-1)\tau-1})^2}{m-1}} \quad (2-15)$$

依据基本尺度 BS_j , 将第 j 个重构分量 $X_j^{m, \tau}$ 中的每个元素按照下式 (2-16) 转换为相应的符号序列 $s(j)$, 即

$$s(j) = \begin{cases} 0, & x_{j+(k-1)\tau} > \bar{X}_j^{m, \tau} + \alpha \times BS_j \\ 1, & \bar{X}_j^{m, \tau} < x_{j+(k-1)\tau} \leq \bar{X}_j^{m, \tau} + \alpha \times BS_j \\ 2, & \bar{X}_j^{m, \tau} - \alpha \times BS_j < x_{j+(k-1)\tau} \leq \bar{X}_j^{m, \tau} \\ 3, & x_{j+(k-1)\tau} \leq \bar{X}_j^{m, \tau} - \alpha \times BS_j \end{cases}, k = 1, 2, \dots, m \quad (2-16)$$

式 (2-16) 中, $\bar{X}_j^{m, \tau}$ 表示重构分量 $X_j^{m, \tau}$ 中元素的均值, 0, 1, 2, 3 仅仅作为划分每一个局域的符号, 没有任何实际的意义, α 是一个参数, 且 $\alpha \in (0.1, 2)$ 。

由上述描述可知, 对于数据长度为 m 的符号序列 $s(j)$, 它可能的符号组合方

式共有 4^m 种。统计每个符号组合在所有 $s(j)$ 中出现的频率，得到相应的概率为

$$P_{BS}(u) = \frac{Num(u)}{N - (m-1)\tau}, u = 1, 2, \dots, 4^m \quad (2-17)$$

其中， $Num(u)$ 表示第 u 个符号组合在所有符号序列 $s(j)$ 中出现的次数。

将上式 (2-17) 带入到式 (2-1) 的香农熵公式中得到相应的基本尺度熵计算公式为^[58]

$$H_{BS}(m) = - \sum_{u=1}^{4^m} P_{BS}(u) \ln P_{BS}(u) \quad (2-18)$$

2.2.3 传递熵

2000 年，Schreiber 在互信息的基础上提出了传递熵，传递熵对于量化信息之间的传递关系具有独特的优势^[59-61]。

对于满足马尔可夫过程的变量 X 和变量 Y ，用 X_i 、 Y_i 表示 i 时刻的时间序列，且 X_i 满足 k 阶马尔可夫过程， Y_i 满足 l 阶马尔可夫过程，则两者之间的传递熵为：

$$TE(X|Y) = \sum p(X_{i+1}, X_i^{(k)}, Y_i^{(l)}) \ln \frac{p(X_{i+1}|X_i^{(k)}, Y_i^{(l)})}{p(X_{i+1}|X_i^{(k)})} \quad (2-19)$$

为避免在计算过程中引入复杂的高维概率密度，式 (2-19) 中取 $k = l = 1$ 。又因 $p(X_{i+1}|X_i, Y_i) = \frac{p(X_{i+1}, X_i, Y_i)}{p(X_i, Y_i)}$ ，因此式 (2-19) 可化解为

$$TE(X|Y) = \sum_{X_{i+1}, X_i, Y_i} p(X_{i+1}, X_i, Y_i) \ln \frac{p(X_{i+1}, X_i, Y_i)}{p(X_{i+1}|X_i)p(X_i, Y_i)} \quad (2-20)$$

其中， $p(X_{i+1}, X_i, Y_i)$ 表示 X_{i+1} 、 X_i 、 Y_i 的联合概率； $p(X_{i+1}|X_i)$ 为条件概率，表示已知 i 时刻 X_i 的条件下 X_{i+1} 的概率； $p(X_i, Y_i)$ 表示 X_i 和 Y_i 的联合概率。

传递熵的特点是具有方向性，用 $TE_{X \rightarrow Y}$ 表示变量 X 和 Y 之间信息流的传递关系^[61]，即

$$TE_{X \rightarrow Y} = TE(Y|X) - TE(X|Y) \quad (2-21)$$

此时，如果 $TE_{X \rightarrow Y} > 0$ ，说明信息是由变量 X 传递到 Y ；如果 $TE_{X \rightarrow Y} < 0$ ，说明信息是由变量 Y 传递到 X ；如果 $TE_{X \rightarrow Y} = 0$ 或者 $TE_{X \rightarrow Y}$ 无限趋近于 0，说明两变量之间无明显的传递关系。

近似熵和基本尺度熵主要针对的是单个信号复杂性变化的分析，而传递熵研究的是两信号之间的耦合程度和信号之间变化的方向性^[69]。由于传递熵在信号分析方面的优势，它已被用在生物医学、经济金融、桥梁检测等众多领域^[62-64]。

2.3 排列熵及其主要衍生算法

2.3.1 排列熵

2002年, Bandt 和 Pompe 为测量时间序列的复杂性, 提出了排列熵算法 (Permutation entropy, PE) [11]。它的原理如下

设一离散时间序列 $x(i) = \{x_i, i = 1, 2, \dots, N\}$, 对该序列进行相空间重构得重构矩阵为

$$\begin{bmatrix} x_1 & x_{1+\tau} & \cdots & x_{1+(m-1)\tau} \\ x_2 & x_{2+\tau} & \cdots & x_{2+(m-1)\tau} \\ \cdots & \cdots & \cdots & \cdots \\ x_j & x_{j+\tau} & \cdots & x_{j+(m-1)\tau} \\ \cdots & \cdots & \cdots & \cdots \\ x_K & x_{K+\tau} & \cdots & x_{K+(m-1)\tau} \end{bmatrix}, j = 1, 2, \dots, K \quad (2-22)$$

式 (2-22) 中, m 和 τ 分别代表相空间重构的嵌入维数和时间延迟, 并且每一行可以看作一个重构分量记为 $X_j^{m,\tau} = \{x_j, x_{j+\tau}, \dots, x_{j+(m-1)\tau}\}, j = 1, 2, \dots, K$, 其中, $K = N - (m-1)\tau$ 为重构分量的总个数。

对每个重构分量 $X_j^{m,\tau}$ 按照数值大小进行升序排列如下:

$$x_{j+(k_1-1)\tau} \leq x_{j+(k_2-1)\tau} \leq \cdots \leq x_{j+(k_m-1)\tau} \quad (2-23)$$

当式 (2-23) 中的两个数值相等时, 例如: $x_{j+(k_{l1}-1)\tau} = x_{j+(k_{l2}-1)\tau}$, 则通过比较 k_{l1} 与 k_{l2} 的大小来表示 $x_{j+(k_{l1}-1)\tau}$ 与 $x_{j+(k_{l2}-1)\tau}$ 的关系, 即, 如果 $k_{l1} < k_{l2}$, 则 $x_{j+(k_{l1}-1)\tau} < x_{j+(k_{l2}-1)\tau}$, 反之则 $x_{j+(k_{l1}-1)\tau} > x_{j+(k_{l2}-1)\tau}$ 。由此, 得到各个重构分量的位置序列如下所示:

$$S_j = \{k_1, k_2, \dots, k_m\}, j = 1, 2, \dots, N - (m-1)\tau \quad (2-24)$$

计算相同位置序列出现的概率, 即:

$$P_{PE}(v) = \frac{Num(v)}{N - (m-1)\tau}, v = 1, 2, \dots, m! \quad (2-25)$$

式中, $Num(v)$ 表示第 v 个排列模式 $F(v), v = 1, 2, \dots, m!$ 在所有位置序列中出现的总次数, $N - (m-1)\tau$ 是位置序列的总个数。最后, 将 $P_{PE}(v)$ 代入到香农熵公式中得到排列熵[11], 即:

$$H_{PE}(m) = - \sum_{v=1}^{m!} P_{PE}(v) \ln P_{PE}(v) \quad (2-26)$$

上式中, 当 $P_{PE}(v) = 1/m!$ 时, $H_{PE}(m)$ 取最大值 $\ln(m!)$, 由此得到 $0 \leq H_{PE}(m) \leq \ln(m!)$ 。一般情况下, 为了方便, 选取 $\ln(m!)$ 对 $H_{PE}(m)$ 进行归一化, 归一化后的排列熵为:

$$h_{PE}(m) = \frac{H_{PE}(m)}{\ln(m!)} \quad (2-27)$$

排列熵的熵值反映的是时间序列的随机性，熵值越大说明时间序列越随机，反之说明时间序列越规则^[22]。

2.3.2 广义排列熵

2015 年，Xu 等人利用上式 (2-5) 替代排列熵中计算具体熵值的香农熵即式 (2-26)，提出了广义排列熵 (Generalized permutation entropy, $PE_{q,\delta}$)。显然，广义排列熵中计算概率的流程与排列熵中完全一致，由此得到广义排列熵的表达式为^[31]

$$S_{PE_{q,\delta}}(v) = \sum_{v=1}^{m!} P_{PE}(v) \left[\ln_q \left(\frac{1}{P_{PE}(v)} \right) \right]^\delta, q \in \mathfrak{R}, \delta > 0 \quad (2-28)$$

式中，当 $q \neq 1$ 时， $\ln_q \left(\frac{1}{P(v)} \right) = \frac{\left(\frac{1}{P(v)} \right)^{1-q} - 1}{1-q}$ ；当 $q = 1$ 时， $\ln_q \left(\frac{1}{P(v)} \right) = \ln \frac{1}{P(v)}$ 。当 $S_{PE_{q,\delta}}(v)$ 中 $\delta = 1$ 时， $S_{PE_{q,1}}(v)$ 为萨利熵 (Tsallis entropy, S_q) 的表达式；当 $S_{PE_{q,\delta}}(v)$ 中 $q = 1$ 时， $S_{PE_{1,\delta}}(v)$ 被称为广义黑洞熵 (Generalized black-hole entropy, S_δ)；当 $S_{PE_{q,\delta}}(v)$ 中 $q = 1$ 且 $\delta = 1$ 时， $S_{PE_{q,\delta}}(v)$ 则等价于排列熵。

2.3.3 加权排列熵

排列熵算法中，通过位置序列去表示不同重构分量虽然能使算法对噪声具有较强的鲁棒性，但是这在一定程度上人为损失了一部分原始数据中的特征信息。例如，当 $X_1^{3,1} = \{5, 2, 7\}$ 和 $X_2^{3,1} = \{2, 1, 3\}$ 时，依据排列熵原理，相应的位置序列为 $S_1 = S_2 = \{2, 1, 3\}$ 。然而， $X_1^{3,1}$ 和 $X_2^{3,1}$ 中的各元素是完全不相同的，它们的数值具有很明显的差异。针对这种情况，Fadlallah 等人提出了加权排列熵 (Weighted-permutation entropy, WPE)^[36]，旨在将数据中的幅值差异信息考虑到排列熵算法中，从而改善排列熵对于原始数据的特征提取能力。

在加权排列熵算法中，获得各个位置序列 S_j 的步骤与排列熵算法完全一致，两者的主要区别在于计算概率的公式不同，排列熵通过式 (2-25) 计算得到相应的概率，而加权排列熵的概率计算公式为

$$P_{WPE}(v) = \frac{\sum_{l=1, X_l^{m,\tau} \text{ has pattern } F(v)} w_l}{\sum_{j=1}^{N-(m-1)\tau} w_j} \quad (2-29)$$

其中， w_l 代表具有相同位置序列的重构分量 $X_l^{m,\tau}$ 中的元素方差即

$$w_l = \frac{1}{m} \sum_{k=1}^m (x_{l+(k-1)\tau} - \bar{X}_l^{m,\tau})^2 \quad (2-30)$$

$\bar{X}_l^{m,\tau}$ 表示重构分量 $X_l^{m,\tau}$ 中的元素均值即 $\bar{X}_l^{m,\tau} = \frac{1}{m} \sum_{k=1}^m x_{l+(k-1)\tau}$ 。 w_j 表示每一个重构分量 $X_j^{m,\tau}$ 中的元素方差， w_j 的计算公式与式 (2-30) 一致。

最后，将式 (2-29) 带入到香农熵公式中可得到相应的加权排列熵熵值，即为

$$H_{WPE}(m) = - \sum_{v=1}^{m!} P_{WPE}(v) \ln P_{WPE}(v) \quad (2-31)$$

$$h_{WPE}(m) = \frac{H_{WPE}(m)}{\ln(m!)} \quad (2-32)$$

2.3.4 幅度敏感排列熵

加权排列熵利用权值信息表示概率在一定程度上优化了排列熵的性能。但是，当两个重构分量中各个元素之间的差值一致时，由公式 (2-30) 计算的权值也相同，这说明加权排列熵对此时时间序列中的特征提取具有一定的局限性。此外，排列熵算法中对于等值元素是按照各个元素出现的位置去构造相应的位置序列，如式 (2-23) 和式 (2-24)，这会使具有差异的重构分量被标记为相同的位置序列。例如，当 $X_1^{3,1} = \{3,5,5\}$ ， $X_2^{3,1} = \{3,6,6\}$ 和 $X_3^{3,1} = \{3,5,6\}$ 时，排列熵会将它们都标记为 $S_1 = S_2 = S_3 = \{1,2,3\}$ 。针对这两方面的问题，Azami 等人于 2016 年提出了幅度敏感排列熵 (Amplitude-aware permutation entropy, AAPE) [39]。

在幅度敏感排列熵中，得到各个重构分量 $X_l^{m,\tau}$ 所对应位置序列 S_l 的步骤与排列熵算法的一致，这两个算法的差异在于计算概率的方法不一致。排列熵利用相同位置序列出现的频率表示概率如式 (2-25)，而幅度敏感排列熵则通过下式计算概率

$$P_{AAPE}(v) = \frac{\sum_{l=1}^m D_l}{\sum_{j=1}^{N-(m-1)\tau} D_j}, v = 1, 2, \dots, m! \quad (2-33)$$

$$= \frac{\sum_{l=1}^{Num(v)} \left(\frac{A}{m} \sum_{k=1}^m |x_{l+(k-1)\tau}| + \frac{1-A}{m-1} \sum_{k=2}^m |x_{l+(k-1)\tau} - x_{l+(k-2)\tau}| \right)}{\sum_{j=1}^{N-(m-1)\tau} \left(\frac{A}{m} \sum_{k=1}^m |x_{j+(k-1)\tau}| + \frac{1-A}{m-1} \sum_{k=2}^m |x_{j+(k-1)\tau} - x_{j+(k-2)\tau}| \right)}$$

同理，将上式 $P_{AAPE}(v)$ 带入到香农熵中得到相应的幅度敏感排列熵的熵值为

$$H_{AAPE}(m) = - \sum_{v=1}^{m!} P_{AAPE}(v) \ln P_{AAPE}(v) \quad (2-34)$$

$$h_{AAPE}(m) = \frac{H_{AAPE}(m)}{\ln(m!)} \quad (2-35)$$

2.3.5 多元排列熵

设某一多元系统的表达式为 $\{x_{Mul}(i), Mul = 1, 2, \dots, \eta, i = 1, 2, \dots, N\}$, η 为该多元系统的总维数, N 为第 Mul 维的总数据长度。由于该多元系统中 η 维序列的取值范围不一定完全一致, 因此, 需要先对每维序列进行归一化处理, 如下式

$$\tilde{x}_{Mul}(i) = \frac{x_{Mul}(i) - \min(x_{Mul})}{\max(x_{Mul}) - \min(x_{Mul})} \quad (2-36)$$

其中, $\min(x_{Mul})$ 表示第 Mul 维序列中的最小值; $\max(x_{Mul})$ 表示第 Mul 维序列中的最大值。该多元系统新的表示如下,

$$X(i) = \{\tilde{x}_1(i), \tilde{x}_2(i), \dots, \tilde{x}_\eta(i)\}, i = 1, 2, \dots, N \quad (2-37)$$

显然, 多元排列熵中多元系统的总维数 η 等价于排列熵算法中的嵌入维数 m , 如图 2-1 所示。由排列熵原理得知: 当嵌入维数 $m = 3$ 时, 可能的排列模式一共有 $3! = 6$ 种, 然而, 此时的排列熵不能很敏感的检测出时间序列中的动态变化。因此, 在多元排列熵算法中, He 等人构造了当多元系统总维数 $\eta = m = 3$ 时, 传统排列模式所对应的子模式如图 2-2 所示^[50]。在该图中, $F(v)$ 表示嵌入维数 $m = 3$ 时的所有可能的排列模式, $F_{sub}(v, u)$ 表示排列模式 $F(v)$ 所具有的排列子模式, 其中, $v = 1, 2, \dots, 3!$, $u = 1, \dots, 3$ 。Top 和 Bot 由下式计算得到

$$\begin{aligned} Top_i &= \frac{1}{3} \min(X(i)) + \frac{2}{3} \max(X(i)) \\ Bot_i &= \frac{2}{3} \min(X(i)) + \frac{1}{3} \max(X(i)) \end{aligned} \quad (2-38)$$

在多元排列熵算法中, 先将 $X(i)$ 中每个元素进行升序排列得到相应的位置序列, 再依据相应的 Top 和 Bot 的值, 将 $X(i)$ 标记为对应排列模式的子模式。显然, 此时的概率分布计算公式为

$$P_{MvPE}(r) = \frac{Num(r)}{N}, r = 1, 2, \dots, 18 \quad (2-39)$$

其中, Num_r 表示图 2-2 中第 r 个排列子模式在 $X(i)$ 所对应的所有排列子模式 $F_{sub}(v, u)$, $v = 1, 2, \dots, 3!$, $u = 1, \dots, 3$ 中出现的次数。

最后, 将上式 (2-39) 带入到 (2-1) 香农熵公式中得到多元排列熵的计算公式如下

$$H_{MvPE}(m = 3) = -\sum_{r=1}^{18} P_{MvPE}(r) \ln P_{MvPE}(r) \quad (2-40)$$



 图 2-1 排列熵和多元排列熵构造重构分量 $X^{m,i}$ 和 $X(i)$ 的对比

 Fig. 2-1 The comparison of constructing $X^{m,i}$ and $X(i)$ in PE and MvPE

可以看出，He 等人提出的在多元排列熵中构造排列模式所对应子模式的方法主要是针对多元系统维数 $\eta = 3$ 时，它的思路是根据 *Top* 和 *Bot* 的值对升序排列后升序序列中的中间元素进行进一步的位置确定。当 $\eta > 3$ 时，升序序列所对应中间元素的个数大于 1，此时依靠上述构造子模式的方法确定中间元素的位置有一定困难。



 图 2-2 $m = 3$ 时 PE 对应的排列模式 $F(v)$ 及其对应的排列子模式

 Fig. 2-2 Permutation pattern $F(v)$ and permutation sub-pattern for embedding dimension $m = 3$

2.3.6 二维排列熵

排列熵算法的研究对象是一维离散时间序列，如果要分析二维序列则需要对其进行重新定义。2012 年，Ribeiro 等人将排列熵算法扩展到二维空间，提出了二维排列熵（Two-dimension permutation entropy, 2D-PE），它的基本原理如下^[4]：

设二维离散序列矩阵 $\{x_{ij}\}_{i,j=1}^{N_1 \times N_2}$ ，其中，该矩阵的大小为 $N_1 \times N_2$ ， x_{ij} 表示该二维矩阵中行和列分别为 j 和 i 时的元素。仿照式 (2-22)，对该矩阵进行二维相空间重构得相应的重构分量为

$$Y_{j_x}^{j_y} = \begin{bmatrix} y_{j_x}^{j_y} & y_{j_x+1}^{j_y} & y_{j_x+2}^{j_y} & \cdots & y_{j_x+m_x-1}^{j_y} \\ y_{j_x}^{j_y+1} & y_{j_x+1}^{j_y+1} & y_{j_x+2}^{j_y+1} & \cdots & y_{j_x+m_x-1}^{j_y+1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ y_{j_x}^{j_y+m_y-1} & y_{j_x+1}^{j_y+m_y-1} & y_{j_x+2}^{j_y+m_y-1} & \cdots & y_{j_x+m_x-1}^{j_y+m_y-1} \end{bmatrix} \quad (2-41)$$

此时, $j_x = 1, 2, \dots, N_x - m_x + 1$, $j_y = 1, 2, \dots, N_y - m_y + 1$, m_x 和 m_y 分别表示重构时水平方向和竖直方向的嵌入维数 (在该定义中默认两方向的时间延迟 τ_x 和 τ_y 的取值都为 1)。

然后, 对该 $(N_x - m_x + 1) \cdot (N_y - m_y + 1)$ 个二维重构分量 $Y_{j_x}^{j_y}$ 中的各个元素进行升序排列。假定未排列前各个 $Y_{j_x}^{j_y}$ 中每个元素的初始位置依次为从第一行的第一个元素到第 m_y 个元素, 接第二行的第一个元素至第 m_x 个元素, 直至结束, 即对新构造的序列 $\pi_l = \{y_{j_x}^{j_y}, \dots, y_{j_x+m_x-1}^{j_y}, y_{j_x}^{j_y+1}, \dots, y_{j_x+m_x-1}^{j_y+1}, \dots, y_{j_x}^{j_y+m_y-1}, \dots, y_{j_x+m_x-1}^{j_y+m_y-1}\}$ 进行升序排列, 其中 $1 \leq l \leq (N_x - m_x + 1) \cdot (N_y - m_y + 1)$ 。经升序排列后, 得到每个 π_l 所对应的位置序列 S_l 。进而, 此处可能的排列模式共有 $(m_x \cdot m_y)!$ 种。因此, 第 v 个排列模式在所有 $(N_x - m_x + 1) \cdot (N_y - m_y + 1)$ 个位置序列中出现的概率为

$$P_{2D-PE}(v) = \frac{Num_v}{(N_x - m_x + 1) \cdot (N_y - m_y + 1)} \quad (2-42)$$

其中, Num_v 表示第 v 个排列模式在所有 S_l 中出现的次数。

最后, 将上式 (2-42) 带入到香农熵公式中得到相应的二维排列熵及其归一化的熵值为

$$H_{2D-PE}(m_x, m_y) = - \sum_{v=1}^{(m_x \cdot m_y)!} P_{2D-PE}(v) \ln(P_{2D-PE}(v))$$

$$h_{2D-PE}(m_x, m_y) = \frac{H_{2D-PE}(m_x, m_y)}{\ln(m_x \cdot m_y)!} \quad (2-43)$$

为了方便理解, 我们用一个例子来简单的说明二维排列熵的原理, 如图 2-3 所示




图 2-3 二维排列熵的计算示例

Fig. 2-3 The example of calculating two-dimension PE

2.4 异常变化检测的定量描述

差异系数 (Coefficient of variation, CV) 是计算时间序列波动程度的一个重要统计量, 它概念简单、计算便捷。CV 的数值越大, 说明时间序列中的动态波动越大^[65]。Brown 的研究表明, 当 CV 值大于 30% 时, 说明序列中的动态波动较大且信号的稳定性较差^[66]。

本文中, CV 被用来定量评估异常变化的波动程度, 它的计算公式如下^[67]

$$CV = \frac{\sigma}{\mu} \cdot 100\% \quad (2-44)$$

其中, σ 表示所测序列的标准差, μ 表示所测序列的均值。

2.5 本章小结

在本章, 介绍了基本的熵公式和常用的信号熵分析算法, 对于本文重点研究的排列熵以及后续章节会涉及到的或者十分重要的排列熵衍生算法进行了详尽的原理说明。最后, 对于后续章节所用的异常变化的定量描述指标, 即差异系数, 进行了简单阐述。

第3章 相位排列熵

目前已有的排列熵衍生算法都是从时间序列的幅值出发,去进行相应的分析和研究。信号的相位同步和幅度关联是功能独立的现象^[68]。1981年,Oppenheim等人的研究表明,相比于通过幅值获得的重构图像,利用相位得到的重构图像则包含更多原始图像信息^[69]。2007年,Luo等人的论文中阐明了缓慢震荡信号的相位相比于幅度能提供更多有用信息^[70]。2011年,Schyns等人的实验说明在视觉分类这一方面,运用信号的相位比利用信号的幅值更具优势^[71]。在神经科学领域,Ng等人证明了相位模式相比于幅度能够编码更多信息^[72]。在这一章中,我们将相位信息引入到排列熵算法中,提出了相位排列熵(Phase permutation entropy, PPE),并通过不同的实验,讨论了算法在异常信号检测中的性能。

3.1 相位排列熵的原理

对于一离散时间序列 $x(i) = \{x_i, i = 1, 2, \dots, N\}$, 它的解析信号 $z(i)$ 是时间的复函数, $z(i)$ 的表达式为

$$z(i) = x(i) + j\tilde{x}(i) = A(i)e^{j\theta(i)} \quad (3-1)$$

其中, $\tilde{x}(i)$ 是离散时间序列 $x(i)$ 的希尔伯特变换(Hilbert transform), 这两者之间的

计算公式为 $\tilde{x}(i) = \frac{1}{\pi} \int_{-\infty}^{+\infty} \frac{x(t)}{i-t} dt$ 。

根据上式(3-1)得到 $x(i)$ 的瞬时相位 $\theta(i)$ 的计算公式为

$$\theta(i) = \arctan \frac{\tilde{x}(i)}{x(i)}, i = 1, 2, \dots, N \quad (3-2)$$

i 是不同频率分量所对应相位的集合。其中, $\theta(i)$ 的取值范围为 $\theta(i) \in (-\pi, \pi)$ 。 $\tilde{x}(i)$ 可以被看做是 $x(i)$ 和 $1/\pi i$ 的卷积, 则 $\tilde{x}(i)$ 的傅里叶变换(Fourier transform) $\tilde{X}(j\omega)$ 等价于 $x(i)$ 的傅里叶变化 $X(j\omega)$ 与 $1/\pi i$ 的傅里叶变换的乘积。当 $\omega > 0$ 时, $\tilde{X}(j\omega) = -jX(j\omega)$, 即将 $x(i)$ 通过幅度响应为 1 且相位响应在各个频率上延迟 $\pi/2$ 的滤波器就能得到相应的 $\tilde{x}(i)$ ^[73]。经过解析信号 $z(i)$ 求得的 $\theta(i)$ 是瞬时相位。

然后, 将该瞬时相位序列 $\theta(i)$ 作为初始时间序列, 进行相应的相空间重构, 得到重构分量 $\Theta_j^{m,\tau}$ 为

$$\Theta_j^{m,\tau} = [\theta_j, \theta_{j+\tau}, \dots, \theta_{j+(m-1)\tau}], j = 1, 2, \dots, N - (m-1)\tau \quad (3-3)$$

接着, 对于每个相位序列的重构分量 $\Theta_j^{m,\tau}$ 进行升序排列, 得到相应的位置序列 S_j , 具体操作与第 2.3 章中的式(2-23)和(2-24)完全一致, 最后计算每一排列模式

$F(v), v = 1, 2, \dots, m!$ 在所有位置序列 S_j 中出现的概率为

$$P_{PPE}(v) = \frac{Num(v)}{N - (m-1)\tau}, v = 1, 2, \dots, m! \quad (3-4)$$

其中, $Num(v)$ 是第 v 个排列模式在所有位置序列 S_j 中出现的次数。将上式 (3-4) 带入到香农熵计算公式中得相位排列熵及归一化后的相位排列熵分别为

$$H_{PPE}(m) = - \sum_{v=1}^{m!} P_{PPE}(v) \ln P_{PPE}(v) \quad (3-5)$$

$$h_{PPE}(m) = \frac{H_{PPE}(m)}{\ln(m!)} \quad (3-6)$$

排列熵和相位排列熵的算法流程图如图 3-1 所示。这两个算法的差异在于排列熵相空间重构的对象是时间序列 $x(i)$, 而相位排列熵相空间重构的对象是时间序列 $x(i)$ 经希尔伯特变化求得的瞬时相位序列 $\theta(i)$ 。




图 3-1 排列熵和相位排列熵的算法流程图

Fig. 3-1 Flowcharts of PE and PPE: (a) PE; (b) PPE

3.2 相位排列熵的性能分析

3.2.1 动态变化检测的有效性

为了分析相位排列熵算法对于时间序列动态变化检测的有效性, 产生离散标准模型 logistic 映射^[11], 即

$$x_{i+1}(n) = r(n) \cdot x_i(n) \cdot (1 - x_i(n)) \quad (3-7)$$

其中, $r(n)$ 表示控制参数, 一般的取值范围为 $0 < r(n) \leq 4$, 本文中 $r(n)$ 的变化区间为 $r(n) \in (3.5, 4)$ 。利用上式 (3-7), 当 $x_0(n) = 0.65$, $r(n)$ 的初值为 3.5 且以步长 0.001 增加至 4 时, 产生数据长度为 2500 的时间序列 $x(n)$ 。考虑到 logistic 映射的瞬态特性, 我们只使用 $x(n)$ 的最后 1000 个数据进行熵值计算, 该 logistic 映射的时间序列图如图 3-2(a) 所示。 $m = 4, \tau = 1$, $m = 5, \tau = 1$ 和 $m = 5, \tau = 2$ 时排列熵和相位排列熵的计算结果如图 3-2(b), 3-2(c) 和 3-2(d)。对于图 3-2, 当 $m = 5, \tau = 2$ 时, 排列熵和相位排列熵在 logistic 映射混沌窗处的熵值下降最为明显; 这说明改变嵌入维数 m 和时间延迟 τ 的值会影响排列熵和相位排列熵的检测效果。然而, 无论 m 和 τ 取哪一组值, 相位排列熵在同一混沌窗处的熵值下降都要比排列熵显著。上述分析表明, 当各个参数取值一致时, 相位排列熵能在排列熵的基础上放大对同一动态变化的检测效果。




图 3-2 $r(n) \in (3.5, 4)$ 时的 logistic 映射及相应的排列熵和相位排列熵的熵值结果

Fig. 3-2 The logistic map and the entropy values of PE and PPE when $r(n) \in (3.5, 4)$: (a) the transient logistic map; (b) the entropy values of PE and PPE for $m = 4, \tau = 1$; (c) the entropy values of PE and PPE for $m = 5, \tau = 1$; (d) the entropy values of PE and PPE for $m = 5, \tau = 2$

3.2.2 参数对 PPE 的影响

对动态变化检测而言, 数据长度 N 、嵌入维数 m 和时间延迟 τ 在相位排列熵算法中是十分重要的三个参数。因此, 对这三个参数进行系统化的分析是十分必要的。

为了研究相位排列熵算法在不同嵌入维数时对数据长度的需求, 根据式 (3-7), 当 $r(n) = 4, x_0(n) = 0.65$ 时, 产生数据长度为 100000 的离散时间序列。在仿真中, 设数据长度 $N = 1000, 5000, 10000, 30000, 50000, 100000$, 嵌入维数 $m = 3, 4, 5, 6, 7, 8$, 计

算归一化后的相位排列熵，结果如表 3-1 所示。

表 3-1 不同嵌入维数 m 时相位排列熵所需的数据长度

Tab. 3-1 The requirement of PPE for data length N in different embedding dimension m

PPE	$N = 1000$	$N = 5000$	$N = 10000$	$N = 30000$	$N = 50000$	$N = 100000$
$m = 3$	0.9314	0.9379	0.9341	0.9364	0.9353	0.9362
$m = 4$	0.8812	0.8927	0.8887	0.8901	0.8898	0.8899
$m = 5$	0.8398	0.8435	0.8423	0.8412	0.8403	0.8402
$m = 6$	0.7726	0.8016	0.8046	0.8058	0.8052	0.8051
$m = 7$	0.6959	0.7603	0.7657	0.7666	0.7662	0.7681
$m = 8$	0.6116	0.6916	0.7207	0.7272	0.7309	0.7344

从表 3-1 能够看出，当 $m \leq 5$ 时，相位排列熵在 $N = 1000$ 时的熵值与 $N = 100000$ 时近似相等，这表明数据长度 N 取 1000 时能保证相位排列熵对 $m \leq 5$ 时的检测准确性。同理，当 $m = 6, 7$ 时，相位排列熵中数据长度 N 的取值应为 5000；当 $m = 8$ 时，数据长度 N 的取值应为 50000。考虑到 $N = 50000$ 时所需的算法运行时间过长，且此时相位排列熵的异常变化检测表现与 $N = 10000$ 时没有明显的差异，所以当 $m = 8$ 时，数据长度 N 的最佳取值为 10000。

接下来，将从异常变化检测性能和算法的时间复杂度两个方面来分析改变 m 和 τ 对于相位排列熵的影响。在本文中，所有的仿真实验均在 MATLAB R2014a 上运行，计算机的 CPU 型号为 i5-7500，内存大小为 16GB。

固定时间延迟 $\tau = 1$ ，嵌入维数的取值为 $m = 3, 4, 5, 6, 7, 8$ ，研究嵌入维数 m 改变对相位排列熵在异常变化检测的影响。logistic 映射序列的数据长度为 $N = 10000$ ，logistic 映射中的其他参数设置与图 3-1(a) 一致。为了避免归一化对检测结果造成的干扰，此处通过式 (3-5) 计算相位排列熵的熵值，检测结果如图 3-3 所示。




图 3-3 相位排列熵在不同嵌入维数 m 时对 logistic 映射的检测

Fig. 3-3 PPE for the logistic map under different embedding dimension m . (a) $m = 3, \tau = 1$; (b) $m = 4, \tau = 1$; (c) $m = 5, \tau = 1$; (d) $m = 6, \tau = 1$; (e) $m = 7, \tau = 1$; (f) $m = 8, \tau = 1$

在图 3-3 中，当 logistic 映射中出现混沌窗时，相位排列熵的熵值会产生相应的下降。值得注意的是，当 $m = 3$ 时，相位排列熵无法检测出 $r(n) = 3.905$ 处的混沌窗(如图 3-3 (a)中的红色箭头所示)，随着嵌入维数 m 的增加，相位排列熵在 logistic 映射混沌窗处的熵值下降越来越明显，如图 3-3 (f)所示。因此，当时间延迟 τ 取恒定值时，增加嵌入维数 m 的值，能够改善相位排列熵对于动态变化的检测效果。




图 3-4 相位排列熵在不同时间延迟 τ 时对 logistic 映射的检测
Fig. 3-4 PPE for the logistic map under different delay time τ : (a) $m = 5, \tau = 1$; (b) $m = 5, \tau = 3$; (c) $m = 5, \tau = 5$; (d) $m = 5, \tau = 7$; (e) $m = 5, \tau = 9$; (f) $m = 5, \tau = 11$

当嵌入维数 $m = 5$ 时，取 $\tau = 1, 3, 5, 7, 9, 11$ ，分析时间延迟的改变对相位排列熵的影响，此处的时间序列与图 3-1(a)一致，相应的熵值结果如图 3-4 所示。由图 3-4 可见，当 $\tau = 3$ 时，相位排列熵对于 logistic 映射混沌窗的检测效果要比 $\tau = 1$ 时显著；随着时间延迟 τ 的增加，相位排列熵中重构分量 N^{re} 的数量在不断减少，使得对于原始数据中的特征提取越来越少，故此造成错误的复杂性变化趋势，如图 3-4(f)所示。因此，增加时间延迟 τ 的值不一定能得到更好的异常变化检测结果。

当嵌入维数 m 和时间延迟 τ 取上述值时，所需的算法运行时间如表 3-2 和表 3-3 所示。根据图 3-3，当嵌入维数 m 取较大值时，更有利于异常变化检测。然而，嵌入维数 m 越大，所需的运行时间越多。

表 3-2 不同嵌入维数 m 时相位排列熵所需的算法运行时间
Tab. 3-2 The running time of PPE algorithm at different m ($N = 10000$)

m	τ	Running time(second)
3	1	11086
4	1	11281
5	1	11371
6	1	12243
7	1	20583
8	1	88888

表 3-3 不同时间延迟 τ 时相位排列熵所需的算法运行时间Tab. 3-3 The running time of PPE algorithm at different τ ($N = 1000$)

m	τ	Running time (second)
5	1	1205
5	3	1180
5	5	1173
5	7	1181
5	9	1120
5	11	1100

如表 3-2 所示, 当嵌入维数 $m \leq 6$ 时, 相位排列熵所需的运行时间随着 m 的增大在逐渐增加; 当 $m = 7$ 和 $m = 8$ 时, 相位排列熵的运行时间分别是 $m = 3$ 时的二倍和八倍。如果相位排列熵在 $m = 7, 8$ 时的异常变化检测结果的改善十分明显, 这种情况下忽略运行时间的过度消耗是可取的。综合考虑异常变化检测结果和所需的时间消耗, 相位排列熵用于异常变化检测时嵌入维数的推荐取值应为 $m = 4, 5, 6$ 。随着时间延迟 τ 的增加, 相位排列熵所需的运行时间有所减少, 但是这种减少是微乎其微的。结合图 3-4 的检测结果, 在相位排列熵中, 时间延迟可设置为 $\tau = 1$ 。

3.3 数据长度和噪声对 PPE 的影响

运用 AR 模型产生的动态序列, 研究数据长度和噪声对相位排列熵的影响。根据 AR 模型^[74], 时间序列可由下式产生:

$$\begin{aligned} X_i &= 0.6X_{i-1} - 0.4X_{i-4} + W1_i \\ Y_i &= 0.6X_{i-1} + W2_i \end{aligned} \quad (3-8)$$

此处, $W1_i$ 和 $W2_i$ 是独立的高斯白噪声, 服从均值为 0, 方差为 1 的正态分布。显然, 该模型中序列 $\{Y_i\}$ 取决于序列 $\{X_i\}$ 。因此, 将序列 $\{Y_i\}$ 视为测试序列。基于上一节对嵌入维数 m 和时间延迟 τ 的分析, 在这一章后续的实验中, 两者的取值为 $m = 5, \tau = 1$ 。

根据式 (3-8), 产生数据长度为 30000 的序列 $\{Y_i\}$, 如图 3-5(a) 所示。以 2000 样本点为递增步长, 研究排列熵和相位排列熵在不同数据长度时的熵值变化, 结果如图 3-5(b) 所示。图 3-5(b) 表明, 改变数据长度, 排列熵和相位排列熵的熵值没有明显变化, 分别为 0.987 和 0.825。这说明排列熵和相位排列熵在 $m = 5$ 时对数据长度的敏感性较弱。




图 3-5 排列熵和相位排列熵在改变数据长度时的熵值对比

Fig. 3-5 PE versus PPE in the case of changing data length when $m = 5, \tau = 1$. (a) series $\{Y_t\}$ with 30000 samples generated by AR model; (b) PE and PPE for the different data length




图 3-6 不同信噪比时的排列熵和相位排列熵

Fig. 3-6 PE and PPE in the case of different SNR when $m = 5, \tau = 1$. (a) PE; (b) PPE

利用上式 (3-8) 产生序列 $\{Y_t\}$, 对比分析噪声对于排列熵和相位排列熵的影响。数据长度 N 分别取值为 10000、20000 和 30000 时, 50 次熵值的统计值如图 3-6 所示。图 3-6 表明, 当数据长度 N 为 30000, 并且信噪比 (signal-to-noise ratio, SNR) 为 -10dB 时, 排列熵的均值为 0.9993, 相位排列熵的均值为 0.8455; 随着信噪比的增加, 排列熵和相位排列熵的熵值都在逐渐减小。但是, 相位排列熵熵值下降的幅度比排列熵的大, 这说明相位排列熵对噪声的鲁棒性更差。

3.4 PPE 在实际信号中的应用

3.4.1 心电信号

心脏疾病是当代社会致死率较高的主要疾病之一, 对心脏疾病的诊断依赖于

对心电信号特征的分析 and 提取。因此，准确获取心电信号中的变化特征对于疾病诊断尤为重要。心室纤颤（Ventricular fibrillation, VF）是心脏病病人突然性死亡最为常见的致死疾病，而心室扑动（Ventricular flutter, VFL）被认为是心室纤颤发病的前兆。同时，心室扑动是由严重的室性心动过速（Ventricular tachycardia, VT）逐渐演变而成。基于此，本节分析相位排列熵对这三种实际信号动态变化的检测效果，以期望为研究心脏活动和进一步早期临床疾病诊断提供一些新的思路 and 手段^[75]。

借助国际标准数据库 PhysioNet^[76]，选取室性心动过速信号、心室纤颤信号和心室扑动信号，它们的编号依次为 cu02、cu01 和 418。这三种信号属于不同的非线性病理状态且具有不同的复杂程度，它们的采样频率为 250 Hz，实验中所取得数据长度为 2500，波形图分别如图 3-7(a)、3-8(a)、和 3-9(a)所示。

为了使熵值变化更贴近于实际数据信息变化且考虑到 C-C 方法计算得到的窗口长度 $w = 200$ 会损失过多起始处的熵值变化信息^[51]，此处取窗口长度为 $w = 100$ ，窗口移动步长 $l = 1$ 生成各异常心电信号的子序列矩阵，即此时各子序列为最大重叠序列，再计算子序列矩阵中每一子序列的排列熵和相位排列熵，从而得到各异常心电信号的熵值变化，其中，计算各熵值时的相空间重构嵌入维数为 $m = 5$ ，时间延迟为 $\tau = 1$ 。




图 3-7 排列熵和相位排列熵对于心动过速信号的异常检测

Fig. 3-7 PE versus PPE in the case of VT signal when $m = 5, \tau = 1$. (a) the VT signal; (b) PE curve for VT signal; (c) PPE curve for VT signal

图 3-7 中，心动过速状态位于样本点 1 到 1500 之间，其它为正常状态（此处的正常状态并不是严格意义上的健康状态，它只是一种相对于病理状态而言的非疾病状态）。根据图 3-7 (b)，排列熵在心动过速状态时的均值为 0.51，而它在正常状态时的熵均值为 0.68，这两个状态所对应的排列熵值是十分相近的；然而，相位排列熵在心动过速状态的熵值明显要比正常状态时的低。上述现象表明相位排

列熵相比于排列熵能较为容易的区分出心动过速状态和正常状态。




图 3-8 排列熵和相位排列熵对于心室扑动信号的异常检测

Fig. 3-8 PE versus PPE in the case of VFL signal when $m = 5, \tau = 1$. (a) the VFL signal; (b) PE curve for VFL signal; (c) PPE curve for VFL signal

图 3-8 中，心室扑动状态位于样本点 600 到 1500 之间，其它为正常状态；在心室扑动状态，排列熵的熵均值为 0.42，相位排列熵的熵均值为 0.15。图 3-8 (b) 中，排列熵熵值随着正常状态样本的起伏而出现轻微的波动且在心室扑动状态的熵值比正常状态的熵值低，这说明排列熵能够区分正常状态和心室扑动之间的状态转变。在图 3-8 (c) 中，相位排列熵不仅能识别出正常与心室扑动之间的状态转换，而且对正常状态中的原始数据起伏变化具有明显的追踪能力。因此，排列熵和相位排列熵都能检测出心室扑动信号中的异常病理状态，但是，相位排列熵的检测效果更为显著。




图 3-9 排列熵和相位排列熵对于心室纤颤信号的异常检测

Fig. 3-9 PE versus PPE in the case of VF signal when $m = 5, \tau = 1$. (a) the VF signal; (b) PE curve for VF signal; (c) PPE curve for VF signal

图 3-9(a) 中，心室纤颤状态起始于样本点 1050，终止于样本点 2500。在图 3-9

(b)中,排列熵在正常状态时的熵值为 0.85,并且心室纤颤状态的排列熵熵值要明显低于正常状态;图 3-9 (c)表明相位排列熵的熵值在正常状态随着原始数据的起伏变化出现了明显的熵值下降,在心室纤颤状态时相位排列熵的熵值基本保持不变。比较图 3-9 (a)和(b)可见,相位排列熵对心室纤颤状态的检测比排列熵更明显。

对于上述三种病理状态,无论是利用排列熵还是相位排列熵,心室纤颤的病理状态是最容易被区分出来的。这是因为随着这三种病理状态的依次出现,心脏系统的复杂性在逐渐减小,心电信号的有序性在逐渐增强。因此,这三种病理状态所对应的熵值在依次减小。综上所述,根据图 3-7、3-8 和 3-9,排列熵能检测出心室扑动和心室纤颤信号中的异常病理状态变化,而相位排列熵的检测结果相比于排列熵则更为明显。

除了利用熵值曲线进行定性分析之外,根据式 (2-44),通过计算各个信号熵值的差异系数 (Coefficient of variation, CV),能够实现从定量的角度去评估排列熵和相位排列熵对实际信号异常变化的检测效果,结果如表 3-4。

表 3-4 排列熵和相位排列熵在分析心电信号时的差异系数

Tab. 3-4 The CV of PE and PPE for the ECG signals

	The VT signal	The VFL signal	The VF signal
PE	18.55%	20%	38.92%
PPE	44.62%	55.15%	86.95%

从表 3-4 中得出,对于同一心电信号而言,相位排列熵的差异系数都比排列熵的大,均大于 30%。上述说明从定量分析的角度来看,相位排列熵算法相比于排列熵算法表现出较好的异常变化检测效果。然而,只有当两种状态的复杂性差异十分显著时,排列熵算法才会表现出明显的异常变化检测结果,正如表 3-4 中心室纤颤信号的检测结果所示。因此,无论从定性分析还是从定量分析的角度出发,相位排列熵对于上述病理信号中的异常状态的检测都要比排列熵明显。

3.4.2 工程信号

在工程技术领域,对管道进行无损检测是一项十分有意义的工作,它对于保障管道的正常运输是十分重要的。借助套管磁探伤仪,我们采集了一组磨损管道的特征数据^[77]。该数据采集过程如下:输入端信号发射器发射一占空比为 50%、频率为 42Hz (周期为 0.024 秒)的方波信号,穿过管道的磨损部位被接收端传感器所接收并输出,该输出特征信号如图 3-10(a)所示。

对于上述输出特征信号,利用排列熵和相位排列熵进行特征分析,相应的熵值曲线如图 3-10(b)和(c)所示。仅仅通过图 3-10(a),无法观察到异常数据的具体位置。图 3-10(b)和(c)表明,相比于排列熵,相位排列熵在 6.55 秒到 6.86 秒之间出现

了异常波动且它在剩余时间段内的熵值保持不变：排列熵在上述时间段内并无明显的异常变化且它在其它时间段内有额外的熵值波动，这对于定位特征数据中的异常数据是十分不利的。计算该工程信号排列熵和相位排列熵的熵值所对应的 CV 值分别为 1.99% 和 3.74%，这表明相比于排列熵，相位排列熵的熵值中则存在明显的异常波动。




图 3-10 排列熵和相位排列熵对于工程信号的异常检测

Fig. 3-10 PE versus PPE in the case of engineering signal when $m = 5, \tau = 1$ (the black dotted line is the dynamical change in the output signal). (a) the engineering signal; (b) PE curve for engineering signal; (c) PPE curve for engineering signal

小波相干是一种衡量两个信号在不同频率时相关程度的物理量，它的值越小说明两信号在该处的相关程度越弱^[78]。为了验证相位排列熵对于上述输出特征信号中异常数据检测的准确性，我们计算输入的方波信号与输出的特征信号之间的小波相干，小波相干图如图 3-11 所示。




图 3-11 输入信号和输出特征信号所对应的小波相干图

Fig. 3-11 The diagram of wavelet coherence between the input signal and the output signal (the vertical dashed lines are the range of dynamical change detected by wavelet coherence when the period is 0.024 seconds)

在图 3-11 中, 当周期为 0.024 秒时, 6.55 秒到 6.8 秒所对应的小波相干值相对较小, 表明输入信号与输出信号在 6.55 秒到 6.8 秒时的相关性较弱。这说明由管道损伤所造成的特征数据中的异常变化位于 6.55 秒到 6.8 秒, 这一结论与相位排列熵的检测结果基本一致。因此, 相位排列熵算法能被用于输送管道的无损检测。

上述实际信号的仿真说明相位排列熵算法能够反映动态系统的异常变化, 即, 通过相位排列熵算法, 原始信号中的正常状态和异常状态能够被检测出来, 即使这种异常变化不能直接从原始信号中观察得到。生理信号结合相位排列熵算法能为医生的病症诊断提供一定的帮助。此外, 在工程技术领域, 相位排列熵算法也是一种有效的信号分析工具。

3.5 本章小结

在本章, 将相位信息引入到排列熵中, 提出了相位排列熵算法。利用标准模型 logistic 映射, 验证了相位排列熵算法对于动态变化检测的有效性, 分析了数据长度、嵌入维数和时间延迟这三个变量对相位排列熵的影响。此外, 相位排列熵算法对噪声的鲁棒性也在这一章被研究。最后, 将相位排列熵运用于心电信号和工程异常信号的分析探讨中。基于上述研究, 可以得到如下结论:

(1) 相位排列熵对时间序列中的异常变化具有较好的检测性能; 即, 相比于排列熵算法, 相位排列熵能改善对于同一异常变化的检测效果。

(2) 增加嵌入维数的值, 能够提升相位排列熵算法对于异常变化的检测结果, 但是, 这将会需要更多的算法运行时间。增加时间延迟, 会对研究系统复杂性变化趋势造成一定的干扰。

(3) 当嵌入维数的值小于 5 时, 相位排列熵对于序列的数据长度不敏感。但是, 它对噪声具有较差的鲁棒性。

(4) 通过全面对比分析, 实际信号的仿真表明相位排列熵算法能被用于心电信号和工程信号的异常变化检测。

第4章 广义相位排列熵

相位排列熵将相位信息引入到排列熵算法中,改善了排列熵算法对于一维时间序列中异常变化的检测性能。在相位排列熵算法中,进行熵值计算时运用的是香农熵公式。广义化的熵公式中引入了新的控制参数,通过调节这些参数,可以扩展香农熵的研究范围。瑞利熵、萨利熵和两参数熵等就是这样的一种广义化的熵公式,当它们取特定值时,则等价于香农熵。在这一章中,我们将相位排列熵中计算具体熵值的香农熵用两参数熵替换,提出基于两参数熵的广义相位排列熵 (Generalized phase permutation entropy, $PPE_{q,\delta}$),并着重分析如何调节熵参数 q 和 δ ,才能增强广义相位排列熵对于时间序列中异常变化的检测效果。

4.1 广义相位排列熵的原理

在广义相位排列熵算法中,求得概率分布之前的步骤与前一章所述的相位排列熵中 $P_{PPE}(v)$ 的计算进程完全一致,即

$$P_{PPE}(v) = \frac{Num(v)}{N - (m-1)\tau}, v = 1, 2, \dots, m! \quad (4-1)$$

上式中, $Num(v)$ 表示相同位置序列的个数, $N - (m-1)\tau$ 表示位置序列的总个数。利用 Ribeiro 等人提出的两参数熵 $S_{q,\delta}$ [79] 计算熵值并定义该熵值为广义相位排列熵,计算公式为

$$S_{PPE_{q,\delta}}(v) = \sum_{v=1}^{m!} P_{PPE}(v) \left[\ln_q \left(\frac{1}{P_{PPE}(v)} \right) \right]^\delta, q \in \mathbb{R}, \delta > 0 \quad (4-2)$$

对上式 (4-2) 做微小改变, 即

$$\begin{aligned} & S_{PPE_{q,\delta}}(v) \\ &= \sum_{v=1}^{m!} P_{PPE}(v) \left\{ \text{sign} \left[\ln_q \left(\frac{1}{P_{PPE}(v)} \right) \right] \ln_q \left(\frac{1}{P_{PPE}(v)} \right) \right\}^\delta, q \in \mathbb{R}, \delta \in \mathbb{R} \end{aligned} \quad (4-3)$$

这样,使得 q, δ 属于实数集,有利于全面分析改变参数 q, δ 对系统动态变化检测的影响[31]。

4.2 广义相位排列熵的性能分析

4.2.1 $PE_{q,\delta}$ 与 $PPE_{q,\delta}$ 的对比分析

沿用非线性系统分析中常用的标准模型 logistic 映射,分析广义相位排列熵与

广义排列熵在不同参数时对同一信号动态变化的检测性能。

为了与广义排列熵对 logistic 映射动态变化检测作对比, 此处各参数取值与文献[31]完全一致, 即取连续 $r(n)$ 的递增步长为 0.0005, 对于每个 $r(n)$, 序列 $x(n)$ 的数据长度为 5000。考虑到 logistic 映射的瞬态特性, 使用序列 $x(n)$ 中后 3000 个数据进行熵计算。在熵值计算时, 相空间重构的嵌入维数取 $m=3$, 时间延迟取 $\tau=1$, 仿真结果如图 4-1 所示。




图 4-1 广义排列熵与广义相位排列熵对于 logistic 映射动态变化检测的对比

Fig. 4-1 Comparison of two kinds of entropy for the logistic map dynamical changes detection when $m=3, \tau=1$. (a) Generalized permutation entropy ($PE_{q,\delta}$); (b) Generalized phase permutation entropy ($PPE_{q,\delta}$)

图 4-1(a)和图 4-1(b)分别为当 $m=3, \tau=1$ 时, q 和 δ 取不同值计算得到的广义排列熵 $PE_{q,\delta}$ 和广义相位排列熵 $PPE_{q,\delta}$ 。对于图 4-1(a), 当 $q \neq 1, \delta \neq 1$ 时, $PE_{q,\delta}$ 在 logistic 映射混沌窗处的熵值下降比 $q=1, \delta=1$ 时显著, 由此得出与文献[31]相一致的结论, 即广义排列熵在 q, δ 取恰当值时能放大系统的微小变化。对于图 4-1(b), 在 $q \neq 1, \delta \neq 1$ 时, $PPE_{q,\delta}$ 在 logistic 映射混沌窗处的熵值下降比 $q=1, \delta=1$ 时更为显著, 同样得出广义相位排列熵在 q, δ 取恰当值时也能放大系统的微小变化的结论。对比图 4-1(a)和图 4-1(b), 在 q, δ 取值相同时, $PPE_{q,\delta}$ 比 $PE_{q,\delta}$ 在同一混沌窗处的熵值下降更多, 即在同等条件下, 广义相位排列熵相比于广义排列熵, 能更为有效地检测出系统的动态变化。

4.2.2 熵参数 q, δ 对于 $PPE_{q,\delta}$ 检测动态变化的影响

为了进一步研究熵参数 q, δ 的影响, 取 $-2 < q \leq 2, \delta=1$ 及 $q=1, -2 < \delta \leq 2$, 分别分析 q, δ 取不同值时, 广义相位排列熵对于 logistic 映射动态变化的检测结果。考虑到研究 q, δ 改变对广义相位排列熵检测系统动态变化的计算量相对较大, 仿真中 $r(n)$ 的递增步长为 0.001, 对于每个 $r(n)$, 序列 $x(n)$ 的长度为 2500, 取 $x(n)$ 的后

1000 个数据进行熵计算。一般的,在仿真中嵌入维数可取 $m=3,4,\dots,7$ 间。但是,若取 $m=3$,得到的位置序列可能的模式有 $3!=6$,则位置序列种类数目相对较少不利于对信号进行全面分析;相反,若取 $m=7$,虽然能改善结果的准确性,但此时的计算量也会随之增加。因此,在本章后续的仿真中,均取相空间重构嵌入维数 $m=5$ 。同时,相空间重构中时间延迟 τ 的取值越大,位置序列总个数 $N-(m-1)\tau$ 越小,则求解概率时包含原始序列信息越少,所以此处取相空间重构时间延迟 $\tau=1$ 。




图4-2 $m=5, \tau=1, 0 < q \leq 2, \delta=1$ 时, $PE_{q,1}$ 与 $PPE_{q,1}$ 对于 logistic 映射的动态变化检测
Fig. 4-2 Detecting dynamical changes in logistic map using $PE_{q,1}$ and $PPE_{q,1}$ when $m=5, \tau=1, 0 < q \leq 2, \delta=1$. (a) $PE_{q,1}$ when $0 < q \leq 2$; (b) $PPE_{q,1}$ when $0 < q \leq 2$

图4-2为当 $m=5, \tau=1, 0 < q \leq 2, \delta=1$ 时,以步长 $\Delta q=0.1$ 改变熵参数 q 值时,广义排列熵 $PE_{q,1}$ 和广义相位排列熵 $PPE_{q,1}$ 对于 logistic 映射动态变化的检测结果。由图4-2(a)和4-2(b)的仿真结果可见,当 $0 < q \leq 2, \delta=1$ 时,随着 q 减小, $PE_{q,1}$ 和 $PPE_{q,1}$ 整体呈上升趋势,且当 $0 < q \leq 1$ 时, $PE_{q,1}$ 和 $PPE_{q,1}$ 的上升趋势比较明显。此时, $PE_{q,1}$ 和 $PPE_{q,1}$ 对于 logistic 映射动态变化检测效果明显增强。在 q, δ 取值相等的条件下,对比 $PE_{q,1}$ 和 $PPE_{q,1}$ 发现, $PPE_{q,1}$ 对于 logistic 系统的动态变化放大程度远比 $PE_{q,1}$ 显著。由此得出,当 $q > 0, \delta=1$ 时,减小 q 值,可以提高 $PE_{q,1}$ 和 $PPE_{q,1}$ 对 logistic 系统动态变化的检测效果,且在 q 取值相同的条件下, $PPE_{q,1}$ 比 $PE_{q,1}$ 的检测效果更加显著。

图4-3为当 $m=5, \tau=1, -2 < q \leq 0, \delta=1$ 时,以步长 $\Delta q=0.1$ 改变熵参数 q 值时,广义排列熵 $PE_{q,1}$ 和广义相位排列熵 $PPE_{q,1}$ 对于 logistic 映射动态变化的检测结果。由图4-3(a)可知,当 $-2 < q \leq 0, \delta=1$ 时,随着 q 减小,每次 logistic 系统出现混沌窗后, $PE_{q,1}$ 都会出现明显的上升毛刺,直至 $q=-2$ 时, $r(n)=3.86$ 处的毛刺直接影响对 logistic 系统动态变化的整体判断。对于图4-3(b),当 $-2 < q \leq 0, \delta=1$ 时,随着 q 减小,在 logistic 映射的非混沌窗处, $PPE_{q,1}$ 的起伏波动也明显被放大,表现为毛刺加剧。由此得出,当 $-2 < q \leq 0, \delta=1$ 时, $PE_{q,1}$ 和 $PPE_{q,1}$ 都会产生毛刺,但是 $PPE_{q,1}$

产生的毛刺不影响对系统动态变化的判断。




图 4-3 $m=5, \tau=1$, $-2 < q \leq 0, \delta=1$ 时, $PE_{q,\delta}$ 与 $PPE_{q,\delta}$ 对于 logistic 映射的动态变化检测
Fig. 4-3 Detecting dynamical changes in logistic map using $PE_{q,\delta}$ and $PPE_{q,\delta}$ when $m=5, \tau=1$, $-2 < q \leq 0, \delta=1$. (a) $PE_{q,1}$ when $-2 < q \leq 0$; (b) $PPE_{q,1}$ when $-2 < q \leq 0$




图 4-4 $m=5, \tau=1$, $q=1.0 < \delta \leq 2$ 时, $PE_{q,\delta}$ 与 $PPE_{q,\delta}$ 对于 logistic 映射的动态变化检测
Fig. 4-4 Detecting dynamical changes in logistic map using $PE_{q,\delta}$ and $PPE_{q,\delta}$ when $m=5, \tau=1$, $q=1.0 < \delta \leq 2$. (a) $PE_{1,\delta}$ when $0 < \delta \leq 2$; (b) $PPE_{1,\delta}$ when $0 < \delta \leq 2$

图 4-4 为当 $m=5, \tau=1$, $q=1.0 < \delta \leq 2$ 时, 以步长 $\Delta\delta = 0.1$, 改变熵参数 δ 值, 广义排列熵 $PE_{q,\delta}$ 和广义相位排列熵 $PPE_{q,\delta}$ 对于 logistic 映射动态变化的检测结果。由图 4-4(a) 和 4-4(b) 的仿真结果可见, 当 $q=1.0 < \delta \leq 2$ 时, 随着 δ 值增大, $PE_{1,\delta}$ 和 $PPE_{1,\delta}$ 整体呈上升趋势, 且对 logistic 映射动态变化的检测效果越来越显著; 但是, 相比于 $PE_{1,\delta}$ 的上升幅度, 随着 δ 增大, $PPE_{1,\delta}$ 上升的更快, 且对于 logistic 动态变化检测效果更为明显。由此说明, 当 $q=1, \delta > 0$ 时, 增大 δ 值, 可以提高 $PE_{1,\delta}$ 和 $PPE_{1,\delta}$ 对于 logistic 系统动态变化的检测效果, 且 δ 取值相同的条件下, $PPE_{1,\delta}$ 比 $PE_{1,\delta}$ 的检测效果更为显著。




图 4-5 $m=5, \tau=1, q=1.2 < \delta < 0$ 时, $PE_{q,\delta}$ 与 $PPE_{q,\delta}$ 对于 logistic 映射的动态变化检测
Fig. 4-5 Detecting dynamical changes in logistic map using $PE_{q,\delta}$ and $PPE_{q,\delta}$ when $m=5, \tau=1, q=1.2 < \delta < 0$. (a) $PE_{q,\delta}$ when $-2 < \delta < 0$; (b) $PPE_{q,\delta}$ when $-2 < \delta < 0$

图 4-5 为 $m=5, \tau=1, q=1.2 < \delta < 0$ 时, 以步长 $\Delta\delta=0.1$, 改变熵参数 δ 值, 广义排列熵 $PE_{q,\delta}$ 和广义相位排列熵 $PPE_{q,\delta}$ 对于 logistic 映射动态变化的检测熵值图。在图 4-5 中, 当 $q=1.2 < \delta < 0$ 时, 随着 δ 值减小, $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 整体呈下降趋势, 但是两者在 logistic 系统出现混沌窗时熵值增大, 在非混沌窗处熵值减小, 这与实际恰好相反。这是由于为了全面分析 δ 值的影响, 人为扩充了 δ 的取值范围, 使其属于实数域, 如式 (4-3)。而且, 当 $q=1.2 < \delta < 0$ 时, 随着 δ 值减小, $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 对于 logistic 系统动态变化检测并无明显放大, 表现为熵值属于区间 $(0,1)$ 。由此说明, 当 $q=1, \delta < 0$ 时, $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 对于 logistic 系统动态变化检测结果与实际相反, 且减小 δ 值, $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 对于 logistic 系统动态变化检测效果无明显增强。

接着对于 q 减小且 δ 增大时, 广义排列熵 $PE_{q,\delta}$ 与广义相位排列熵 $PPE_{q,\delta}$ 在检测 logistic 系统动态变化时的规律进行分析。分别取 $q=0.3, \delta=1.7, q=0.4, \delta=1.6, q=0.5, \delta=1.5, q=1, \delta=1$, 计算 logistic 映射的 $PE_{q,\delta}$ 和 $PPE_{q,\delta}$, 结果如图 4-6 所示。

图 4-6 表明, 当 $q > 0$ 且 $\delta > 0$ 时, q 值选取越小且 δ 取值越大, $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 对于 logistic 系统动态变化检测效果越显著; 同时, 在 q, δ 取值相同的条件下, $PPE_{q,\delta}$ 对于动态变化的检测效果比 $PE_{q,\delta}$ 显著的多。然而, q 越小且 δ 取值越大, $PE_{q,\delta}$ 在 logistic 系统出现混沌窗后产生的上升毛刺越明显, 而 $PPE_{q,\delta}$ 并未出现毛刺。因此, 在之后的分析时可以同时使 q, δ 取较优值, 但是要尽可能的选用 $PPE_{q,\delta}$ 去测量, 从而使检测结果更为显著。




图 4-6 $m=5, \tau=1$ 时, q, δ 取不同值时, $PE_{q,\delta}$ 与 $PPE_{q,\delta}$ 对于 logistic 映射的动态变化检测
Fig. 4-6 Detecting dynamical changes in the logistic map with different value of q, δ using $PE_{q,\delta}$ and $PPE_{q,\delta}$ when $m=5, \tau=1$. (a) The generalized permutation entropy ($PE_{q,\delta}$); (b) The generalized phase permutation entropy ($PPE_{q,\delta}$)

4.2.3 数据长度和噪声对 $PPE_{q,\delta}$ 的影响

为了探究数据长度和噪声对于广义相位排列熵的影响, 产生数据长度为 10000 的高斯波包序列, 如图 4-7(a)。图 4-7(b)为 $m=5, \tau=1$ 时, 以 1000 为递增步长改变数据长度所对应的广义排列熵 $PE_{q,\delta}$ 和广义相位排列熵 $PPE_{q,\delta}$ 。




图 4-7 $m=5, \tau=1$ 时, 不同数据长度和信噪比 (SNR) 时的 $PE_{q,\delta}$ 与 $PPE_{q,\delta}$

Fig. 4-7 The $PE_{q,\delta}$ and $PPE_{q,\delta}$ in different length of data and signal-to-noise ratio (SNR) when $m=5, \tau=1$. (a) The sequence of Gaussian wave packets; (a1) enlarged vies of each wave packet in a Gaussian wave packet sequence; (b) $PE_{q,\delta}$ and $PPE_{q,\delta}$ in different length of data when $m=5, \tau=1$; (c) $PE_{q,\delta}$ and $PPE_{q,\delta}$ in different SNR when $m=5, \tau=1$

图 4-7(b) 的表明, 当 $m=5, \tau=1$ 且 q, δ 取不同值时, 不同数据长度下, $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 的熵值基本保持不变, 并不会因数据长度改变而出现明显熵值波动。由此说明, 数据长度对 $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 影响较小。图 3-7(c) 为 $m=5, \tau=1$ 时, 对图 4-7(a)

所示数据长度为 10000 的高斯波包序列加入信噪比初始值为 -15dB，递增步长为 0.5dB 的高斯噪声，重复计算 30 次得到的各信噪比时广义排列熵 $PE_{q,\delta}$ 和广义相位排列熵 $PPE_{q,\delta}$ 的统计平均熵值。由图 4-7(c) 的仿真结果可见，对于数据长度为 10000 的高斯波包序列，不同 SNR 时的 $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 值都相对稳定，若观察具体熵值，不同 q, δ 时的 $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 都随着 SNR 的增加有轻微的减小。由此说明，相对来看， $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 对于噪声具有良好的鲁棒性。

4.3 广义相位排列熵在异常心电信号检测中的应用

广义相位排列熵是在相位排列熵的基础上，研究熵参数 q, δ 改变对于异常变化检测的影响。为前后一致，此处选取与第三章中的心电信号完全一致相同的数据进行仿真分析，结果如图 4-8，图 4-9，图 4-10。




图 4-8 $m=5, \tau=1$ 时， $PE_{q,\delta}$ 与 $PPE_{q,\delta}$ 对室性心动过速信号的检测

Fig. 4-8 $PE_{q,\delta}$ and $PPE_{q,\delta}$ in the case of the V1 signal when $m=5, \tau=1$. (a) The V1 signal; (b) The results of $PE_{q,\delta}$ in different q, δ ; (c) The results of $PPE_{q,\delta}$ in different q, δ

图 4-8(a) 为 cu02 室性心动过速信号，其中，室性心动过速的病发阶段位于数据点 1-1500，数据点 1500-2500 为正常阶段。图 4-8(b) 和 4-8(c) 分别为 $q=1, \delta=1$ ， $q=0.5, \delta=1.5$ ， $q=0.4, \delta=1.6$ 时室性心动过速信号的 $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 熵值图。图 4-8(b) 和图 4-8(c) 的仿真结果表明，随着 q 减小 δ 增大， $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 的熵值都相应的增加，且室性心动过速病发阶段与正常阶段熵值的差别越来越大。但是，在 q, δ 取值相等的条件下，相比于 $PE_{q,\delta}$ ， $PPE_{q,\delta}$ 能更容易的区分出室性心动过速病发阶段和正常阶段。

图 4-9(a) 所示为 418 心室扑动信号，数据点 600-1500 为心室扑动病发阶段，其余处为正常阶段。图 4-9(b) 和 4-9(c) 分别为 $q=1, \delta=1$ ， $q=0.5, \delta=1.5$ ， $q=0.4, \delta=1.6$ 时心室扑动信号的 $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 熵值图。与图 4-8(b) 和图 4-8(c) 一

致, 图 4-9(b)和图 4-9(c)显示随着 q 减小 δ 增大, $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 的熵值都相应增加且对于心室扑动信号状态变化检测越来越清晰, 特别是 $PPE_{q,\delta}$ 能很清楚的显示出心室扑动病发阶段与正常阶段相互转换发生的具体数据点, 即正常阶段转变为病发阶段发生在数据点 600 左右, 病发阶段转变为正常阶段发生在数据点 1500 左右。




图 4-9 $PE_{q,\delta}$ 与 $PPE_{q,\delta}$ 对比分析 $m=5, \tau=1$ 时的心室扑动信号

Fig. 4-9 $PE_{q,\delta}$ and $PPE_{q,\delta}$ in the case of the VFL signal when $m=5, \tau=1$. (a) The VFL signal; (b) The results of $PE_{q,\delta}$ in different q, δ ; (c) The results of $PPE_{q,\delta}$ in different q, δ




图 4-10 $PE_{q,\delta}$ 与 $PPE_{q,\delta}$ 对比分析 $m=5, \tau=1$ 时的心室纤颤信号

Fig. 4-10 $PE_{q,\delta}$ and $PPE_{q,\delta}$ in the case of the VF signal when $m=5, \tau=1$. (a) The VF signal; (b) The results of $PE_{q,\delta}$ in different q, δ ; (c) The results of $PPE_{q,\delta}$ in different q, δ

图 4-10(a)为 cu01 心室纤颤信号, 数据点 1050-2500 为心室纤颤病发阶段, 其余处为正常心电信号。图 4-10(b)和 4-10(c)分别为 $q=1, \delta=1$, $q=0.5, \delta=1.5$, $q=0.4, \delta=1.6$ 时心室纤颤信号的 $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 的熵值图。相比于图 4-8 和图 4-9, 无论 q, δ 取何值, $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 都能明显的检测出心室纤颤病发阶段。对比相同 q, δ 时的 $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 可以发现, 对于心室纤颤检测, $PPE_{q,\delta}$ 比 $PE_{q,\delta}$ 更能清晰刻画数据的起伏及状态变化。同时, 随着 q 减小 δ 增大, 病发阶段与正常阶段之间的

$PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 的熵值差增加。

上述分析表明,与 logistic 映射得出的结论一致,在 q, δ 取相同值时, $PPE_{q,\delta}$ 对于这三种疾病的动态变化检测相比于 $PE_{q,\delta}$ 更为显著;此外,随着 q 减小且 δ 增大, $PE_{q,\delta}$ 和 $PPE_{q,\delta}$ 对于这三种疾病的病发状态检测效果明显增强。因此,合理选择 q, δ 值, $PPE_{q,\delta}$ 能更好、更准确的检测出病理系统的动态变化。

4.4 本章小结

在本章中,用两参数熵替代相位排列熵中计算熵值的香农熵,提出了广义相位排列熵算法。借助标准模型 logistic 映射,对比分析了广义相位排列熵在检测系统动态变化方面的性能,探究了两参数熵中的 q, δ 改变对于 logistic 系统动态变化检测的影响,并给出了如何恰当的选取 q, δ 值以提高广义排列熵和广义相位排列熵对于微小变化的检测效果。通过高斯波包序列,研究了信号的数据长度和信噪比变化对广义相位排列熵的影响。最后,将广义相位排列熵运用到异常心电信号的检测分析中。仿真研究表明:当广义排列熵和广义相位排列熵的 q, δ 取值相同时,对于系统动态变化检测,广义相位排列熵比广义排列熵更为明显。当 $q > 0, \delta > 0$ 时, q 取值越小, δ 取值越大,无论是针对 logistic 映射还是心电信号的异常变化检测,广义排列熵和广义相位排列熵都能放大对序列中异常变化的检测效果。此外,数据长度变化对于广义排列熵和广义相位排列熵基本无影响且两者对噪声均具有良好的鲁棒性。广义相位排列熵在系统动态变化检测领域具有一定优势,能够为之后医生临床诊断疾病提供一定参考。

第 5 章 编码排列熵

相位排列熵和广义相位排列熵是对排列熵算法在宏观上的改进。随着研究的深入,基于已有的排列熵衍生算法,对于一维时间序列的异常变化检测而言,排列熵算法在数据的细节特征信息抓取方面依然有待改进。传统的排列熵算法通过计算各个排列模式在所有位置序列中出现的频率去获得相应的概率。但是,相同位置序列所对应的原重构分量不一定完全一致。因此,仅仅利用排列模式去区分不同的重构分量是不够精确的,会人为损失重构分量中的某些细节信息。加权排列熵和幅度敏感排列熵在这一方面做了相应的优化。相比于排列熵,这两个算法对信号中幅度异常的检测有明显的改善^[36,39]。除了幅度的异常变化检测之外,系统中也存在时间序列复杂度的异常变化。针对这种情况,加权排列熵和幅度敏感排列熵将不具优势。

排列熵在进行特征提取时的另一个难点在于嵌入维数 m 的选取。如果 m 的取值过小,排列熵中排列模式的种类会较少,这对于异常变化检测时数据的特征提取是十分不利的^[12];但是,增加嵌入维数 m 的值,相应的数据长度 N 的值也应增加,这会显著增加算法的计算量。对于一些实际数据,给定的数据量较小,但又需要较好的异常检测效果,此时已有的排列熵衍生算法则显得无能为力。

造成上述两方面问题的主要原因在于排列熵算法将排列模式 (Permutation pattern) 作为求解概率 $P_{PE}(v)$ 时不同概率分量的区分准则太过粗略。第二章提到的多元排列熵算法在排列模式的基础上进行二次区分的,并将其称为排列模式的子模式。多元排列熵中求解排列模式的子模式针对的是嵌入维数 m 等于 3 时,这种子模式的构造方法对于 $m > 3$ 时并不适用。基于上述问题,这一章中我们在排列模式的基础上构造一种更为灵活多样的子模式,并提出编码排列熵 (Coded permutation entropy, CPE)。

5.1 编码排列熵的原理

加权排列熵和幅度敏感排列熵对于幅度异常变化检测具有较好表现的原因在于它们直接利用数据中的具体数值进行概率计算。因此,相比于排列熵,它们对数据中幅值变化范围较小,而复杂度变化十分显著的异常的检测则无明显的改善。为了避免这一问题,我们在排列模式的基础上构造了二次分区 (The secondary partitioning),并提出了编码排列熵。编码排列熵算法的计算步骤如下:




图 5-1 编码排列熵的算法流程图

Fig. 5-1 The flow chart of CPE algorithm

Step 1: 获取离散时间序列 $x(i)$ 所对应的位置序列 S_j ，计算步骤如式 (2-22) 到式 (2-24) 所示。

Step 2: 求得每个位置序列 S_j 在所有排列模式 $F(v)$ 中的位置索引，称该索引为序列编号 (The serial number)，并将该值记录在矩阵 Q 第 1 列的第 j 行，即 $Q(j,1)$ 。

Step 3: 对具有相同位置序列的所有重构分量 $X_j^{m,\tau}$ 求平均值，称其为均值序列 $Me(v), v=1,2,\dots,m!$ 。

Step 4: 利用下式 (5-1)，比较重构分量 $X_j^{m,\tau}$ 与所对应均值序列 $Me(v)$ 中每个元素的大小，并将结果依次记录在矩阵 Q 第 j 行的第 2 列到第 $m+1$ 。

$$Q(j,1+k) = \begin{cases} 2, & X_j^{m,\tau}(k) > Me(v,k) \\ 1, & X_j^{m,\tau}(k) = Me(v,k), j=1,2,\dots,N-(m-1)\tau, k=1,\dots,m \\ 0, & X_j^{m,\tau}(k) < Me(v,k) \end{cases} \quad (5-1)$$

Step 5: 上述操作构造出编码序列矩阵 $Q(N-(m-1)\tau,1+m)$ ，称矩阵 Q 中的每一行为一个编码序列。显然，编码排列熵中可能的编码模式共有 $m!3^m$ 种，每一个独立出现的编码序列的概率为

$$P_{CPE}(r) = \frac{Num(r)}{N-(m-1)\tau}, 1 \leq r \leq m!3^m \quad (5-2)$$

Step 6: 将上述概率 $P_{CPE}(r)$ 带入到香农熵公式中，得到编码排列熵，即

$$H_{CPE}(m) = - \sum_{r=1}^{m!3^m} P_{CPE}(r) \ln P_{CPE}(r) \quad (5-3)$$

归一化的编码排列熵计算公式为：

$$h_{CPE}(m) = H_{CPE}(m) / \ln(m! \cdot 3^m) \quad (5-4)$$

由于排列熵和编码排列熵归一化的基准不同，为了做对比分析，在本章中我们使用未归一化的熵公式进行具体的熵值计算。




图 5-2 排列熵和编码排列熵对一随机序列的计算过程

Fig.5-2 The processes of calculating PE and CPE for a simple example

编码排列熵的算法流程图如图 5-1，图 5-2 用一个简单的例子来对比说明排列熵和编码排列熵的具体熵值计算过程。该例子中的离散时间序列 $x(i)$ 由服从标准正态分布的随机数构成， $x(i)$ 的数据长度为 10。在图 5-2 中，位置序列“1,2,3”是 $m=3$ 的所有排列模式中的第五个；因此，我们令 $Q(i,1)=5$ ，此处 $j=6,7,8$ ，这一具体过程如图 5-2 中的红色粗线所示。由于重构分量 $X_6^{3,1}$ 、 $X_7^{3,1}$ 和 $X_8^{3,1}$ 具有相同的位置序列“1,2,3”，则相应的均值序列 $Me(5)$ 可以通过求解 $X_6^{3,1}$ 、 $X_7^{3,1}$ 、 $X_8^{3,1}$ 的平均值得到，即 $Me(5)=[0.3076,0.5943,0.8231]$ 。然后，比较 $X_6^{3,1}$ 、 $X_7^{3,1}$ 和 $X_8^{3,1}$ 与 $Me(5)$ 中各元素的大小，得到 $Q(6,2:4)$ 、 $Q(7,2:4)$ 和 $Q(8,2:4)$ 。图 5-2 中仅仅呈现了 $Q(8,2:4)$ 的计算过程如图中蓝色粗线所示， $Q(8,2:4)=[2,2,2]$ 表示矩阵 $Q(8,4)$ 的第 8 行的第 2 到 4 列的各个元素值依次为 2，2 和 2。显然，编码排列熵将具有不同值的重构分量 $X_6^{3,1}$ 、 $X_7^{3,1}$ 和 $X_8^{3,1}$ 标记为三种不同的编码模式，而排列熵将它们都标记为同一种排列模式。图 5-1 和图 5-2 说明，如果只用矩阵 $Q(N-(m-1)\tau,1+m)$ 第一列中的不同元素出现的频率表示概率，此时的编码排列熵则退化为排列熵。

5.2 算法性能分析

排列熵、加权排列熵和幅度敏感排列熵中可能的排列模式的个数为 $m!$ ；编码排列熵中构造了二次分区，它可能的编码模式的个数为 $m!3^m$ 。因此，相比于排列熵、加权排列熵和幅度敏感排列熵，编码排列熵对于动态变化检测会具有较为显著的检测效果。在这一章中，构建三种常用的模型，即模拟信号、离散标准模型和连续标准模型，去验证编码排列熵在动态变化检测方面的性能。除了利用熵值图进行定性分析之外，还将计算各个熵值所对应的熵值标准差（The standard deviation, Std）（本章没有继续采用差异系数 CV 进行定量分析的原因在于二次分区整体增加了编码排列熵对同一信号的检测熵值，故而编码排列熵所求得的熵均值与其他三种算法不一致，如若继续采用 CV 进行定量对比分析将会减弱编码排列熵对异常变化检测的实际表现）。最后，分析噪声对于编码排列熵的影响以及算法的复杂度。

5.2.1 模拟信号

产生一模拟信号 $y(t)$ ，如下式

$$y(t) = \begin{cases} \sin(2\pi \cdot t) + \sin(2\pi \cdot 10 \cdot t), & 0 < t \leq 10 \\ \sin(2\pi \cdot t) + \sin(2\pi \cdot 10 \cdot t) + \sin(2\pi \cdot 20 \cdot t), & 10 < t \leq 20 \\ 2 \cdot \sin(2\pi \cdot t) + 1.5 \cdot \sin(2\pi \cdot 10 \cdot t) + 1.25 \cdot \sin(2\pi \cdot 20 \cdot t), & 20 < t \leq 30 \end{cases} \quad (5-5)$$

此处，信号 $y(t)$ 的采样频率是 1000Hz，采样时间为 30 秒。模拟信号 $y(t)$ 如图 5-3 所示。




图 5-3 模拟信号 $y(t)$

Fig. 5-3 Synthetic signal $y(t)$




图 5-4 排列熵、加权排列熵、幅度敏感排列熵和编码排列熵对于仿真信号 $y(t)$ 中的动态变化检测对比

Fig. 5-4 Detecting dynamical change existing in the synthetic signal $y(t)$ with different m using PE, WPE, AAPE and CPE: (a) $m = 3, \tau = 1$; (b) $m = 4, \tau = 1$; (c) $m = 5, \tau = 1$; (d) $m = 6, \tau = 1$

表 5-1 模拟信号 $y(t)$ 的四种排列熵算法熵值标准差和其在突变处的熵值跳变

Tab. 5-1 The jumps (Jump1, Jump2) and the Std of PE, WPE, AAPE and CPE for the synthetic signal $y(t)$ in different m . Jump1 is equal to $Mv2$ minus $Mv1$ and Jump2 is equal to $Mv2$ minus $Mv3$, where $Mv1$, $Mv2$ and $Mv3$ represent the mean of entropy value when $t = 2s - 10s$, $t = 12s - 20s$ and $t = 22s - 30s$

模拟 信号	$m = 3$			$m = 4$		
	Jump1	Jump2	Std	Jump1	Jump1	Std
PE	0.081	0.001	0.037	0.169	0.008	0.075
WPE	-0.006	0.006	0.005	0.000	0.007	0.003
AAPE	0.073	0.003	0.032	0.135	0.006	0.060
CPE	0.130	0.092	0.053	0.268	0.179	0.108
模拟 信号	$m = 5$			$m = 6$		
	Jump1	Jump2	Std	Jump1	Jump2	Std
PE	0.256	0.015	0.113	0.354	0.029	0.155
WPE	0.014	0.009	0.006	0.037	0.012	0.015
AAPE	0.190	0.007	0.085	0.251	0.007	0.112
CPE	0.334	0.144	0.133	0.413	0.179	0.164

图 5-4(a)-(d)分别是排列熵、加权排列熵、幅度敏感排列熵和编码排列熵对上述模拟信号 $y(t)$ 在 $m = 3, \tau = 1$, $m = 4, \tau = 1$, $m = 5, \tau = 1$ 和 $m = 6, \tau = 1$ 时的检测结果(幅度敏感排列熵中参数 A 在本章中的取值都为 0.5)。在这次计算中,窗口长度 w 为 2000 样本点,每个窗口之间采用最大重叠。图 5-4 的仿真结果表明,排列熵、加权排列熵、幅度敏感排列熵和编码排列熵的熵值在 $t = 10s$ 时突然增加(此处的熵值跳变被记为 Jump1),并且这四种算法在 $t = 20s$ 时出现熵值下降(Jump2)。造

成上述熵值变化的原因在于模拟信号 $y(t)$ 在 10 秒到 20 秒时的复杂度相对较高, 故而此时的熵值应当大于 0 秒到 10 秒时的熵值。信号 $y(t)$ 在 $t \in (10, 20)$ 时的幅值与 $t \in (20, 30)$ 时不同, 这造成了四种算法在 $t = 20s$ 时的熵值下降。无论 m 取何值时, 熵值结果表明编码排列熵在 $t = 10s$ 和 $t = 20s$ 时的熵值跳变都是这四种算法中最显著的。

四种算法在分析信号 $y(t)$ 时的熵值跳变和熵值标准差如表 5-1 所示, 由表中数据可知, 编码排列熵在 $t = 10s$ 和 $t = 20s$ 时的熵值变化和熵值标准差都是这四种算法中最大的。上述两方面说明编码排列熵不仅在复杂性异常变化检测方面有一定优势, 而且在幅度异常检测方面也具备优势。

5.2.2 离散标准模型

logistic 映射通过式 (3-7) 产生, 在这一章的仿真分析中, 取 $x_0(n) = 0.65$, $r(0) = 3.5$, $r(n)$ 以步长 0.001 连续增加至 $r(n) = 4$ 。对于每一个 $r(n)$, 产生数据长度为 3000 的序列 $x(n)$ 。为了考虑 logistic 映射的瞬时特性, 使用每个 $x(n)$ 的后 2000 个数据进行熵值计算。




图 5-5 排列熵、加权排列熵、幅度敏感排列熵和编码排列熵对于 logistic 映射混沌窗检测对比

Fig. 5-5 Detecting chaotic windows existing in the logistic map with different m using PE, WPE,

AAPE and CPE: (a) $m = 3, \tau = 1$; (b) $m = 4, \tau = 1$; (c) $m = 5, \tau = 1$; (d) $m = 6, \tau = 1$

图 5-5 为排列熵、加权排列熵、幅度敏感排列熵和编码排列熵在嵌入维数 m 取不同值时, 对 logistic 映射中动态变化的检测结果。图 5-5 显示, 在 m 取值相同时, 排列熵、加权排列熵和幅度敏感排列熵对 logistic 映射中混沌窗的检测效果基本一致, 而编码排列熵在出现混沌窗时的熵值下降是这四种算法中最明显的。虽然加权排列熵考虑了相同位置序列所对应的幅值差异信息, 但它相比于排列熵而言, 并没有明显改善对 logistic 映射中混沌窗的检测效果。对比图 5-5(a)和(b)可以发现, 当 $m = 3.4$ 时, 排列熵、加权排列熵和幅度敏感排列熵没有检测出 $r(n) = 3.638$ 处的

混沌窗，而编码排列熵则在此处有明显的熵值下降。

表 5-2 记录了四种算法在分析 logistic 映射时的熵值标准差及其在 $r(n)=3.702$ 和 $r(n)=3.961$ 时的熵值跳变，即 Jump1 和 Jump2。表 5-2 中，编码排列熵分析 logistic 映射时的熵值标准差和跳变依然是四种算法中最大的。上述仿真结果表明，编码排列熵增加了对 logistic 映射中动态变化的检测能力。并且，对编码排列熵而言，嵌入维数 m 在取较小值时依然能实现异常变化的精准检测。

表 5-2 logistic 映射的四种排列熵算法熵值标准差和其在突变处的熵值跳变

Tab. 5-2 The jumps when $r(n)=3.702$ (Jump1) and $r(n)=3.961$ (Jump2), and the Std of PE, WPE, AAPE and CPE for the logistic map in different m . Jump1 is equal to the entropy value when $r(n)=3.701$ minus those when $r(n)=3.702$, and Jump2 is equal to the entropy value when $r(n)=3.96$ minus those when $r(n)=3.961$

Logistic map	$m=3$			$m=4$		
	Jump1	Jump2	Std	Jump1	Jump2	Std
PE	0.137	0.445	0.107	0.218	0.952	0.351
WPE	0.144	0.240	0.089	0.245	0.804	0.327
AAPE	0.132	0.375	0.098	0.219	0.937	0.356
CPE	0.397	0.857	0.385	0.589	1.467	0.657
Logistic map	$m=5$			$m=6$		
	Jump1	Jump2	Std	Jump1	Jump2	Std
PE	0.611	0.877	0.478	0.764	1.524	0.737
WPE	0.689	0.710	0.447	0.846	1.330	0.699
AAPE	0.655	0.850	0.551	0.821	1.503	0.801
CPE	1.003	2.091	0.844	1.223	2.750	1.106

5.2.3 连续标准模型

在本节，连续标准模型 Lorenz 映射将被用来分析编码排列熵对周期窗的检测效果，Lorenz 映射的表达式为^[12]

$$\begin{aligned}
 \frac{dx}{dt} &= -10(x-y) \\
 \frac{dy}{dt} &= -xz + r(t)x - y \\
 \frac{dz}{dt} &= xy - \frac{8}{3}z
 \end{aligned}
 \tag{5-6}$$

步长 $\Delta t = 0.01$ ，利用四阶龙科库塔（Fourth-order Runge-Kutta method）方法求解上式（5-6）。在仿真中， $x(0) = -1$ ， $y(0) = 0$ ， $z(0) = -1$ ， $r(0) = 28$ ，并且以步长 $\Delta r = 0.2$ 增加 $r(t)$ 至 $r(t) = 268$ 。对于每一个 $r(t)$ ，生成一数据长度为 3000 的序列 $x(t)$ 。与 logistic 映射中的熵值求解一致，使用每个序列的最后 2000 个数据进行熵

值计算，暂态 Lorenz 映射的时间序列图如图 5-6 所示。




图 5-6 Lorenz 映射

Fig. 5-6 The transient Lorenz map

理论上，Lorenz 映射中存在三个周期窗，它们位于 $99.524 < r(t) < 100.795$ ， $145 < r(t) < 166$ ，和 $r(t) > 214.4$ 。嵌入维数 m 和时间延迟 τ 的选取与 Δt 有关，基于这一点，我们取 $m = 3, \tau = 10$ ， $m = 4, \tau = 10$ ， $m = 5, \tau = 10$ ， $m = 6, \tau = 10$ 进行仿真^[12]，相应的熵值图如图 5-7 所示。




图 5-7 排列熵、加权排列熵、幅度敏感排列熵和编码排列熵对于 lorenz 映射中的动态变化检测对比

Fig. 5-7 Detecting dynamical change existing in the lorenz map with different m using PE, WPE, AAPE and CPE: (a) $m = 3, \tau = 1$; (b) $m = 4, \tau = 1$; (c) $m = 5, \tau = 1$; (d) $m = 6, \tau = 1$

图 5-7 中，由仿真结果可见，排列熵、加权排列熵和幅度敏感排列熵对 Lorenz 映射中周期窗口的检测结果仍然十分相近。图 5-7(a)和(b)中，当 $m = 3, 4$ 时，编码排列熵对 $r(t) = 166$ (Jump1) 处的周期窗具有较好的检测效果，存在于 $r(t) = 230.4$ (Jump2) 处的异常变化在 $m = 4$ 时可以被编码排列熵检测出来，而其它三种算法只有到 $m = 6$ 时才可检测出此处的变化。在 m 取较小值时就能得到较好的异常变化

检测效果对实际序列的异常分析十分有利。

表 5-3 展示了检测 Lorenz 映射时相应的熵值标准差和跳变, 结果表明无论嵌入维数 m 取四种中的哪个值, 编码排列熵的熵值跳变和标准差都最大。

表 5-3 Lorenz 映射的四种排列熵算法熵值标准差和其在突变处的熵值跳变

Tab. 5-3 The jumps when $r(t)=166$ (Jump1) and $r(t)=230.4$ (Jump2), and the Std of PE, WPE, AAPE and CPE for the Lorenz map in different m . Jump1 is equal to the entropy value when $r(t)=166.4$ minus those when $r(t)=166$, and Jump2 is equal to the entropy value when $r(t)=227$ minus those when $r(t)=230.4$

Lorenz map	$m=3$			$m=4$		
	Jump1	Jump2	Std	Jump1	Jump1	Std
PE	-0.073	-0.008	0.078	0.055	-0.003	0.154
WPE	0.013	0.016	0.120	0.143	0.006	0.226
AAPE	-0.033	0.008	0.097	0.117	0.012	0.152
CPE	0.299	0.033	0.246	0.809	0.414	0.479
Lorenz map	$m=5$			$m=6$		
	Jump1	Jump2	Std	Jump1	Jump2	Std
PE	0.355	0.038	0.375	0.953	0.181	0.587
WPE	0.442	0.041	0.374	0.992	0.202	0.570
AAPE	0.390	0.043	0.376	0.959	0.195	0.579
CPE	1.286	0.660	0.693	1.605	0.852	0.880

对于排列熵算法, Bandt 和 Pompe 建议嵌入维数取 $m=3,4,5,6,7$ [11]。然而, 排列模式 $F(v)$ 的个数在 $m=3$ 和 $m=4$ 时分别为 6 和 24。因此, 可能的排列模式数目过少是嵌入维数 $m=3,4$ 时排列熵算法对异常变化检测不显著的直接原因 [12]。加权排列熵和幅度敏感排列熵考虑了相同位置序列在幅值信息上的差异, 但是, 对于上述所示的 logistic 映射中的混沌窗和 Lorenz 映射中的周期窗的检测, 它们的结果并不比排列熵的明显。然而, 编码排列熵无论是对 logistic 映射中的混沌窗和 Lorenz 映射中的周期窗的检测, 都具有十分显著的异常变化检测能力。上述现象表明, 编码排列熵中所构造的二次分区对一维时间序列中的特征提取是十分有用的, 它显著改善了排列熵算法在 $m=3,4$ 时的检测结果。

5.2.4 噪声的鲁棒性分析

为了研究编码排列熵在不同信噪比时的动态变化检测表现, 向两个序列中加入不同分贝 (dB) 的高斯白噪声, 序列长度均为 20000, 由式 (3-7) logistic 映射在 $r(n)=3.961$ 和 $r(n)=3.962$ 时产生。在 logistic 映射中, $r(n)=3.961$ 时生成的序列 $x(n)$ 是周期序列, 而 $r(n)=3.962$ 时的是混沌序列。当 $m=3, \tau=1$ 时, 排列熵、加权

排列熵、幅度敏感排列熵和编码排列熵在不同信噪比时对上述周期序列和混沌序列的熵值统计值如上图 5-8 所示。




图 5-8 四种算法对含不同噪声时的周期信号和混沌信号检测表现

Fig. 5-8 The performance of four algorithm in distinguish periodic series and chaotic series under different SNR when $m = 3, \tau = 1$: (a) PE; (b) WPE; (c) AAPE; (d) CPE

图 5-8 表明，随着信噪比的增加，周期序列所对应熵值的下降要比混沌序列的多。此外，无论是对于周期序列还是混沌序列，编码排列熵的熵值下降是这四种算法中最多的。在图 5-8 中，当信噪比的值接近 13dB 时，编码排列熵逐渐能区分出周期序列和混沌序列，而排列熵、加权排列熵和幅度敏感排列熵分别在信噪比为 10, 9 和 11 开始区分出这两个序列。上述现象表明，相比于其它三种算法，编码排列熵对噪声具有较差的鲁棒性。

5.2.5 算法的复杂度分析

在这一节中，对排列熵、加权排列熵、幅度敏感排列熵和编码排列熵的算法复杂度进行对比分析，这四种算法在分析上述三种模型时的算法运行时间如表 5-4 所示。

在表 5-4 中，随着嵌入维数 m 的增加，排列熵、加权排列熵、幅度敏感排列熵和编码排列熵的算法运行时间都在增加；当 m 值不变时，排列熵算法的运行时间在这四种算法中是最少的。对于 $m = 3$ 时，加权排列熵的算法运行时间略微高于编码排列熵；当 $m = 4, 5, 6$ 时，四种算法所需的运行时间从小到大排序依次为排列熵、幅度敏感排列熵、加权排列熵和编码排列熵。加权排列熵和编码排列熵的算法运行时间长的原因在于加权排列熵增加了权值求解，而编码排列熵中增加了二次分区。

表 5-4 对于上述三种模型, 排列熵、加权排列熵、幅度敏感排列熵和编码排列熵在不同 m 时的算法运行时间Tab.5-4 The running time of PE, WPE, AAPE and CPE for the above three models in different m

		运行时间			
		$m = 3$	$m = 4$	$m = 5$	$m = 6$
模拟信号	PE	1037	1668	3677	17534
	WPE	2293	2800	5315	19823
	AAPE	1390	1945	4239	17950
	CPE	1925	3021	5534	20811
Logistic map	PE	8	16	53	290
	WPE	29	36	73	309
	AAPE	15	24	71	386
	CPE	21	37	89	365
Lorenz map	PE	26	41	134	711
	WPE	81	100	183	765
	AAPE	40	57	151	712
	CPE	74	162	441	1367

此外, 我们计算了编码排列熵相比于排列熵的算法运行时间增长率 (The growth rate, Gr), 增长率的计算公式为 $Gr = \frac{T_{CPE} - T_{PE}}{T_{PE}} \cdot 100\%$, T_{CPE} 和 T_{PE} 分别表示排列熵和编码排列熵的算法运行时间, 结果如表 5-5。

表 5-5 不同 m 时编码排列熵相对于排列熵的算法运行时间增长率Tab. 5-5 The Gr of running time of CPE referring to PE in different m

		Gr			
		$m = 3$	$m = 4$	$m = 5$	$m = 6$
模拟信号		86%	81%	51%	19%
Logistic map		163%	131%	68%	26%
Lorenz map		185%	295%	229%	92%
Average		145%	169%	116%	55.5%

在表 5-5 中, “Average” 表示同一 m 时三个信号对应的增长率均值; 如果取不同 m 时的 “Average” 的均值, 则得到编码排列熵对排列熵的运行时间增长率为 121%。相同的操作可被用来计算编码排列熵对加权排列熵和幅度敏感排列熵的运行时间增长率, 不同 m 时的 “Average” 的均值分别为 25% 和 72%。

算法的运行时间与其它因素密切相关, 比如, 计算机的硬件配置。因此, 我们还列出了四种算法的时间复杂度如表 5-6。表 5-6 表明, 四种算法的时间复杂度由小到大的排序依次为排列熵、幅度敏感排列熵、加权排列熵和编码排列熵, 这与算法运行时间得到的结论基本一致。综上所述, 无论是从算法的运行时间还是时间复杂度的角度来分析, 编码排列熵的计算花费是这四种算法中最高的。

表 5-6 排列熵、加权排列熵、幅度敏感排列熵和编码排列熵的时间复杂度

Tab. 5-6 The time complexity of PE, WPE, AAPE and CPE

算法	时间复杂度
PE	$O((N-(m-1)\tau) \cdot m!)$
WPE	$O((N-(m-1)\tau) \cdot 4m!)$
AAPE	$O((N-(m-1)\tau) \cdot m!(m-1))$
CPE	$O((N-(m-1)\tau) \cdot m!(m+1))$

5.3 编码排列熵在轴承故障信号检测中的应用

滚动轴承是旋转机械中最为重要的一种零部件，而轴承故障是造成机器故障最为常见的原因之一。为了验证编码排列熵在实际信号异常变化检测中的表现，在 CWRU (Case Western Reserve University) 轴承故障数据库^[80]中取内圈故障 (The inner race fault, IRF)，滚动体故障 (Ball fault, BF) 和外圈故障 (Outer race fault, ORF) 信号用于实验分析^[81-82]。这些信号的采样频率为 12000 Hz，信号中的异常脉冲被认为是数据中的异常变化。

在这次分析中，上述三个信号分别取 $0s-0.5s$ 、 $0s-10s$ 和 $0s-0.5s$ 的样本作为实验的测试数据^[83]，计算各个熵值时的窗口长度 w 取值分别为 200、500 和 200，且各个窗口之间为最大数据重叠。




图 5-9 m 取不同值时，排列熵、加权排列熵、幅度敏感排列熵和编码排列熵检测轴承内圈故障信号中的异常脉冲

Fig. 5-9 Detecting abnormal pulse existing in IRF signal with different m using PE, WPE, AAPE and CPE: (a) The IRF signal; (b) $m=4, \tau=1$; (c) $m=3, \tau=1$; (d) $m=5, \tau=1$

内圈故障信号如图 5-9(a)所示，图 5-9(b)、5-9(c)和 5-9(d)为不同 m 时计算的熵值曲线。在图 5-9 中，每当内圈故障信号中出现一个幅值脉冲时，熵曲线中总会出现持续时间为一个窗口长度的熵值下降，而编码排列熵的熵值下降在 $m=3,4$ 时相

比于其它三种算法是最为明显的；当 $m = 5$ 时，编码排列熵的检测效果并没有加权排列熵的显著。这是由于当 $w = 200, m = 5$ 时，编码排列熵中具有相同排列模式的重构分量的个数较少，此时它的检测优势不容易显现出来。

表 5-7 排列熵、加权排列熵、幅度敏感排列熵和编码排列熵在不同 m 时分析轴承内圈故障信号的熵值标准差

Tab. 5-7 The Std of PE, WPE, AAPE and CPE for IRF signal in different m

IRF	Std		
	$m = 3$	$m = 4$	$m = 5$
PE	0.010	0.061	0.096
WPE	0.043	0.122	0.261
AAPE	0.011	0.068	0.127
CPE	0.165	0.176	0.081

表 5-7 为四种算法在不同嵌入维数时测得轴承内圈故障信号的熵值标准差。在表 5-7 中，当 $m = 3, 4$ 时，编码排列熵的熵值标准差最大，因此编码排列熵的检测结果相比于其它三种算法则更为突出。




图 5-10 m 取不同值时，排列熵、加权排列熵、幅度敏感排列熵和编码排列熵检测轴承滚动体故障信号中的异常脉冲

Fig. 5-10 Detecting abnormal pulse existing in BF signal with different m using PE, WPE, AAPE and CPE: (a) The BF signal; (b) $m = 3, \tau = 1$; (c) $m = 4, \tau = 1$; (d) $m = 5, \tau = 1$.

滚动体故障信号如图 5-10(a)， $m = 3, 4, 5, \tau = 1$ 时的熵值图如图 5-10(b)，5-10(c)和 5-10(d)。在图 5-10(b)和 5-10(c)中，当 $m = 3, 4$ 时，编码排列熵算法对滚动体故障信号的异常脉冲检测效果与对内圈故障的基本一致。对比图 5-9(c)和 5-10(c)，编码排列熵对于内圈故障和滚动体故障信号的检测差异在于当 $m = 5$ 时，编码排列熵对后者的异常检测差异更为明显。表 5-8 所示为四个熵算法在不同嵌入维数时对于滚动体故障信号检测的熵值标准差。表 5-8 中，当 $m = 3, 4$ 时，编码排列熵的熵值标准差依旧是四种算法中最大的； $m = 5$ 时，编码排列熵的熵值标准差要比加权排

列熵和幅度敏感排列熵小。

表 5-8 排列熵、加权排列熵、幅度敏感排列熵和编码排列熵在不同 m 时分析轴承滚动体故障信号的熵值标准差

Tab. 5-8 The Std of PE, WPE, AAPE and CPE for BF signal in different m

BF	Std		
	$m = 3$	$m = 4$	$m = 5$
PE	0.004	0.048	0.094
WPE	0.015	0.053	0.113
AAPE	0.004	0.048	0.100
CPE	0.061	0.109	0.097

图 5-11 呈现了外圈故障信号的幅度谱和四种算法在不同 m 时的熵值。当外圈故障信号中出现异常脉冲时，编码排列熵的值会有一个轻微的下降，之后它的熵值将保持恒定并持续一个窗口长度。造成上述熵值变化的原因在于外圈故障信号的异常脉冲强度比内圈故障信号的强。因此，相比于加权排列熵对内圈和外圈故障信号在不同 m 时近乎一致的熵值表现而言，编码排列熵的上述检测差异可以更好的识别这两个轴承故障信号。除此之外，在不同 m 值时，四种算法对于内圈和外圈故障信号中的异常脉冲的检测表现基本一致。




图 5-11 m 取不同值时，排列熵、加权排列熵、幅度敏感排列熵和编码排列熵检测轴承外圈故障信号中的异常脉冲

Fig. 5-11 Detecting abnormal pulse existing in ORF signal with different m using PE, WPE, AAPE and CPE: (a) The ORF signal; (b) $m = 3, \tau = 1$; (c) $m = 4, \tau = 1$; (d) $m = 5, \tau = 1$

表 5-9 为四种算法在不同 m 时对轴承外圈故障信号检测的熵值标准差。表 5-9 中，当 $m = 3, 4$ 时，编码排列熵的熵值标准差最大，而它在 $m = 5$ 时的熵值标准差在四种算法中最小。无论是根据图 5-11 还是表 5-9，编码排列熵在 $m = 3, 4$ 时的异常变化检测效果是四种算法中最好的，而在 $m = 5$ 时，加权排列熵的表现略胜一筹。

表 5-9 排列熵、加权排列熵、幅度敏感排列熵和编码排列熵在不同 m 时分析轴承外圈故障信号的熵值标准差Tab. 5-9 The Std of PE, WPE, AAPE and CPE for ORF signal in different m

ORF	Std		
	$m = 3$	$m = 4$	$m = 5$
PE	0.012	0.059	0.093
WPE	0.062	0.120	0.251
AAPE	0.020	0.083	0.167
CPE	0.214	0.227	0.088

对比 5.2 节三个标准模型的检测结果, 编码排列熵在 $m = 5$ 时对轴承故障信号的异常检测相比于其它三种算法并没有很明显的改善。在理论上, 对相同嵌入维数 m , 窗口长度 w 的值越大, 每个可能的排列模式在所有位置序列中重复出现的概率就越大, 此时编码排列熵在特征提取方面的算法优势才能更好的凸显出来。为了从仿真分析的角度说明这一点, 我们截取 $t = 5s - 10s$ 时图 5-10(a) 的轴承故障信号。在这次仿真中, 固定嵌入维数的值为 $m = 5$, 分别设窗口长度 w 的值为 500、800 和 1000, 对应的熵值标准差如表 5-10。

表 5-10 当 $m = 5$, 改变窗口长度 w , 四种算法在分析滚动体故障信号的熵值标准差Tab. 5-10 The Std of the entropy value for the BF signal when changing the value of w under the condition of $m = 5$

	Std			
	PE	WPE	AAPE	CPE
$w = 500$	0.0904	0.1179	0.1010	0.1047
$w = 800$	0.0701	0.0995	0.0821	0.1186
$w = 1000$	0.0629	0.0940	0.0758	0.1218

在表 5-10 中, 随着 w 的增加, 编码排列熵的熵值标准差在增加, 这说明它对于滚动体故障信号在 $t = 5s - 10s$ 时的异常脉冲的检测效果在增强。窗口长度在分析三种标准模型时为 $w = 2000$, 而它在分析轴承故障信号时是 200 和 500。因此, 在分析三种标准模型且当 $m = 5$ 时, 编码排列熵中每个可能的排列模式在所有位置序列中重复出现的概率要比分析轴承故障信号时的大, 这就使得编码排列熵对于前者的检测效果要比后者显著。综上所述, 当可能的排列模式在所有位置序列中重复出现的概率越大时, 编码排列熵相比于其它三种算法对此时的动态变化检测具有较好的检测效果。

5.4 本章小结

为了改善排列熵算法中存在的问题, 基于二次分区, 提出了一种改进算法,

即，编码排列熵。分别运用模拟信号、离散标准模型和连续标准模型分析了编码排列熵的性能。最后，我们将编码排列熵算法用于实际轴承故障信号的检测分析中。仿真研究表明：无论是对于模拟信号、logistic 映射、还是 Lorenz 映射，相比于排列熵、加权排列熵和幅度敏感排列熵，编码排列熵均能放大对动态变化的检测效果；并且当 $m=3,4$ 时，编码排列熵表现出更为突出的特征提取能力。然而，编码排列熵对于噪声具有较差的鲁棒性，它的计算花费也要比其它三种算法高。实际信号的分析表明，当嵌入维数 m 的取值较小时，编码排列熵相比于其它三种算法对于轴承故障信号中的异常脉冲具有较为显著的检测效果。

第6章 总结与展望

6.1 全文总结

异常变化是自然界和人类社会中一种十分常见的由环境或机体自身状态改变而引起个体脱离原存在状态的一种现象,检测复杂系统的异常变化对于分析系统的存在状况及预防未知风险的发生具有重要意义。排列熵是一种分析时间序列复杂性的算法,由于它概念简单、抗噪性能良好而被学者们所广泛运用。在宏观方面,目前已有的排列熵衍生算法都是从幅度出发去进行相应的研究,而众多研究表明,相位相比于幅度则包含更多信息。在微观方面,随着研究的深入,已有的排列熵衍生算法在细节特征提取方面的缺陷逐渐暴露。本文以改善排列熵算法对异常变化的检测性能为研究目标,从宏观和微观两方面着手,提出了三种排列熵优化算法,并且对这三种算法的性能进行了分析。具体研究内容及主要结论如下:

1、将相位信息引入到排列熵算法中,提出了相位排列熵,给出了算法的原理,对比分析了排列熵算法和相位排列熵算法对标准模型 logistic 映射中混沌窗的检测差异,讨论了数据长度、嵌入维数、时间延迟对相位排列熵性能的影响,以及相位排列熵的算法复杂度和噪声鲁棒性。最后,将相位排列熵算法运用于心电信号和工程信号的异常检测分析。研究结果表明:相比于排列熵,相位排列熵能改善对信号中异常变化的检测效果;增加嵌入维数,能提高相位排列熵对同一异常的检测性能;当嵌入维数小于等于 5 时,相位排列熵对数据长度不敏感。然而,相位排列熵相比于排列熵具有较差的噪声鲁棒性。实际信号的仿真说明相位排列熵算法在生理信号处理及工程信号分析方面是一种十分有用的工具。

2、用两参数熵取代相位排列熵中计算熵值的香农熵,提出了广义相位排列熵。借助标准模型 logistic 映射,对比分析了广义相位排列熵在检测系统动态变化方面的性能,探究了两参数熵中的 q, δ 改变对于 logistic 系统动态变化检测的影响并给出了如何恰当的选取 q, δ 值以提高广义相位排列熵对于微小变化的检测效果。通过高斯波包序列,研究了信号的数据长度和信噪比变化对广义相位排列熵的影响。最后,将广义相位排列熵运用到异常心电信号的检测分析中。仿真结果表明:当广义排列熵和广义相位排列熵的 q, δ 取值相同时,对于系统动态变化检测,广义相位排列熵比广义排列熵更为明显。当 $q > 0, \delta > 0$ 时, q 取值越小, δ 取值越大,无论是针对 logistic 映射还是心电信号,广义排列熵和广义相位排列熵都能放大对这些序列中异常变化的检测效果。此外,数据长度变化对于广义排列熵和广义相

位排列熵基本无影响且两者对噪声均具有良好的鲁棒性。广义相位排列熵在系统动态变化检测领域具有一定优势，能够为之后医生临床诊断疾病提供一定参考。

3、基于二次分区，提出了编码排列熵。运用模拟信号、离散标准模型和连续标准模型阐明了排列熵、加权排列熵和幅度敏感排列熵在动态变化检测方面的不足，呈现了编码排列熵的优势。此外，对于四种算法在含噪信号的动态变化检测方面的表现和算法复杂度也进行了研究。最后，将编码排列熵算法用于实际轴承故障信号的检测分析中。仿真分析表明：无论是模拟信号还是 logistic 映射或 Lorenz 映射，相比于排列熵、加权排列熵和幅度敏感排列熵，编码排列熵能放大对于动态变化的检测效果。当 $m=3,4$ 时，编码排列熵表现出较为准确的特征提取能力。然而，编码排列熵对于噪声具有较差的鲁棒性，它的计算花费也要比其它三种算法高。实际信号的分析表明，当嵌入维数 m 的取值较小时，编码排列熵相比于其它三种算法对于轴承故障信号中的异常脉冲具有较为显著的检测效果。

6.2 未来工作展望

本文提出了三种排列熵改进算法，即，相位排列熵、广义相位排列熵和编码排列熵。并且，对比分析了上述三种算法在不同条件时的性能表现。这三种算法对于异常变化检测都具有较为显著的检测效果，但是对于噪声都具有较差的鲁棒性。基于本文的研究内容，今后的工作可从以下几个方面开展：

1. 本文主要侧重于提出这三种算法，对于这些算法其它性能的探索 and 实际场景的应用，还有待补充和加强。

2. 本文的所有熵值都是试验仿真的结果，对于编码排列熵而言，实际熵值与试验结果之间的差异还需理论推导。

3. 有文献表明，分数阶对于图像具有较好的噪声鲁棒性，今后可从提升算法的抗噪性入手，开展相应的工作。

4. 除了一维数据，二维图像也是信号处理中最为常见的一种数据类型。本文提出的三种算法有望被扩展到二维数据的分析，并将其与深度学习相结合，实现二维图像的特征提取。

参考文献

- [1] Martin M T, Plastino A, Rosso O A. Generalized statistical complexity measure: geometrical and analytical properties[J]. *Physica A: Statistical Mechanics and its Application*, 2006, 369(2): 439-462.
- [2] López-Ruiz R, Mancini H L, Calbet X. A statistical measure of complexity[J]. *Physics Letters A*, 1995, 209: 321-326.
- [3] Shi J J, Liang M, Guan Y P. Bearing fault diagnosis under variable rotational speed via the joint application of windowed fractal dimension transform and generalized demodulation: a method free from prefiltering and resampling[J]. *Mechanical Systems and Signal Processing*, 2016, 68: 15-33.
- [4] Wolf A, Swift J B, Swinney H L, et al. Determining lyapunov exponents from a time series[J]. *Physica D: Nonlinear Phenomena*, 1985, 16(3): 285-317.
- [5] Ding R, Li J. Nonlinear finite-time lyapunov exponent and predictability[J]. *Physics Letter A*, 2007, 364(5): 396-400.
- [6] Hao B, Zheng W. *Applied symbolic dynamics and chaos*[M]. Singapore: World Scientific, 2014.
- [7] Pincus S M. Approximate entropy as a measure of system complexity[J]. *Proceedings of the National Academy of Science of the United states of America*, 1991, 88: 2297-2301.
- [8] Richman J S, Moorman J R. Physiological time-series analysis using approximate entropy and sample entropy[J]. *American Journal of Physiology Heart and Circulatory Physiology*, 2000, 278: H2039-H2049.
- [9] Costa M, Goldberger A L, Peng C K. Multiscale entropy analysis of complex physiologic time series[J]. *Physical Review Letters*, 2002, 89: 068102.
- [10] Lobier M, Siebenhuhner F, Satu P, et al. Phase transfer entropy: a novel phase-based measure for directed connectivity in networks coupled by oscillatory interactions[J]. *NeuroImage*, 2014, 85: 853-872.
- [11] Bandt C, Pompe B. Permutation entropy: a natural complexity measure for time series[J]. *Physical Review Letters*, 2002, 88: 174102.
- [12] Zhang J, Hou G, Cao K, et al. Operation conditions monitoring of flood discharge structure based on variance dedication rate and permutation entropy[J]. *Nonlinear*

- Dynamics, 2018, 93: 2517-2531.
- [13] Bandt C, Keller G, Pompe B. Entropy of interval maps via permutations[J]. Nonlinearity, 2002, 15(5): 1595.
- [14] Cao Y, Tung W, Gao J, et al. Detecting dynamical changes in time series using the permutation entropy[J]. Physical Review E, 2004, 70: 046217.
- [15] 赵小磊, 任明荣, 张亚庭等. 基于排列熵的心电信号非线性分析[J]. 现代电子技术, 2010, 19: 90-93.
- [16] Yan R, Liu Y, Gao R. Permutation entropy: a nonlinear statistical measure for status characterization of rotary machines[J]. Mechanical Systems and Signal Processing, 2012, 29: 474-484.
- [17] Rosso O A, Larrondo H A, Martin M T, et al. Distinguishing noise from chaos[J]. Physical Review Letters, 2007, 99: 154102.
- [18] Li D, Liang Z, Wang Y, et al. Parameter selection in permutation entropy for an electroencephalographic measure of isoflurane anesthetic drug effect[J]. Journal of Clinical Monitoring and Computation, 2013, 27: 113-123.
- [19] Zhang H, Liu X. Analysis of parameter selection for permutation entropy in logistic chaotic series[C]. 2018 International Conference on Intelligent Transportation, Big Data and Smart City, Xiamen, China, 2018, 398-402.
- [20] 陆振波, 蔡志明, 姜可宇. 基于改进的 C-C 方法的相空间重构参数选择[J]. 系统仿真学报, 2007, 19(11): 2527-2530.
- [21] 谢忠玉, 张立. 相空间重构参数选择方法的研究[J]. 基础及前沿研究, 2009, 16: 42-43.
- [22] 饶国强, 冯辅周, 司爱威等. 排列熵算法参数的优化确定方法研究[J]. 振动与冲击, 2014, 33(1): 188-193.
- [23] Staniek M, Lehnertz K. Parameter selection for permutation entropy measurements[J]. International Journal of Bifurcation and Chaos, 2007, 17(10): 3729-3733.
- [24] Quintero-Quiroz C, Pigolotti S, Torrent M C, et al. Numerical and experimental study of the effects of noise on the permutation entropy[J]. New Journal of Physics, 2015, 17: 1-8.
- [25] Tsallis C. Possible generalization of Boltzmann-Gibbs statistics[J]. Journal of Statistical Physics, 1988, 52: 479-487.
- [26] Rényi A. On measure of information and entropy[C]. The fourth Berkeley

- Symposium on Mathematics, Statistics and Probability, 1960, 547-561.
- [27] Bian S, Shang P. Refined two-index entropy and multiscale analysis for complex system[J]. Communication in Nonlinear Science and Numerical Simulation, 2016, 39: 233-247.
- [28] Zunino L, Perez D G, Kowalski A, et al. Fractional Brownian motion, fractional Gaussian noise, and Tsallis permutation entropy[J]. Physica A: Statistical Mechanics and its Application, 2008, 387: 6057-6068.
- [29] Zhao X, Shang P, Huang J. Permutation complexity and dependence measure of time series[J]. Europhysics Letters, 2013, 102: 40005.
- [30] Mammone N, Duun-Henriksen J, Kjaer T W, et al. Differentiating interictal and ictal states in childhood absence epilepsy through permutation Rényi entropy[J]. Entropy, 2015, 17: 4627-4643.
- [31] Xu M, Shang P. Generalized permutation entropy analysis based on the two-index entropic form $S_{q,s}$ [J]. Chaos: An Interdisciplinary Journal of Nonlinear Science, 2015, 25: 053114.
- [32] Xu K, Wang J. Weighted fractional permutation entropy and fractional sample entropy for nonlinear Potts financial dynamics[J]. Physics Letters A, 2017, 381: 767-779.
- [33] Cánovas J S, García-Clemente G, Muñoz-Guillermo M. Comparing permutation entropy functions to detect structural changes in time series[J]. Physica A: Statistical Mechanics and its Application, 2018, 507: 153-174.
- [34] Liu X. F, Wang Y. Fine-grained permutation entropy as a measure of natural complexity for time series[J]. Chinese Physics B, 2009, 18(7): 2690-2695.
- [35] Bian C, Qin C, Ma Q, et al. Modified permutation entropy analysis of heartbeat dynamics[J]. Physical Review E, 2012, 85: 021906.
- [36] Fadlallah B, Chen B, Keil A, et al. Weighted-permutation entropy: a complexity measure for time series incorporating amplitude information[J]. Physical Review E, 2013, 87: 022911.
- [37] Gao J F, Chen K Y, Wu P, et al. Leakage detection of pipeline based on weighted-permutation entropy[C]. 2017 29th Chinese control and decision conference, 2820-2823.
- [38] Xia J, Shang P, Wang J, et al. Permutation and weighted-permutation entropy analysis for the complexity of nonlinear time series[J]. Communication in

- Nonlinear Science and Numerical Simulation, 2016, 31: 60-68.
- [39] Azami H, Escudero J. Amplitude-aware permutation entropy: illustration in spike detection and signal segmentation[J]. Computer Methods and Programs in Biomedicine, 2016, 128: 40-51.
- [40] Ribeiro H, Zunino L, Lenzi E, et al. Complexity-entropy causality plane as a complexity measure for two-dimensional patterns[J]. PloS one, 2012, 7(8): e40689.
- [41] Zunino L, Ribeiro H V. Discriminating image texture with the multiscale two-dimension complexity-entropy causality plane[J]. Chaos solitons fractals, 2016, 91: 679-688.
- [42] Sigaki H Y, Perc M, Ribeiro H V. History of art paintings through the lens of entropy and complexity[J]. Proceedings of the National Academy of Sciences, 2018, 115(37): E8585-E8594.
- [43] Sigaki H Y, Souza R F, Souza R T, et al. Estimating physical properties from liquid crystal texture via machine learning and complexity-entropy methods[J]. Physical Review E, 2019, 99(1): 013311.
- [44] He S, Sun K, Wang H. Multivariate permutation entropy and its application for complexity analysis of chaotic systems[J]. Physica A: Statistical Mechanics and its Application, 2016, 461: 812-823.
- [45] Aziz W, Arif M. Multiscale permutation entropy of physiological time series[C]. 2005 Pakistan Section Multitopic Conference, Karachi, Pakistan, 2005, 1-6.
- [46] Ouyang G X, Li J, Liu X, et al. Dynamic characteristics of absence EEG recordings with multiscale permutation entropy analysis[J]. Epilepsy Research, 2013, 104: 246-252.
- [47] 姚文坡, 刘铁兵, 戴加飞等. 脑电信号的多尺度排列熵分析[J]. 物理学报, 2014, 63(7): 078704.
- [48] Liu T, Yao W, Wu M, et al. Multiscale permutation entropy analysis of electrocardiogram[J]. Physica A: Statistical Mechanics and its Application, 2017, 471: 492-498.
- [49] Ribeiro H V, Zunino L, Mendes R S, et al. Complexity entropy causality plane: a useful approach for distinguishing songs[J]. Physica A: Statistical Mechanics and its Application, 2012, 391(7): 2421-2428.
- [50] Liu L, Miao S, Cheng M, et al. Permutation entropy for random binary sequences[J]. Entropy, 2015, 17: 8207-8216.

- [51] Little D J, Kane D M. Permutation entropy with vector embedding delays[J]. *Physical Review E*, 2017, 96: 062205.
- [52] Tao M, Poskuviene K, Alkayem N F, et al. Permutation entropy based on non-uniform embedding[J]. *Entropy*, 2018, 20: 612.
- [53] Bandt C. A new kind of permutation entropy used to classify sleep stages from invisible EEG microstructure[J]. *Entropy*, 2017, 19(5): 197.
- [54] Shannon C E. A mathematical theory of communication[J]. *Bell System Technical Journal*, 1948, 27(3): 379-423.
- [55] Zunino L, Olivares F, Rosso O A. Permutation min-entropy: an improved quantifier for unveiling subtle temporal correlations[J]. *Europhysics Letters*, 2015, 109(1): 10005.
- [56] Jaynes E T. Information theory and statistical mechanics[J]. *Physical Review*, 1957, 106(4): 620-630.
- [57] Tsallis C. Introduction to nonextensive statistical mechanics: approaching a complex world[M]. Springer Science and Business Media, 2009.
- [58] Li J, Ning X. Dynamical complexity detection in short-term physiological series using base-scale entropy[J]. *Physical Review E*, 2006, 73(5): 052902.
- [59] Schreiber T. Measuring information transfer[J]. *Physical Review Letter*, 2000, 85(2): 461-464.
- [60] Lobier M, Siebenhuhner F, Palva S, et al. Phase transfer entropy: a novel phase-based measure for directed connectivity in networks coupled by oscillatory interactions[J]. *Neuroimage*, 2014, 85: 853-872.
- [61] 宋晔, 张小凤. 基于相位传递熵的心电信号分析[J]. *陕西师范大学学报(自然科学版)*, 2018, 46(2): 52-56.
- [62] Li C Q, Zhang X F. Analysis the characteristic of ECG signals based on the transfer entropy[C]. *IEEE Symposium on Piezoelectricity*, 2014: 5-8.
- [63] Mao X G, Shang P J. Transfer entropy between multivariate time series[J]. *Communications in Nonlinear Science and Numerical Simulation*, 2017, 47: 338-347.
- [64] Michael W, Benjamin R, Maria R, et al. Transfer entropy in magnetoencephalographic data: quantifying information flow in cortical and cerebellar network[J]. *Progress in Biophysics and Molecular Biology*, 2011, 105(1/2): 80-97.
- [65] Zhang J, Ge H, Cao K, et al. Operation condition monitoring of flood discharge

- structure based on variance dedication rate and permutation entropy[J]. *Nonlinear Dynamics*, 2018, 93: 2517-2531.
- [66] Brown C E. Applied multivariate statistics in geohydrology and related science[M]. Berlin, Springer, 1998: 155-157.
- [67] Abdi H. Coefficient of variation[J]. *Encyclopedia of Statistical Sciences*, 2011, 94(1): 94.
- [68] Bruns A, Eckhorn R, Jokeit H, et al. Amplitude envelope correlation detects coupling among incoherent brain signals[J]. *Neuroreport*, 2000, 11: 1509-1514.
- [69] Oppenheim A. V, Lim J. S. The importance of phase in signals[C]. *Proceedings of the IEEE*, 1981, 69: 529-541.
- [70] Luo H, Poeppel D. Phase patterns of neuronal responses reliably discriminate speech in human auditory cortex[J]. *Neuron*, 2007, 54: 1001-1010.
- [71] Schyns P. G, Thut G, Gross J, Cracking the code of oscillatory activity[J]. *PLoS biology*, 2011, 9: e1001064.
- [72] Ng B. S. W, Logothetis N. K, Kayser C, EEG phase patterns reflect the selectivity of neural firing[J]. *Cerebral Cortex*, 2013, 23: 389-398.
- [73] Rosenblum M. G, Pikovsky A. S, Kurths J. Phase synchronization of chaotic oscillators[J]. *Physical Review Letters*, 1996, 76: 1804-1807.
- [74] Zhang N, Lin A, Shang P. Symbolic phase transfer entropy method and its application[J]. *Communications in Nonlinear Science and Numerical simulation*, 2017, 51: 78-88.
- [75] Liberthson R, Nagel E, Hirschman J, et al. Pathophysiologic observations in prehospital ventricular fibrillation and sudden cardiac death[J]. *Circulation*, 1974, 49: 790-798.
- [76] Goldberger A, Amaral L, Glass L, et al. Physiobank, physiotoolkit, and physionet: components of a new research resource for complex physiologic signals[J]. *Circulation*, 2000, 101: 215-220.
- [77] 王彩峰. 基于相干小波变化的信号相位差估计[D]. 陕西师范大学, 2014.
- [78] Aguiar-Conraria L, Soares M. J. The continuous wavelet transform: a primer[C]. University of Minho, Working Paper, 2011.
- [79] Ribeiro M. S, Nobre F. D, Tsallis C. Probability distributions and associated nonlinear Fokker-Planck equation for the two-index entropic form $S_{q,\delta}$ [J]. *Physical Review E*, 2014, 89: 052135.

- [80] Bearing Data center of Case Western Reserve University. Available online: <http://csegroups.case.edu/bearingdatacenter/pages/12k-drive-end-bearing-fault-data>(accessed on 30 May 2019)
- [81] Wu S. D, Wu P. H, Wu C. W, et al. Bearing fault diagnosis based on multiscale permutation entropy and support vector machine[J]. Entropy, 2012, 14: 1343-1356.
- [82] Wu S. D, Wu C. W, Humeau-Heurtier A. Refined scale-dependent permutation entropy to analyze systems complexity[J]. Physica A: Statistical Mechanics and its Application, 2016, 450, 454-461.
- [83] Smith W. A, Randall R. Rolling element bearing diagnostics using the case western reserve university data: a benchmark study[J]. Mechanical Systems and Signal Processing, 2015, 64: 100-131.

致 谢

七年的师大生活转瞬即逝，回首过往，一幕幕恍如昨日般清晰明了。从2013年本科入学至今，我见证了这座知识殿堂的飞速发展，它也见证了我这七年的成长。盛夏时的防暑降温茶、中秋时的师大牌月饼、除夕时的新春团圆宴等，都是师大留给我们最为宝贵的记忆。在此，感谢所有师大人一直以来的栽培与照拂，您的谆谆教诲我将永远铭记于心。

行文至此，首先感谢我的导师张小凤老师，是您引领我走入科研这条新奇而又令人神往的道路。在三年的研究生生涯里，每一次组会汇报的些许进展、每一份审稿意见的成功回复、每一篇论文的最终录取都是您学识渊博最好的见证。无论是面对科研中一个个让人抓耳挠腮的问题，还是人生路上暂时的挫折和失意，您总是静心倾听、耐心鼓励、细心指导。您精益求精、诲人不倦的崇高师德，朴实无华、平易近人的人格魅力，循循善诱、宽以待人的高尚风范一直在潜移默化的影响着我，您教给我做人的种种品性和态度将让我受益终身。十分幸运能成为您的学生，感谢您给予的一切鼓励与指导。

同时，非常感谢同组的张光斌老师。张老师思考问题另辟蹊径、眼光独到，总是能一针见血的指出我的各种问题。在和张老师的沟通交流中，我收获颇多。感谢王晷老师、辛云宏老师、郭建中老师、杨秋菊老师、李锦老师、马骁老师、曹辉老师、韩维佳老师、葛宝老师等的指导和帮助，感谢各位老师对我的教育和培养。

感谢课题组的伙伴们陪我一起度过快乐而又充实的三年，感谢宋晔、孙玉姣、史菁尧、邓云云等师姐与我一起分享快乐、共同成长；感谢同级的李舒园、李永杰、代志强在科研中给我的诸多鼓励与帮助；感谢方冲、马明明、王运、范浩祥、孙慧慧、葛倩、张伟铎、贺雅琼、王杰霞等师弟师妹的加入，让我们课题组的氛围更加活泼愉快。同窗之谊，我将终生难忘！

我最想感谢的是我的父母和弟弟，一路以来他们默默的支持我、理解我、关心我、照顾我，赐予了我一往无前的勇气与魄力。他们是最坚强的后盾，有了他们我才得以全身心投入到学业中，而不必因要面对生存的压力而不得不放弃梦想与追求。在我迷茫挫败时，是他们鼓舞我挺过一个又一个难关；在我面对选择时，是他们陪伴我耐心剖析种种；在我伤心难过时，是他们安慰我、给予我无限的包容与爱。无论未来怎样，我都将全力以赴，努力生活，不辜负他们的殷切期望。

最后，向百忙之中参与评阅本文的各位专家老师表示感谢，你们的批评指正将是我人生中的宝贵财富，感谢你们对本论文倾注的精力和心血。祝愿你们：身体健康，万事顺心！

攻读硕士学位期间的研究成果

科研论文:

- [1] 康欢, 张小凤, 张光斌. 基于两参数熵的广义相位排列熵算法. 中国科学:信息科学, 2019, 49(9): 1205-1216.(已发表)
- [2] Kang Huan, Zhang Xiaofeng. The influence of parameter selection for Rényi phase permutation entropy on the abnormal change detection. In proceedings of ICSIDP2019, Chongqing, China, 11-13 December 2019.(已发表)
- [3] Kang Huan, Zhang Xiaofeng, Zhang Guangbin. Coded permutation entropy: a measure for dynamical changes based on the secondary partitioning of amplitude information. Entropy, 2020, 22(2): 187. (已发表)

发明专利:

- [1] 张小凤, 康欢, 宋晔, 张光斌. 一种基于相位排列熵的心电信号异常识别方法. 申请号: 201810088734.8 (进入实质审查阶段)

获奖情况:

- [1] 获“陕西师范大学优秀毕业研究生”称号, 2020年5月
- [2] 获“研究生国家奖学金”, 2019年12月
- [3] 陕西师范大学科研单项奖, 2019年12月
- [4] 陕西师范大学二等积学奖学金, 2018年12月
- [5] 陕西师范大学二等积学奖学金, 2017年12月