

分类号 0236
学校代码 10517

学 号 YXF21070105257
密 级 不保密



硕 士 学 位 论 文

基于熵的时间序列不可逆性及异常 点识别研究

学 位 申 请 人: 王钢进

学 科 专 业: 运筹学与控制论

指导教师及职称: 魏代俊 教授

答 辩 日 期: 2024 年 5 月 20 日

二〇二四年五月

A Dissertation Submitted in Partial Fulfillment of the
Requirements for the Degree of Master

Research on Irreversibility and Outlier Identification of Time Series Based on Entropy

Candidate : Gangjin Wang

Major : Operational Research and Cybernetics

Supervisor: Prof. Daijun Wei

Hubei Minzu University
Enshi 445000, P.R.China

May, 2024

摘要

时间序列是反映复杂系统特征的一类重要数据,利用熵理论工具进行这类数据性质的深入挖掘研究对揭示系统客观规律具有十分深远的意义.熵具有量化和区分系统复杂性的作用,并有助于探索数据内部的隐藏规律,这为认识各种复杂系统提供理论支撑.本文基于熵理论在刻画数据规律特征方面的有效性,对时间序列的不可逆性和异常值识别进行了研究,并提出完全平均散度熵计算的方法和动态邓熵的理论,实现了对时间序列数据性质的有效刻画.本文做的研究工作主要为:

(1) 基于完全平均散度熵理论并结合复杂网络转换,提出了一种研究时序数据的不可逆性质的新方法.传统上用于研究时间序列数据不可逆性质的方法大多根据统计假设,并且单一地依赖于序列的数值大小,其缺点为信息的使用不充分.本文从完全平均散度熵的计算策略出发,设计了一种将时间序列数据转换成简单易行、节点数量少(相较于其它网络转换算法)、网络拓扑性质较多的拓展序数网络方法.新方法克服了以往的 Bandt-Pompe 符号法(用于建构序数网络的数据符号化准则)对数据波动描述不完备的不足,增加了序数网络中数据相等的符号节点,使得用于计算完全平均散度熵的序数网络拥有更为复杂丰富的空间信息特征.本文所提方法在研究数据不可逆性质方面不仅更为全面地考虑了数据局部波动形状,而且充分地利用了网络节点的拓扑结构信息.最后将其应用于黄金价格和股票收盘价序列进行不可逆性质的分析,结果表明:初期的黄金市场价格数据不可逆性程度最高;不同股票指数之间存在较强相关关系.将本文所获的结果与 Bandt-Pompe 符号法、水平可视图方法比较,新方法具有信息更全面、结果更直观简洁且更精确的优点.

(2) 基于多种熵融合的优势,本文构建了一种新的理论熵(动态邓熵),应用于时间序列异常点的识别研究.传统的检测时间序列异常点的熵理论方法大都基于经典的香农熵,通过讨论系统的不同统计特征并利用概率分布计算而得.邓熵则基于证据理论中不确定性的信念度获得的,其考虑的事件更完备,是香农熵的一种拓展形式.邓熵突破了香农熵的信息容量边界,是一种描述信息更为全面且范围更广泛的全局性熵.而排列分布熵能灵敏地识别出时序数据的局部异常波动,并且对于具有周期性质的数据,排列分布熵呈现一个较为稳定的

值. 鉴于以上原因, 将全局性和局部性信息同时考虑, 构建出动态邓熵. 本文通过数值模拟了六种常见的复杂时间序列异常的行为, 用邓熵、动态香农熵及动态邓熵进行了识别率对比, 新方法展现了更高的准确性. 最后将动态邓熵应用于监测地磁活动的扰动风暴时间指数数据, 因发生磁暴活动而产生异常数据的时间位置被准确地识别出来, 这为探索地球周围磁场的活动规律提供了新的见解.

本文基于熵的理论知识对时间序列的数据性质进行了分析, 拓宽了时间序列性质研究工具的渠道, 丰富了熵在时间序列应用研究的理论成果, 展现了熵在时序数据研究的重要作用.

关键词: 时间序列; 熵; 序数网络; 不可逆性; 异常点识别

ABSTRACT

Time series is an important type of data that reflects the characteristics of complex systems. Using entropy theory tools to conduct in-depth mining research on the nature of such data has profound significance in revealing the objective laws of the system. Entropy has the function of quantifying and distinguishing the complexity of systems, and is helpful in exploring hidden patterns within data, which provides theoretical support for understanding various complex systems. Based on the effectiveness of entropy theory in characterizing data regularities, this paper studies the irreversibility and outlier identification of time series, and proposes a method for calculating the complete average divergence entropy and a dynamic Deng entropy theory to effectively characterize the nature of time series data. The main research work done in this paper is as follows:

(1) A new method for studying the irreversibility of temporal data is proposed based on the theory of complete mean divergence entropy and combined with complex network transformation. The traditional methods used to study the irreversibility of time series data are mostly based on statistical assumptions and rely solely on the numerical size of the sequence. The disadvantage is that the utilization of information is insufficient. Starting from the calculation strategy of complete mean divergence entropy, this article designs an extended ordinal network method that converts time series data into a simple and feasible method with fewer nodes (compared to other network conversion algorithms) and more topological properties of the network. The new method overcomes the shortcomings of the previous Bandt-Pompe symbol method (a data symbolization criterion used to construct ordinal networks) in describing data fluctuations incompletely. It adds equal symbol nodes in ordinal networks, making them more complex and rich in spatial information features for calculating complete mean divergence entropy. The method proposed in this article not only comprehensively considers the local fluctuation shape of data in studying the irreversible properties of data, but also fully utilizes the topological structure information of network nodes.

Finally, it is applied to analyze the irreversibility of gold price and stock closing price sequences, and the results showed that the initial gold market price data had the highest degree of irreversibility; There is a strong correlation between different stock indices. Comparing the results obtained in this article with Bandt-Pompe symbol method and horizontal visibility graph method, the new method has the advantages of more comprehensive information, more intuitive and concise results, and more accurate.

(2) Based on the advantages of multiple entropy fusion, this paper constructs a new theoretical entropy (dynamic Deng entropy) for the identification of time series outliers. The traditional entropy theory methods for detecting anomalies in time series are mostly based on the classic Shannon entropy, which is calculated by discussing the different statistical characteristics of the system and using probability distributions. Deng entropy is based on the belief degree of uncertainty in evidence theory, which considers more complete events and is an extended form of Shannon entropy. Deng entropy breaks through the information capacity boundary of Shannon entropy and is a more comprehensive and widely-ranging global entropy that describes information. The permutation distribution entropy can sensitively identify local abnormal fluctuations in time-series data, and for data with periodic properties, the permutation distribution entropy presents a relatively stable value. Given the above reasons, considering both global and local information, a dynamic Deng entropy is constructed. This article numerically simulates the behavior of six common complex time series anomalies, and compares the recognition rates using Deng entropy, dynamic Shannon entropy, and dynamic Deng entropy. The new method demonstrates higher accuracy. Finally, the dynamic Deng entropy is applied to monitor the disturbance storm time index data of geomagnetic activity, accurately identifying the time position of abnormal data caused by geomagnetic storm activity. This provides new insights for exploring the activity patterns of the magnetic field around the Earth.

This article analyzes the data properties of time series based on the theoretical knowledge of entropy, expands the channels for research tools on time series properties, enriches the theoretical achievements of entropy in time series applica-

tion research, and demonstrates the important role of entropy in time series data research.

Key words: Time series; Entropy; Ordinal network; Irreversibility; Anomaly detection

目 录

1	绪论	1
1.1	研究背景及研究意义	1
1.2	国内外研究现状	3
1.2.1	时间序列的不可逆性研究	3
1.2.2	时间序列的异常点识别研究	4
1.3	论文的主要研究方法	6
1.4	论文的组织结构	6
2	预备理论知识	8
2.1	熵的相关概念	8
2.1.1	香农熵	8
2.1.2	排列分布熵	9
2.1.3	邓熵	11
2.1.4	其它散度熵	14
2.2	时间序列的网络转换方法	15
2.2.1	水平可视图转换算法	16
2.2.2	复杂网络的矩阵描述	17
2.3	本章小结	18
3	基于完全平均散度熵的时间序列不可逆性研究	19
3.1	引言	19
3.2	基于不可逆性度量模型的构建	19
3.2.1	拓展序数网络的构建	20
3.2.2	基于不可逆性测度理论的算法提出	24
3.2.3	模拟数据实验	25
3.3	实证数据分析	27
3.3.1	黄金价格序列的不可逆性研究	27
3.3.2	不同股票数据的不可逆性分析	38
3.4	本章小结	40
4	基于动态邓熵的时间序列数据异常点识别研究	42
4.1	引言	42
4.2	理论模型的构建	42
4.2.1	动态邓熵的理论模型	42
4.2.2	算法实现	45
4.2.3	数值模拟	45
4.2.4	结果分析	58

4.3 实证数据应用	59
4.4 本章小结	61
5 总结和展望	62
5.1 论文工作总结	62
5.2 未来展望	63
参考文献	64
攻读学位期间主要研究成果、参加学术会议及获奖	70
致谢	71

1 绪论

1.1 研究背景及研究意义

大数据时代将人类带入一个万物皆可被数据描述的世界,海量数据往往蕴藏着丰富的信息联系^[1,2].因此,有效挖掘数据内潜在的信息为人们了解复杂系统与复杂世界提供了可能.数据类型多种多样,时间序列数据是一类比较重要的数据.所谓时间序列^[3],其实是在间隔某段时间内,按照时间的发生顺序依次观测记录的一组数据.时间序列中各数据之间存在着密切“关系”,这些联系往往表征了系统的某些性质特征,所以对时间序列数据进行深入研究十分有必要^[4,5].

对时间序列的研究最早时间可以追溯到七千年前,古埃及人为了发展农业生产将每天的尼罗河涨落信息记录下来.通过对长时间的涨落信息序列研究分析,他们发现了尼罗河泛滥的规律特征并应用于农业生产生活,最终创造了灿烂的古埃及文明.之后随着时间序列研究的不断发展,用于时序数据研究的方法层出不穷,简单地可以归纳为以下两大类:描述性时序分析^[6]和统计时序分析^[7,8].描述性时序分析在基于观测时间足够长的假设下,利用直观的图像进行观测和比较分析从而发现现象规律.这种方法操作简单、易于实现,被广泛应用于粮食生产^[9]、天文现象研究^[10](如太阳黑子运动),从而推动了社会及生产生活的进步和发展.统计时序分析是一类利用数理统计理论知识对时间序列数据内在规律联系进行挖掘的方法.相较于描述性时序分析方法,统计时序分析更侧重对数据深层隐藏规律的挖掘.较早的统计分析方法有 G.U.Yule 的自回归算法^[11](Autoregressive Algorithm, AR),英国天文学家、数学家 G.T.Walker 的移动平均模型^[12](Moving Average Model, MA),以及 Herman Wold 提出的自回归移动平均^[13](Autoregressive Moving Average, ARMA)和后面发展的 Box-Jenkins 模型^[14](Autoregressive Integrated Moving Average Model, ARIMA).随着统计学家们对时间序列的不断深入研究,单变量、同方差的线性模型存在较多的局限性,转而对多变量、异方差等模型方法进行摸索.相关模型主要有 1982 年 Robert F. Engle 教授因研究英国通货膨胀率问题时而提出的自回归条件异方差^[15],以及获得 Nobel 经济学奖的 Sims 教授采用多方程联立形式而提出的向量自回归模型^[16].上述模型大都基于线性和平稳性为假设条件,而现实数据以

非线性和非平稳性为主，因此更多的方法被提出。例如：熵作为研究非线性复杂系统的工具，在时间序列相关性质的研究应用上具有重要的作用^[17]。

自从学者 R. Clausius 在热力学领域中因研究分子的混乱程度运动状态而定义了熵的概念后^[18]，熵理论得到了迅速的发展。20 世纪时期，香农提出了香农熵^[19]更是促进了信息论等新兴学科的发展。香农熵以其简洁的数学公式度量了信息的具体量，在非平稳非线性时间序列的广泛应用中逐渐凸显其较好的优势，并衍生出了一系列其它类型的熵。比如，Steven Pincus 在对各种类型的数据集进行研究时发展了一种近似熵^[20]并用它分类了复杂性不同的系统；Rényi 定义了一种含参数 α 的熵族—Rényi 熵^[21]，研究了时间序列表征的复杂系统的不同结构信息；Pompe 等人为了对时间序列的波动性进行动力学刻画，基于符号概率提出了排列熵^[22]并取得了满意的结果；在考虑对同种符号模式的数据聚集权重差异性后，Fadlallah 提出了一种加权排列熵^[23]，并在含噪信号序列中表现出更强的稳定性和鲁棒性。值得注意的是，尽管各种熵在每个领域内都取得了不错的结果，然而它们大部分只侧重于讨论序列某一方面的性质，在处理更为开放的环境时可能面临失效的境地^[24]。因此，2016 年邓勇在证据理论的框架下创造了邓熵^[25,26]，在应对更为现实的复杂处境时邓熵更能灵活地描述，并对系统信息的刻画展示了更全面的能力。之后肖富元团队将时间序列异常性方面的工作与邓熵结合在了一起^[27]，其脑电数据实验的分类精度提高了很多。可见，熵的理论知识对时间序列性质挖掘以及解释相关复杂系统的规律特征起着十分重要的作用。同时，复杂网络作为一种研究时序数据性质的有效理论，自 Lacasa 等人提出将时序数据转换成网络的可视图理论后^[28,29]，网络与时间序列的转换方法不断被提出，可视图算法族得到了空前的发展。先后有相空间重构^[30]、递归网络^[31]和符号网络映射^[32,33]提出。然而，单一的研究方法对问题解决往往存在一定局限性，因此相关学者往往组合多种理论对时间序列性质进行研究，这进一步推动了相关理论（诸如熵）对时间序列性质探索的组合研究。

从应用上讲，对时间序列数据性质的研究具有重要的现实意义。例如对国民经济有很大影响的股票时间序列数据，研究其平稳性质和复杂性质能有效识别某些经济活动（如金融危机）对金融市场的影响，从而帮助施政者及时调整政策方针，对维护国民经济的稳定有指导建设作用^[34]；地质灾害的发生往往给人民造成巨大的生命伤害和财产损失，研究其水质中化学物质的溶度及种类的变化序列数据异常性质能及时捕获灾难发生时的预警信息，对维护社会安全具有

预防警示作用^[35]；人体的各种器官的正常运行是保障生命健康的基石，监控心脏器官状况的心跳间隔时间序列不可逆性质的研究可以对心脏的病变程度进行准确的诊断，在临床病理学分析有广泛的实际应用^[36,37]。

在数据理论分析上，金融数据、灾情数据和生理数据等现实生活中的这些数据往往具有规律复杂、结构多样、易于突变等特征，简单统计方法对序列数据性质的挖掘往往不能得到令人满意的结果。特别是对于序列诸如不可逆性与异常性质的研究，往往与数据复杂性的程度相关，合理地对数据的上述两个性质进行挖掘解析，对了解时间序列数据规律的特点及未来演变方向具有重要作用。熵是刻画复杂性的良好理论工具，为了弥补单一熵方法对时间序列性质描述的不足，本文将熵方法与序数网络方法结合对时间序列的性质（如不可逆性）进行刻画，且通过融合多种熵而提出新的熵应用于时间序列异常性行为研究，这对熵应用于时间序列领域的理论研究具有推动意义。

1.2 国内外研究现状

1.2.1 时间序列的不可逆性研究

在各种内部驱动力的作用下，复杂系统^[38,39]形成了自相似性^[40]、不可逆性^[41,42]等各种性质。其中，不可逆性是一个非常重要的特性，它反映了一个非线性系统的可逆平衡被打破后所处的“状态”^[43]。时间不可逆性是一个鼓舞人心的研究点，相关研究者已经成功地将其应用于股票数据、心脑血管信号等复杂数据中，获得了系统的演化规律。如李金阳等人采用不可逆性测度作为指标研究了中美两国相关公司的股票收益效率^[44]。结果表明，美国公司的不可逆性得分较高，这与实际收益状况吻合得较好。脑电图信号 (EEG)^[45] 是反馈人类健康状况的重要医学数据，Martínez 等人通过研究癫痫患者发作期间和发作间的脑电图，揭示了不可逆性是癫痫发作的重要特征^[46]。心电信号是监测心脏是否患病的重要参考对象，心脏器官患病不同严重程度，其心电信号的动态行为存在明显差异。Wang 等学者分析了四种心脏病患者的不可逆性程度，发现不可逆性是心脏系统的固有特征，健康个体表现出更高的不可逆性。不同程度疾病的患者心脏系统的不可逆性程度不同，疾病越严重，不可逆性结果越小^[47]。因此，研究以时间序列为代表的复杂系统的不可逆性，在疾病救济^[48]、金融市场前景分析^[49]等领域具有重要意义。判断非线性系统是否可逆已成为掌握系统相关特征

的关键问题. 在最早的一些关于时间不可逆性的研究中, 主要是基于庞加莱图 (Poincaré graph)^[50], 这是一种直观判断点分布不对称性的方法, 并结合 Porta 指数^[51,52]、Guzik 指数^[53] 和其他合理的指标^[54] 来评价不可逆性. 从概率的角度来看, 时间的不可逆性也可以通过时间序列两个方向的概率分布的“距离差”来衡量, 而这个差异可以通过一系列散度指标来量化. 散度是一类重要的熵理论知识, 是从经典的香农熵推导演化而来^[55], 主要包括 Kullback-Leibler 散度^[56]、Jensen-Shannon 散度^[57] 和完全平均散度^[44]. 统计概率方法取得了令人鼓舞的效果, 并得到了广泛的应用^[58,59]. 令人兴奋的是, Lacasa 等人提出了一种新的观点, 即通过测量复杂网络框架下节点的出度分布和入度分布之间的差异来衡量不可逆性^[60]. 该方法能很好地区分不可逆数据和可逆数据, 具有较好的鲁棒性. 这表明复杂网络可能是一种将时序数据的不可逆性质很好映射到拓扑空间的合适工具, 再结合相对熵等其他熵指标能很好刻画不可逆性^[61].

1.2.2 时间序列的异常点识别研究

在时间序列数据分析中如何识别数据的异常行为是个重要的研究课题, 它在生理疾病^[62]、自然灾害预测^[63,64]、金融市场分析诊断^[65]、器械保养维修^[66]等一系列领域尤为显得重要. 时间序列异常行为的出现导致的后果便是孕育出一系列的异常数据, 因此准确识别所要分析的时间序列中的异常数据成为研究的热点^[67].

时间序列的异常点识别早在 1972 年福克斯就提出了一种简单的自回归预测模型^[68], 福克斯通过运用预测误差这种方式进行了统计检验并准确检测到了异常点. 在机器学习研究理论提出之前, 大多数学者针对时间序列的异常检测研究工作还都集中在统计学的视角上进行. 然而, 自机器学习和深度学习方法逐渐浮现之后, 激发了众多研究者希望在这个新的研究工具上提出一个有效的检测异常点方法的研究兴趣. 在这些种种检测模型中, 主要概括为以下两种思想: 预测误差的预测模型^[69-71] 和重构误差的重构模型^[72-74]. 并且在异常点检测比较流行的方法主要有贝叶斯方法^[75]、支持向量机^[76]、密度比估计^[77]、逻辑回归^[78] 和核检测算法^[79], 这些都是经典的可从数据中训练的监督机器学习算法的监督方法. 另外, Avraam Charakopoulos 等人提出了一种基于可视图算法的在线和离线变化点检测的新指标—后向度^[80]. Avraam Charakopoulos 等人识别的时序数据异常点主要是指那些突变点, 这些突变点将时间序列的一种动力学演变规律转换

或跳转到另一种动力学规律，概括来说就是数据状态演化的转换点。不论是传统的单一统计方法，还是最近流行的机器学习策略，对异常性质的研究方法大都具有识别效果不佳、运算量大、参数处理繁琐等问题，因此在面临大型数据的异常处理往往不如人意。

近年来随着熵的不断发展，应用各种类型的熵方法来研究时间序列的异常性质越来越流行。比如 Jaakkola 等人提出了基于最大熵原理及其拓展的判别估计一般框架，在这个框架内能较为有效地估计类条件模型树结构上的区分分布^[81]。高光谱遥感中的异常检测是一项十分重要的课题，Ran Tao 等人充分利用分数傅里叶熵进行了高光谱异常检测，通过真实高光谱数据集的实证例子表明了方法具有较强的竞争力^[82]。Joshua Garland 运用置换熵技术识别地质气候数据记录中的异常，包括噪声、异常值和后处理问题，并证实了在一些野外工作、实验室分析或数据后处理过程中受影响的异常数据检测中，置换熵表现优秀^[83]。Yuqing Li 等人通过霍夫曼多尺度熵提出了一种基于真实遥测数据的异常检测框架，并将其应用于卫星动量轮电压遥测数据的异常检测，异常数据的识别准确率和检测率极大地提高了^[84]。Valentina 等人基于熵的数据处理和基于机器学习的攻击检测技术，提出了机器学习增强熵，它是一种综合异常检测体系结构，在网络异常检测中表现出良好的性能^[85]。实际上，上面列出的熵识别方法只在其应用范围内有效，即如果放弃设定的条件，该方法往往会失败。例如，如果数据离开基于最大熵原理及其扩展判别估计的一般框架，则无法实现异常检测的可行性。如果信号不满足分数阶傅里叶变换的 Shannon 熵不确定性条件，则分数阶傅里叶熵无法检测异常。机器学习增强的熵依赖于更容易检测到隐藏的流量模式。从根本上说，几乎每一种熵都有其局限性或缺陷。因此，单一熵的应用结果并不令人满意。

香农熵和置换分布熵是应用于时间序列异常检测的两种典型熵^[86]。Teodora Komazec 和 Slavko Gajin 利用香农熵分析了基于流量的异常检测^[87]。利用善于总结全局信息的香农熵，可以很好地揭示数据某些全局方面的属性。排列分布熵对局部波动非常敏感，因此处理局部可变信息非常有效。然而，如前所述，它们有其局限性。2021 年，何佳毅等研究人员将香农熵与排列分布熵结合，生成了一种新的熵，称为动态香农熵 (DySEn)^[88]。由于动态香农熵结合了两种熵，DySEn 继承了香农熵和排列分布熵的优点。动态香农熵的识别能力明显优于香农熵和排列分布熵。在此分析基础上，本文期望进一步优化动态香农熵，以应对更为复

杂的数据的异常检测行为. 邓熵是香农熵的拓展熵, 因此将邓熵与排列分布熵进行合理的融合成为第四章的研究重点.

1.3 论文的主要研究方法

本文利用熵这个主要工具分别对时间序列的不可逆性进行数据特性分析和时序数据的异常行为检测, 主要概括为:

(1) 用完全平均散度熵进行时序数据的不可逆性度量, 通过拓展的 Bandt-Pompe 符号化策略将时间序列转化成序数网络, 利用网络节点出入度分布的距离差对原时间序列的不可逆性进行描述.

(2) 融合多种熵的优点对数据异常值准确识别, 充分利用邓熵对时序数据的全局复杂性描述全面的特点和排列分布熵对局部波动的灵敏性, 将两者进行数学融合形成新的熵并对复杂数据或复杂异常行为进行准确检测.

基于不同方法的效果比较和模拟数据、实证数据的分析研究, 证实了新方法分别对不可逆性数据分析和异常检测的有效性.

1.4 论文的组织结构

为更清晰展示本文的研究内容, 内容结构如图 1.1 所示, 具体描述为:

第一章的绪论内容介绍时间序列的研究渊源、方法研究的演变及对生产生活的重要影响, 并展示了本文的两个问题研究的发展现状和所用方法.

第二章的预备理论知识为论文的相关工作做铺垫, 主要有香农熵、排列分布熵、邓熵, 以及用于量化不可逆性性质的散度熵指标 (如 Kullback-Leibler 散度, Jensen-Shannon 散度, 完全平均散度 D_m), 并补充了复杂网络的数学描述理论.

第三章提出了一种基于散度熵 D_m 与拓展的序数网络对时间序列进行不可逆性分析的新方法. 优化了传统的 BP 符号化方法的建网策略, 重点对相对稳定的金融数据不可逆性展开研究, 并与水平可视图方法、BP 方法进行了比较分析, 得出了一些重要的结论.

第四章融合了一种名为动态邓熵的新算法, 新方法在应用于检测并识别时间序列的局部异常行为非常有效, 以讨论六类复杂异常行为的模拟实验和地球周围磁场的扰动风暴时间指数磁暴异常行为的实证分析, 展示了动态邓熵的较

高识别率.

最后, 第五章阐述并总结了本文的相关创新工作, 并对以熵为研究方法关于时间序列的时间不可逆性分析和异常行为应用研究工作做了展望.




图 1.1: 本文内容结构

Fig 1.1: The content structure of this article

2 预备理论知识

本章将重点展示论文研究工作中涉及到的香农熵、排列分布熵、邓熵和相关散度熵指标等基础概念，另外还介绍了时间序列网络转换方法的内容，方便读者对本文的内容有更好的理解和掌握。

2.1 熵的相关概念

熵研究时间序列的相关性质近年来得到了广泛发展，并将许多不便直观比较的数据性质（如复杂性）进行了量化，为数据分析带来了极大的便利。这部分内容将以香农熵为基础展开介绍相关的熵理论。

2.1.1 香农熵

熵最初为衡量能量的衰退变化程度的量，但随着热力学第一、第二定律的提出，更是促进了平衡态熵的发展。热力学第一定律刻画了系统在某个过程中从一个状态转换到另一个状态后其能量变化的物理量，具体表达式为

$$\Delta U = U_2 - U_1 = Q + W \quad (2.1)$$

其中 Q 为外部世界传递给所讨论系统的热量部分， W 是系统获得的外力或外部影响对它做的功， U_2 、 U_1 分别为系统初始状态和末始状态的能量。热力学第一定律因具有无法描述系统能量流动规律的变化情况的缺陷，从而又发展出了熵增原理。

所谓熵增原理，其实是热力学第二定律，它描述了系统能量流动规律的一种“不可逆”性质。由卡诺定义的“可逆性”概念的广泛传播及深入人心，克劳修斯就可逆的热力系统状态发展了一种熵函数，具体描述为

$$d_s = \left(\frac{dQ}{T}\right)_R \quad (2.2)$$

熵增原理阐述了能量只能由高传至低，不可反过来由低温转至高温，表明了一种不可逆的行为。

热力学定律（第一定律和第二定律）从宏观系统层面利用能量转换关系对熵进行了描述，但还没有从微观层面对熵进行推广。1877 年玻尔兹曼以微观热

力学熵将子系统进行联系, 这种联系用 Gibbs 公式表示为:

$$S = K_B \ln W \quad (2.3)$$

式中 K_B 是 Boltzmann 常数, W 是宏观系统具有的微观状态数目, S 为所定义的熵. 一般地, 如果系统包含了更多的子系统将导致整个系统越复杂混乱, 从而 S 的值也越大.

实际上, 以上所讨论的对象大多是平衡态熵. 自平衡态熵被 Helmholtz 等人应用到化学领域后, 化学家们利用熵增或熵减来得到物质的化学反应方向与反应程度等情况, 更是推动了化学科学的发展. 之后 Prigoging 等人又提出了非平衡态熵, 熵理论再一次得到了更大的突破性发展. 1948 年, 香农第一次将信息论与熵结合在一起, 提出了对信息进行量化度量的香农熵, 香农熵的一般化式子为

$$H = -K \sum p(x_i) \log p(x_i) \quad (2.4)$$

K 是一个系数, x_i 是随机变量 x 的某个状态事件, $p(x_i)$ 为事件的发生概率. 香农熵首次以数学式子的形式对信息进行度量, 用数值量化了事件发生的不确定性容量大小. 特别地, 当计算香农熵时一般取 K 为 1.

2.1.2 排列分布熵

自香农熵被提出之后, 基于香农熵改进的其他熵以及为了研究时间序列不同性质的熵被大量提出, 如 Kolmogorov 熵^[89], 近似熵^[20], 样本熵^[90], 排列熵^[22], 分布熵^[91], 这些熵被广泛运用在时间序列的研究工作中, 并取得了一系列不错的结果. 2019 年, 戴屹梅和商朋见等人提出了一种由排列熵改进而来的排列分布熵 (permuted distribution entropy, PDEn)^[92]. 排列分布熵不同于排列熵只考虑各种排序模式在所有的顺序模式中的占比, 而是进一步研究了每个模式它们之间的差异性, 通过排序模式之间距离值的概率分布情况来捕捉时间序列数据局部的微小变化. 本小节将主要介绍排列分布熵, 其计算步骤主要有重构时序数据的相空间、向量符号化、计算符号向量之间的距离、统计距离出现的概率、计算 PDEn. 具体为:

假设有时间序列 $\{x_i\}_{i=1}^n = \{x_1, x_2, \dots, x_n\}$, 显然其数据观测长度为 n , 接下来计算它的 PDEn. 先将 $\{x_i\}_{i=1}^n$ 所表征的系统空间进行重构, 重构做法遵循 Takens 的嵌入定理^[93]: 把 n 个数据描述的相空间构造为维数为 m , 延迟时间是

τ 的向量空间 $\{X_t\}_{t=1}^{n-(m-1)\tau}$, X_t 的具体结构形式为 $X_t = (x_t, x_{t+\tau}, \dots, x_{t+(m-1)\tau})$. 根据相关研究发现, 向量的维数 m 一般不大于 10, 为应用方便习惯让 $\tau=1$. 所以, X_t 又可写为 $X_t = (x_t, x_{t+1}, \dots, x_{t+(m-1)})$.

完成第一步的空间重构工作后, 对生成的向量再进行序数符号化. 符号化的规律为位置优先性和相等数值统一性, 详细展开为: 以向量 $X_t = (x_t, x_{t+1}, \dots, x_{t+(m-1)})$ 为例, 首先将 $x_t, x_{t+1}, \dots, x_{t+(m-1)}$ 进行从小到大的排序, 分别得到每个分量 $x_k (k = t, t+1, \dots, t+(m-1))$ 的顺序标号索引, 为了方便每个索引值都相应减一, 因此索引的范围为 $0, 1, \dots, m-1$. 为更清晰表明符号向量的产生过程, 本文以维数 m 等于 3 为例展示在表 2.1 中.

表 2.1: 向量符号化准则

Table 2.1: Vector symbolization criteria

$X_t = (x_t, x_{t+1}, x_{t+2})$	$X'_t = (x'_t, x'_{t+1}, x'_{t+2})$
$x_t < x_{t+1} < x_{t+2}$	(0,1,2)
$x_t < x_{t+2} < x_{t+1}$	(0,2,1)
$x_{t+1} < x_t < x_{t+2}$	(1,0,2)
$x_{t+1} < x_{t+2} < x_t$	(2,0,1)
$x_{t+2} < x_t < x_{t+1}$	(2,1,0)
$x_{t+2} < x_{t+1} < x_t$	(1,2,0)
$x_t = x_{t+1} = x_{t+2}$	(0,0,0)
$x_t = x_{t+1} < x_{t+2}$	(0,0,1)
$x_{t+2} < x_t = x_{t+1}$	(1,1,0)
$x_t = x_{t+2} < x_{t+1}$	(0,1,0)
$x_{t+1} < x_t = x_{t+2}$	(1,0,1)
$x_{t+1} = x_{t+2} < x_t$	(1,0,0)
$x_t < x_{t+1} = x_{t+2}$	(0,1,1)

所有向量都化为序数符号模式后, 任意两个符号向量之间的距离利用切比雪夫距离公式 (Chebyshev distance) 计算而得. 也即, 设两个重构向量分别为 $X_i = (x_i, x_{i+1}, \dots, x_{i+(m-1)})$ 与 $X_j = (x_j, x_{j+1}, \dots, x_{j+(m-1)})$, 且它们对应的符号向量分别为 $X'_i = (x'_i, x'_{i+1}, \dots, x'_{i+(m-1)})$ 和 $X'_j = (x'_j, x'_{j+1}, \dots, x'_{j+(m-1)})$, 则它们的距离为 $Dis(i, j) = \max |X'_i - X'_j| = \max(|x'_i - x'_j|, |x'_{i+1} - x'_{j+1}|, \dots, |x'_{i+(m-1)} - x'_{j+(m-1)}|)$. 任意两个符号向量都计算它们的距离, 显然有 $(n - m + 1)^2$ 个距离值. 接着归一化所有的距离值, 分析易知存在 m 种距离并且分别为 $0, 1, 2, \dots, m-1$. 最后统计每种距离 k (k 取 $0, 1, 2, \dots, m-1$) 出现的次数得出相应的距离概率 $p(k)$, $p(k) = \frac{num(k)}{(n-m+1)^2}$, 这里 $num(k)$ 代表距离 k 出现的次数. 然后通过香农熵公式得到排列分布熵 PDEn 的表达式, 即

$$PDEn = - \sum_{k=0}^{m-1} p(k) \log p(k) \quad (2.5)$$

PDEn 对数据的波动特征能很好地描述, 对于具有周期性背景 (如正、余弦规律) 的信号数据表现出非常稳定的值, 因此对局部出现异常行为则表现得很灵敏.

2.1.3 邓熵

世界是不确定性的, 在生活中通过观察而获得了一些确定和规则的现象往往是需要特定条件的. 不确定性表现是多方面的, 比如随机性的信息和知识不仅具有模糊性, 还表现出非恒常性和不完备性. 研究人员对信息的基本性质—不确定性如何进行表示及推理展示了极大的兴趣, 且该性质逐渐成为知识表示和推理研究的一个重要要点. 不确定性该怎么表示是一个热点问题, 相关学者提出了诸如云模型、主观贝叶斯方法、MYCIN 推理模型、模糊集论和 Dempster-Shafer 证据理论等方法, 其中 Dempster-Shafer 证据理论 (记为 D-S 证据理论) 成为不确定的一种推理方法得到了广泛发展. 而邓熵又是基于 D-S 理论的辨识框架下对不确定性进行讨论的, 基于以上考虑, 理解 D-S 理论对更好掌握邓熵的内容有重要意义. 因此在介绍邓熵之前, 有必要对 Dempster-Shafer 证据理论进行简要的概述. 以下是对 D-S 证据理论的发展和相关内容含义做的一些介绍.

(a) D-S 证据理论

20 世纪 60 年代, 美国著名的哈佛大学数学家 Dempster 教授开创性地研究了不具备可加性性质的概率模型, 并且为解决多值映射的难题提出了上概率和

下概率的定义，而后他给出了关于来自两个独立信息源的证据之间进行融合的规则。这些重要的工作奠定了证据理论的内容基础。1976 年 Dempster 的门生 Shafer 出版了一本重要的专著，《证据的数学理论》。Shafer 在书中提出了信任函数的概念，进一步将 Dempster 对证据间的合成规则推广到更一般的情形，最终发展成了一套完备的数学方法。为纪念师生两人作出的创造性成果，由这套数学方法发展而成的理论也被叫作 Dempster-Shafer 证据理论。Dempster-Shafer 证据理论是经典概率论的推广，它利用一整套相对于概率论较弱的条件理论合并证据和更新信任函数，能更好地对不确定信息进行处理和表示。辨识框架、幂集、基本概率分配函数、焦元、Dempster-Shafer 合成规则是证据理论的重要基础内容，以下进行逐一介绍。

辨识框架 Θ 是由一些相互排斥的基本事件组成的集合，是所讨论问题的所有存在的答案， Θ 具体展开写为： $\Theta = \{\theta_1, \theta_2, \dots, \theta_i, \dots, \theta_n\}$ 。幂集定义为 Θ 的所有元素 θ_i 构成的所有可能存在子集的集合，记 $2^\Theta = \{\emptyset, \{\theta_1\}, \{\theta_2\}, \dots, \{\theta_i\}, \dots, \{\theta_n\}, \{\theta_1, \theta_2\}, \dots, \{\theta_1, \theta_n\}, \{\theta_2, \theta_3\}, \dots, \{\theta_1, \dots, \theta_i\}, \dots, \Theta\}$ 。根据集合论的相关知识， 2^Θ 的元素显然有 2 的 n 次方个。基本概率分配函数 BPA(Basic Probability Assignment) 是一个定义在幂集 2^Θ 的映射，也常记作质量函数 $\mathbf{m}: 2^\Theta \mapsto [0, 1]$ 。 $\mathbf{m}$ 满足下列条件

$$\mathbf{m}(\emptyset) = 0 \text{ 且 } \sum_{A \in 2^\Theta} \mathbf{m}(A) = 1 \quad (2.6)$$

若 $\mathbf{m}(A) > 0$ ，则 A 叫做 $\mathbf{m}$ 的焦元。

为了处理不同信息源的证据使之对事件形成一个综合的看法，需要将多个 BPA 函数进行组合以生成一个融合的质量函数。设 $\mathbf{m}_1$ 和 $\mathbf{m}_2$ 是定义在同一个辨识框架 Θ 的两个不同质量函数，Dempster 将两者进行组合从而结合了不同观点对事件刻画。Dempster 组合规则也成为 Dempster-Shafer 合成规则，规则具体为

$$\mathbf{m}(A) = \begin{cases} \frac{\sum_{A_i \cap B_j = A} \mathbf{m}_1(A_i) \mathbf{m}_2(B_j)}{1 - K}, & A \neq \emptyset \\ 0, & A = \emptyset \end{cases} \quad (2.7)$$

这里的 K 为冲突系数，具体计算为

$$K = \sum_{A_i \cap B_j = \emptyset} \mathbf{m}_1(A_i) \mathbf{m}_2(B_j) \quad (2.8)$$

以上只是将两个质量函数的融合进行了详细的说明，更多数量的质量函数的融合规则可仿照进行。

为了说明 D-S 证据理论在处理不确定性方面的优势, 不确定度的摸球游戏作为列举案例. 如图 2.1 所示, 假设有两个完全一样的盒子. 左边盒子里只有黑球, 被选中的概率是 0.3. 另一个在右边的盒子里既有红球也有黑球, 被选中的概率是 0.7. 两个盒子里的球数是完全未知的, 两种球的比例也是未知的. 感兴趣的问题是如何表达这样的不确定信息? 换句话说, 摸中红球或黑球的概率是多少? 由于缺乏足够的信息, 概率论是无法解决这个问题的. 但是如果此时应用 D-S 理论来处理这类问题, 那么可以得到一个 BPA, BPA 的内容为 $m(\text{黑}) = 0.3$, $m(\text{黑, 红}) = 0.7$. 所以用 D-S 理论很好地表示了这种不确定性问题. D-S 理论应用十分广泛, 如决策分析、脑电信号数据的异常故障诊断、网络入侵检测等.




图 2.1: 摸球游戏案例

Fig 2.1: Case of touch ball game

(b) 邓熵

西安交通大学的邓勇教授设想了系统存在对所研究问题的多个解决方案场景, 提出了邓熵. 邓熵对辨识框架的幂集中元素 A 的非特异性有独特的理解, 即把焦点中可能存在的状态数全部进行考虑. 邓熵的数学式为:

$$E_d = - \sum_{A \subseteq \Theta} m(A) \log_2 \frac{m(A)}{2^{|A|}-1} \quad (2.9)$$

通过运算邓熵还可写为

$$E_d = \sum_{A \subseteq \Theta} m(A) \log_2 (2^{|A|} - 1) - \sum_{A \subseteq \Theta} m(A) \log_2 m(A) \quad (2.10)$$

与香农熵相比, 邓熵考虑了每个焦点元素的所有可能的潜在状态数, 它对不确定性的描述更为详细, 并以每个焦点元素最可能不确定性的存在尺度来描述信息的不确定性, 表现出邓熵更为全面的特征. 和信息熵一样, 邓熵也善于描述数据的整体信息, 然而它包含更多的全局不确定性和复杂信息.

2.1.4 其它散度熵

散度熵函数是香农熵发展的另一个重要应用理论，常利用它判断两个概率分布之间信息差异的距离度量。散度熵在优化算法研究分支中得到了广泛应用，其计算值描述了实际概率分布与拟合分布的差异程度。这一小节介绍几种常见的散度熵函数，为第三章的研究工作做内容铺垫。

（一）Kullback-Leibler 散度熵

Kullback-Leibler 散度熵是由著名学者 Solomon Kullback 与 Richard Leibler 共同提出的，又称信息散度或相对熵，简记为 D_{KL} 。它衡量了两个分布之间的相似性大小， D_{KL} 越大意味着分布之间存在着较小的相似程度；相反， D_{KL} 越接近零则表示分布趋近于相同。 D_{KL} 有连续型和离散型的表达式，具体为：设随机变量 X 为连续的，已知 X 的两个分布函数为 P 、 Q 且对应的概率密度函数分别是 $p(x)$ 与 $q(x)$ ，则 $p(x)$ 相对于 $q(x)$ 的不确定性定义为

$$D_{KL}(P||Q) = \int p(x) \log \frac{p(x)}{q(x)} dx \quad (2.11)$$

特别地，当 X 是离散变量时便有两个概率分布 $P = \{p_1, p_2, \dots, p_n\}$ 、 $Q = \{q_1, q_2, \dots, q_n\}$ ，此时定义的 $D_{KL}(P||Q)$ 为

$$D_{KL}(P||Q) = \sum_i p(i) \log \frac{p(i)}{q(i)} \quad (2.12)$$

(2.11) 和 (2.12) 没有本质的差别，都计算了 X 的两个分布之间的相对熵距离。值得注意的是 Kullback-Leibler 散度熵具有以下性质：非对称性和非负性。非对称性指 $D_{KL}(P||Q)$ 一般与 $D_{KL}(Q||P)$ 没有相等的关系。并且对于任意的两个概率分布（或概率密度函数） P 和 Q ，容易证明关系式 $D_{KL}(P||Q) \geq 0$ 总是满足的，当且仅当 P 和 Q 完全一样等号成立，这便是相对熵的非负性。

（二）基于 Kullback-Leibler 散度熵发展的其他散度指标

（a）Jensen-Shannon 散度 (D_{JS})

D_{KL} 因其非对称性往往无法很好地处理差异性较大的两个分布，特别是当处理两个完全没有重叠面积的分布时，计算的 D_{KL} 是无穷大或说是无意义的。另外，在神经网络应用 D_{KL} 训练参数时由于 D_{KL} 不具有对称性，最终由于顺序不同得到的训练结果也不同，这为研究者带来极大的困扰。为此，一些学者改

进了一种对称版本的 D_{KL} , 叫作 Jensen-Shannon 散度, 记为 D_{JS} . 具体式为

$$\begin{aligned}
 D_{JS} &= \frac{1}{2}(D_{KL}(P||U) + D_{KL}(Q||U)) \\
 &= \frac{1}{2}(D_{KL}(P||\frac{P+Q}{2}) + D_{KL}(Q||\frac{P+Q}{2})) \\
 &= \frac{1}{2}(\sum_i p(i) \log \frac{p(i)}{\frac{p(i)+q(i)}{2}} + \sum_j q(j) \log \frac{q(j)}{\frac{p(j)+q(j)}{2}}) \\
 &= \frac{1}{2}(\sum_i p(i) \log \frac{p(i)}{p(i)+q(i)} + \sum_j q(j) \log \frac{q(j)}{p(j)+q(j)}) + \log 2
 \end{aligned} \tag{2.13}$$

这里 P 、 Q 与式子 (2.12) 中的含义是相同的, 也为离散随机变量的两个分布, U 是 P 与 Q 的一个平均分布. 式子 (2.13) 表明了当对数运算的底数取 2 时, D_{JS} 的范围为 $[0,1]$. $D_{JS}=0$ 表明 P 和 Q 完全相同, 而 P 、 Q 完全不同时 (即 P 与 Q 没有重叠部分) $D_{JS}=1$. D_{JS} 的最大优势在于解决了 D_{KL} 的非称性问题.

(b) 完全平均散度 (D_m)

D_{JS} 很好地完善了 D_{KL} 的对称性质. 然而, 通过分析 D_{JS} 的生成过程, 商朋见等人发现了 D_{JS} 也可能会存在一些缺陷. U 是 P 和 Q 的平均分布, 即 $U = \frac{P+Q}{2}$. 然而, 倘若盲目地将 P 、 Q 简单地求平均, 一些潜在的性质则可能被中和, 在利用 D_{JS} 讨论相关统计特征 (如时间序列的不可逆性) 后会产生较多的不确定性, 对其获得结果的准确性造成一定的影响. 因此, 一种新的散度熵——完全平均散度被提出来. 完全平均散度熵的符号为 D_m , 解析式为

$$\begin{aligned}
 D_m &= \frac{1}{2}(D_{KL}(P||Q) + D_{KL}(Q||P)) \\
 &= \frac{1}{2}(\sum_i p(i) \log \frac{p(i)}{q(i)} + \sum_j q(j) \log \frac{q(j)}{p(j)})
 \end{aligned} \tag{2.14}$$

这里仍然考虑的是离散情形, 连续随机变量的形式是类似的. (2.14) 与 (2.13) 相比较, D_m 的值完全由 P 、 Q 决定而与第三方分布 U 无关, 这减少了 D_{JS} 需要构造新分布 U 的很多不确定性, 保证了研究问题的确定性和准确性. 相关研究文献^[44] 证明 D_m 具有较多的优点, 如直观性、简洁性、对称性与准确性, 这为本文第三章对时序数据的不可逆性分析提供了合适的研究工具.

2.2 时间序列的网络转换方法

传统的数据性质分析大都基于数值本身大小进行讨论的, 而忽视了数据的空间规律性. Zhang 与 Small 等人创造性地将时间序列数据在复杂网络理论下进行了研究分析, 得出了具有不同规律性质的时间序列对应的网络拓扑性质是不同的重要结论. 之后 Lacasa 和 Luque 等人相继提出了可视图、水平可视图的时

间序列网络转换化方法，并逐渐发展成为一种族算法—可视图族. 本小节主要介绍水平可视图转换算法，并简单概述了复杂网络的矩阵描述方法.

2.2.1 水平可视图转换算法

水平可视图 (horizontal visibility graph, 简记作 HVG) 是一种将时间序列映射到无向无权网络的便捷方法，它取决于局部数据的大小和观测的顺序. 为了说明 HVG，提供了如下详细的介绍.

考虑序列 $\{y_t\}_{t=1}^N$, 将其转化为 HVG 网络的核心步骤概括如下:

1. 将时间序列 $\{y_t\}_{t=1}^N$ 中的每个数据点 y_t 视为网络中的一个节点 n_t . 因此，若映射网络中的节点集为 $\{n_t\}_{t=1}^N$, 则节点数等于序列 $\{y_t\}_{t=1}^N$ 的长度;
2. 要在节点 n_i 和节点 n_j 之间建立联系 (边), 需要满足以下条件: 介于节点 n_i 和节点 n_j 之间的任意节点 n_k , 若始终存在 $y_k < y_i$ 且 $y_k < y_j$, 则节点 n_i 和节点 n_j 之间建立一条网络连边;
3. 按照步骤 2 判断 $\{n_t\}_{t=1}^N$ 中的其他两个节点是否有边. 任意节点 n_g 与相邻节点 n_{g-1} 和 n_{g+1} 都有连边;
4. 所得网络的相关矩阵为 0-1 矩阵，并利用相关软件对所得网络进行可视化.




图 2.2: HVG 转换算法. 上面是序列变换的原理, 下面是得到的网络

Fig 2.2: HVG conversion algorithm. The upper part is the principle of sequence transformation, and the lower part is the resulting network

为了更直观地说明 HVG 算法, 具体示例如图 2.2 所示. 假设 $\{y_i\}_{i=1}^{10} = \{2, 10, 4, 2, 5, 4, 8, 2, 6, 7\}$ 是一个时间序列. 具体来说, 指定一个随时间变化的方向. 显然, 根据上述算法, 图 2.2 中柱状图中任意两个节点之间的连接关系用虚线表示. 以节点 ② 和节点 ⑦ 是否通过一条边连接为例. 节点 ② 对应的序列数据为 $y_2 = 10$, 节点 ⑦ 对应的序列数据为 $y_7 = 8$. 对于节点 ② 和节点 ⑦ 之间的任意节点 $k(k=3,4,5,6)$, 很容易知道 $y_k < y_2$ 且 $y_k < y_7$. 因此, 在节点 ② 和节点 ⑦ 之间存在一条边. 任何其他两个节点也遵循此规则. 序列 $\{y_i\}_{i=1}^{10}$ 通过 HVG 算法映射的对应网络如图 2.2 柱状图下方的图案所示.

2.2.2 复杂网络的矩阵描述

将所要研究的时序数据转成复杂网络后, 如何用合适的数学工具表示网络成为网络研究中的关切问题. 矩阵是一个有力的工具, 能合理地将网络中的复杂关系用元素表达. 常见的网络有无向无权网络、无向加权网络、有向无权网络、有向加权网络, 图 2.3 是这些类型网络的示例, 相应地根据每类网络中节点间关系可以给出合适的矩阵表示.




图 2.3: 四种类型的网络图

Fig 2.3: Four types of network diagrams

图 2.3 四种网络对应的矩阵表示为如下：

$$\begin{pmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \end{pmatrix}, \begin{pmatrix} 0 & 0 & 0.75 & 0 \\ 0 & 0 & 1.5 & 0.75 \\ 0.75 & 1.5 & 0 & 1 \\ 0 & 0.75 & 1 & 0 \end{pmatrix}, \begin{pmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \end{pmatrix}, \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0.75 & 0 & 1 & 0 \\ 0 & 2 & 0 & 0 \\ 2.5 & 0 & 0.83 & 0 \end{pmatrix}.$$

容易知道，矩阵简洁地描述了网络的拓扑关系. 网络的矩阵表示有效地为时间序列数据性质分析提供了代数运算的可能，为挖掘数据规律提供了更方便的分析工具.

2.3 本章小结

本章首先以香农熵为线索，首先论述了由物理熵发展到化学熵，再到香农的信息熵过程，并以香农熵出发介绍了一系列其它类型的熵（排列分布熵、邓熵、 D_{KL} 、 D_{JS} 、 D_m ）. 接着分别讨论了它们可能存在的应用方向及时间序列的网络转换方法的介绍，为论文第三章、第四章的研究工作（时间序列的不可逆性和异常点研究）打下理论基石.

3 基于完全平均散度熵的时间序列不可逆性研究

3.1 引言

时序数据的不可逆性性质研究是一个开放的问题,它对解释系统内部规律演化方向有重要作用.所谓时间序列是可逆的,说明复杂系统在时间反转假设条件下其规律性质(如统计性)是保持不变的;反之,如果不可逆,则在系统的反转作用下其相关性质可能千差万别.并且,一般地系统复杂性越高其时间不可逆程度也越大.而散度熵是描述和分析复杂性规律的较好方法,因而将熵策略应用于时间序列的不可逆性分析成为热门研究.完全平均散度熵(complete mean divergence, D_m)是最近提出的一种散度熵,用于量化不可逆性程度大小,研究发现其判断不可逆性的准确性更好,在数值上给人以更直观的感受.然而,用于完全平均散度熵计算的概率分布如何获取是个难题.最近,使用复杂网络方法研究时间序列是一个前沿方向.基于以上分析,本章应用复杂网络中节点的出入度分布得到了用于 D_m 计算的概率分布,从而实现了对时序数据所表征系统的不可逆性的准确刻画.具体研究内容的步骤为:首先推广了 Bandt-Pompe 的符号化方法,提出了一种新的映射序列数据为序数网络的方法;然后将网络拓扑信息中节点的出入度分布视作时间序列数据的正反两个方向的数据分布,从而将空间拓扑信息与数据分布统计信息对应起来;最后利用熵测度—完全平均散度对不可逆性进行统计量化.与传统方法相比,本文所提新策略在网络转化步骤中考虑了更完备的数据波形信息,且完全平均散度熵的应用使得结果更为直观,与模拟数据和实证数据的特点吻合效果较好.本章节的研究还表明复杂和高波动性的数据系统具有高度的不可逆性,揭示了非线性系统的不可逆性与波动性之间的密切关系.

3.2 基于不可逆性度量模型的构建

本节将主要介绍一种基于扩展序数网络表征时间序列不可逆性的新算法,内容包含时间序列的序数化及序数符号网络的构建过程、不可逆性的新测度建立和两种经典的模拟数据(分形布朗运动系统和逻辑混沌映射系统)对新度量模型准确性的验证实验.

3.2.1 拓展序数网络的构建

序数网络是研究时间序列数据规律的一种新颖方法,它充分利用了波动信息、演化趋势和复杂的网络结构,具有较强的识别不同特征数据系统的能力.将时间序列转化为序数网络的步骤一般包括相空间的重建、向量符号化、节点的归一化和节点连接的构建.其中,被广泛接受的数据段符号化方法是 Bandt-Pompe 原理,且数据大小和位置优先级是 Bandt-Pompe 符号化的核心.一般序数网络映射方法的操作如下.

对于给定一个时间序列 $\{x(t)\}_{t=1}^N$, 根据 Bandt-Pompe 原理构造一般序数网络的具体步骤如下:

1. 空间重构: 应用相空间重构技术, 将一维数据空间 $\{x(t)\}_{t=1}^N$ 变换为 m 维向量空间 $\{X(i)\}_{i=1}^{N-(m-1)\tau}$, 其中 m 为嵌入维数, τ 为延迟时间, $X(i) = (x_i, x_{i+\tau}, \dots, x_{i+(m-1)\tau})$. 根据 Takens 的嵌入定理^[93], 当选择合适的维数 m 和时滞 τ 时, $\{x(t)\}_{t=1}^N$ 所表征的系统等价于重构的向量系统 $\{X(i)\}_{i=1}^{N-(m-1)\tau}$. 相关研究表明^[94,95], m 在 3 至 7 之间, τ 一般为 1. 因此, $\{X(i)\}_{i=1}^{N-(m-1)\tau}$ 中的每个向量也表示为 $X(i) = (x_i, x_{i+1}, \dots, x_{i+(m-1)}) (\tau = 1)$, 向量总数为 $N-m+1$.

2. 向量符号化: 通过第一步得到相应的 $N-m+1$ 个向量后, 对每个向量 $X(i)$ 中的 m 个分量从小到大进行局部排序, 分别得到相应的位置序列号 $x'_i, x'_{i+1}, \dots, x'_{i+m-1}$. 很明显, 每个向量 $X(i)$ 只有一个唯一的符号序列 Π^i 与之对应. 值得注意的是, 如果分量 $x_{(k)}$ 和 $x_{(j)}$ 相等, 则按照原始时间序列数据采集的顺序给出符号标记. 为了更好地理解符号映射的原理, 表 3.1 给出了基于 Bandt-Pompe 原理的三维向量的符号结果 (为了方便, 每个分量对应的位置标号都减一).

3. 节点归一化: 通过符号化得到所有向量的状态模式后, 将每个模式作为对应复杂序数网络中的一个节点. 即使一个模式出现了不止一次, 它仍然只对应于结果网络中的一个唯一节点. 换句话说, 所得到的序数网络中的节点数量完全取决于符号模式的类型.

4. 边的建立和序数网络的生成. 节点间的连接是根据时间跃迁的方向来构建的, 模式间的跃迁越多, 对应节点间的耦合强度越强. 最后, 利用相应的软件, 根据节点数量和节点之间的连接关系, 对序数网络进行可视化.

通过上述步骤获得的结果网络是反映原始数据波动信息的加权有向网络,

具有丰富的网络拓扑性质，对研究未来波动趋势具有重要意义。

表 3.1: Bandt-Pompe 原理 (以 $m=3, \tau=1$ 为例)

Table 3.1: Bandt-Pompe principle (Take $m=3, \tau=1$ as an example)

$X(t) = (x_t, x_{t+1}, x_{t+2})$ 的分量	
满足的大小关系	对应的序数模式 Π^t
$x_t \leq x_{t+1} \leq x_{t+2}$	(012)
$x_t \leq x_{t+2} \leq x_{t+1}$	(021)
$x_{t+1} \leq x_t \leq x_{t+2}$	(102)
$x_{t+1} \leq x_{t+2} \leq x_t$	(120)
$x_{t+2} \leq x_t \leq x_{t+1}$	(201)
$x_{t+2} \leq x_{t+1} \leq x_t$	(210)

事实上, Bandt-Pompe 方法有一定的局限性, 即忽略了相等的情况. 不妨考虑以下情况: 向量 $X(i) = (x_i, x_{i+1}, x_{i+2})$ 和 $X(j) = (x_j, x_{j+1}, x_{j+2})$ 满足 $x_i = x_{i+1} = x_{i+2}, x_j < x_{j+1} < x_{j+2}$. 用 Bandt-Pompe 方法进行符号化后, $X(i)$ 和 $X(j)$ 统一表示为符号模式“(012)”. 但是, $X(i)$ 和 $X(j)$ 的波形完全不同, 用相同的符号模式来表示这两类数据变化之间的关系显然是不合适的. 也就是说, 如果所研究的时间数据是相对稳定的, 那么用传统的 Bandt-Pompe 方法对所研究的数据进行符号化得到的序数网络中就包含了缺失的和不完全的振动信息. 因此, 本节提出使用严格的不等式关系 (考虑相等性) 对数据段进行符号处理. 满足 $x_i = x_{i+1} = x_{i+2}$ 的 $X(i)$ 用序数模式“(000)”表示, 而 $X(j)$ 用“(012)”表示. 显然, 通过这种处理, 完全区分了不同波形的数据段, 使之对数据的演变趋势信息有了更全面的了解. 优化后的 Bandt-Pompe 方法如表 3.2 所示. 利用表 3.2 提出的改进方法, 最终得到一个扩展序数网络. 与传统的符号化方法相比, 新的符号化方法主要有以下优点: 1. 序数网络中的节点类型更加多样化, 数量远远大于 $m!$. 2. 生成的网络包含了更多关于数据变化的信息, 这将对原始时间序列的性质有一个更彻底和完整的理解.

基于表 3.2 得到的序数网络节点数目是一个重要的问题, 因而在此做适当

表 3.2: 优化的 Bandt-Pompe 方法 (以 $m=3, \tau=1$ 为例)

Table 3.2: Optimized Bandt-Pompe method (Take $m=3, \tau=1$ as an example)

$X(t) = (x_t, x_{t+1}, x_{t+2})$ 的分量	
满足的新关系	对应的序数模式 Π^t
$x_t < x_{t+1} < x_{t+2}$	(012)
$x_t < x_{t+2} < x_{t+1}$	(021)
$x_{t+1} < x_t < x_{t+2}$	(102)
$x_{t+1} < x_{t+2} < x_t$	(201)
$x_{t+2} < x_t < x_{t+1}$	(120)
$x_{t+2} < x_{t+1} < x_t$	(210)
$x_t = x_{t+1} = x_{t+2}$	(000)
$x_t = x_{t+1} < x_{t+2}$	(001)
$x_{t+2} < x_t = x_{t+1}$	(110)
$x_t = x_{t+2} < x_{t+1}$	(010)
$x_{t+1} < x_t = x_{t+2}$	(101)
$x_{t+1} = x_{t+2} < x_t$	(100)
$x_t < x_{t+1} = x_{t+2}$	(011)

探索. 以维数 m 为对象, 通过符号处理所能得到的图案的最大可能数, 对此将进行如下简单的理论分析. 设 $S(m)$ 为可能模式的最大数目, 显然 $S(m)$ 是 m 的一个函数. 当 $x_i, x_{i+1}, x_{i+2}, \dots, x_{i+m-1}$ 满足所有可能的不等式关系时, 可以确定 $S(m)$ 是最大的. 所有的关系可以被分为 m 类: 1. 零分量相等, 意味着 m 个值遵循严格的大小关系; 2. 两个分量相等, 即 m 个数中只有两个相等, 而其他数严格不相等; ... ; m . 向量 $X(i) = (x_i, x_{i+1}, \dots, x_{i+m-1})$ 的 m 个分量是完全相等的. 因此, 可用下式表示:

$$S(m) = m! + (A_m^2 A_{m-2}^{m-2} + C_m^2 A_{m-2}^{m-2}) + (C_m^3 A_{m-3}^{m-3} A_2^2 + C_m^3 A_{m-3}^{m-3}) + \dots + 1. \quad (3.1)$$

由 $S(m)$ 的表达式可以很容易地知道, 随着 m 的增大, 符号模式的数量会迅速增加. 为了帮助读者更好地理解本文提出的网络构建方法与传统 Bandt-Pompe 方法的区别, 给出了一个更详细的网络构建过程.

$\{x(t)\}_{t=1}^{10} = \{1, 1, 3, 3, 1, 3, 3, 0, 2, 2\}$ 是一个随机数组. 首先, 以 $m=3$ 和 $\tau=1$ 重构 $\{x(t)\}_{t=1}^{10}$ 的向量空间, 得到包含 $10-(3-1)=8$ 个向量的新空间. 向量是 $X_1 = \{1, 1, 3\}, X_2 = \{1, 3, 3\}, \dots, X_7 = \{3, 0, 2\}$ 和 $X_8 = \{0, 2, 2\}$. 考虑使用 Bandt-Pompe 方法将 8 个向量转换为符号模式. 在向量 $X_1 = \{1, 1, 3\}$ 中, 由于满足关系 “ $1 \leq 1 \leq 3$ ”, 对应的符号模式为 “(012)”. X_2 的符号模式与 X_1 相同, 同样满足 “ $1 \leq 3 \leq 3$ ”. “(102)” 是 X_4 的模式, 因为有不相等的关系式 “ $1 \leq 3 \leq 3$ ”. X_7 的三个分量满足 “ $0 \leq 2 \leq 3$ ”, 因此符号模式为 “(120)”. 其他向量按照表 3.1 中的关系进行变换, 依次得到其对应的符号模式. 基于 Bandt-Pompe 方法, 将随机数组 $\{x(t)\}_{t=1}^{10}$ 转换为 “012”、“102”、“120”、“201” 四种模式, 四种模式之间的连接关系为: “012” $\rightarrow$ “012” $\rightarrow$ “201” $\rightarrow$ “102” $\rightarrow$ “012” $\rightarrow$ “201” $\rightarrow$ “120” $\rightarrow$ “012”. 由此得到相应的序数网络图如图 3.1(a) 所示. 下面将应用扩展的 Bandt-Pompe 符号化方法来构造序数网络. 和上面的方法一样, 仍然首先应用同样的方法得到由 $X_1, X_2, \dots, X_8$ 构成的向量空间. 根据表 3.2, 使用扩展的符号化方法对所有向量进行模式化. 向量 X_1 和向量 X_2 的符号图案不再相同, 分别是 “001” 和 “011”. 这是合理的, 因为 X_1 呈现的数据趋势是先不变后增加, 而 X_2 呈现的趋势是先增加后保持不变. 将数据段与更多类型的模式进行匹配, 以更好地展示数据段波动的特征, 为挖掘数据中更多潜在信息提供了更多可能性. X_4 和 X_7 的模式分别为 “101” 和 “201”. 同样, 每个序数模式也被视为网络中的一个节点, 从而得到 5 类模式, 对应于扩展序数网络的 5 个不同节点. 五

类模式的转换关系为:“001” → “011” → “110” → “101” → “011” → “110” → “201” → “011”. 5 个节点之间的连接关系反映在一个有向加权网络中, 得到的扩展序数网络图如图 3.1(b) 所示.




图 3.1: (a) 是基于 Bandt-Pompe 原理构造的网络, (b) 是新方法构造的网络图

Fig 3.1: (a) is a network constructed based on the Bandt-Pompe principle and (b) is the network diagram constructed by the new method

从直观上看, 同一数据通过不同的映射方法得到的两个网络的节点数量及其连接关系存在显著差异. 从状态“012”到状态“201”的过渡在图 3.1(a) 中更为频繁, 而模式“011”与模式“110”的连接次数在图 3.1(b) 中更多. 此外, 新方法获得的网络中节点之间的交互关系更加复杂, 使得网络结构拓扑更加丰富, 包含更多的空间信息. 由于随机数组变化的随机性, 数据的波动行为也更加多样, 导致网络更加复杂. 新方法构建的网络完全符合这一特点. 由于该方法考虑了更多的节点信息, 可以探索非线性系统的不可逆性等特性, 从而提供更可靠的结果.

3.2.2 基于不可逆性测度理论的算法提出

将一组时间序列转换成序数网络后, 得到该网络的邻接矩阵. 设序数网络的邻接矩阵为 $A = (a_{ij})$, 其中 $a_{ij} > 0$ 表示序数模态 Π^i 已经转换了 a_{ij} 次到序数模态 Π^j , $a_{ij}=0$ 且 $a_{ji}=0$ 表示模式 Π^i 和模式 Π^j 之间没有转换. 值得注意的是, 矩阵 A 一般是不对称的, 因为序数网络是一个加权有向网络. 每个节点 i 的输出转移概率 p_{i-out} 和输入转移概率 p_{i-in} 表示时间序列两个方向 (正反向) 的状态转移信息, 且 p_{i-out} 和 p_{i-in} 定义为

$$P_{i-out} = \frac{\sum_{j=1}^{N_0} \text{sgn}(a_{ij})}{N_0} \quad (3.2)$$

$$P_{i-in} = \frac{\sum_{j=1}^{N_0} \text{sgn}(a_{ji})}{N_0} \quad (3.3)$$

N_0 表示序数网络的节点总数, 即符号模式的种类数. $\text{sgn}(x)$ 是一个符号函数, 只有当 $x > 0$ 时有 $\text{sgn}(x) = 1$. 结合公式 (2.14) 及 (3.2), (3.3), 时间序列的不可逆性度量可表示为

$$\begin{aligned} D_m &= \frac{1}{2}(D_{KL}(P_{out}||P_{in}) + D_{KL}(P_{in}||P_{out})) \\ &= \frac{1}{2}\left(\sum_{i=1}^{N_0} p_{i-out} \log \frac{p_{i-out}}{p_{i-in}} + \sum_{j=1}^{N_0} p_{j-in} \log \frac{p_{j-in}}{p_{j-out}}\right) \end{aligned} \quad (3.4)$$

3.2.3 模拟数据实验

为了验证该方法在测量不可逆性方面的性能, 将其应用于模拟数据 (分形布朗运动序列和混沌序列). 分形布朗运动是一种随机过程, 其运动波动率与 Hurst 指数 H 密切相关. 分形布朗运动时间序列作为时间可逆性的运动数据, 经常被用作检验统计可逆性测度的可靠实验对象. 其中, Logical Map 是具有时间显著不可逆性的典型混沌数据生成系统, 生成表达式为 $x_{n+1} = ax_n(1-x_n)$ (这里 $x_0 = 0.2983$, 参数 $a=4$). 采用不同维数 m 和不同序列长度 L 考察上述两类数据所表征的系统的不可逆性趋势, 模拟时间序列数据的动态形态变化如图 3.2 所示, 图 3.3 为计算散度值的变化情况.




图 3.2: (a) 为分数阶布朗运动时间序列 (参数 $H=0.6$), (b) 为 Logistic Map 混沌信号 (其中 $x_0 = 0.2983$, $a=4$)

Fig 3.2: (a) is the Fractional Brownian Motion time series (parameter $H=0.6$) and (b) is Logistic Map chaotic

signal (where $x_0 = 0.2983$, $a=4$)




图 3.3: (a) 为分形布朗运动数据计算得到的 D_m 值, (b) 为混沌时间序列的结果

Fig 3.3: (a) shows the D_m value calculated from Fractional Brownian Motion data, and the results of chaotic time series are shown in (b)

正如预期的那样,随着观测数据长度的增加,具有时间可逆性的分形布朗运动序列计算的 D_m 逐渐趋近于 0. 当 $m=4, 5, 6$ 时, D_m 变化趋势先增大后减小. 这是合理的. 当获得的数据量相对较少时,系统所覆盖的信息是片面的或不充分的. 因此,随着数据量的增加,系统的信息越来越全面,最终计算出的 D_m 会收敛到一个稳定的值. 值得注意的是,当维度 $m=7$ 时, D_m 的趋势持续增加. 虽然这里考虑的数据长度达到 50000,但 D_m 仍然是 0.1929. 这可能是由于随着 m 的增加,有序模式的类型数量显著增加,导致更严重的信息冗余和 D_m 到 0 的收敛速度慢得多. 为了验证新方法在 $m=7$ 时的性能预测,实验又显著增加了所讨论的时间数据的长度,结果如图 3.4 所示. 从图 3.4 可以看到, D_m 先快速增大后持续减小,类似于小维度 ($m=4, 5, 6$) 的表现. 值得注意的是,虽然 D_m 的最终值也可能收敛于零,但在 $m=7$ 处的计算成本更高 (需要更多的采样数据). 这在大尺度上也是一个明显的缺陷. 当 $m=3$ 时, D_m 保持 0. 这表明,虽然较小的维数可以使不可逆性度量快速收敛到 0,但由于模式数量少,只能提取少量的观测数据. 图 3.3(b) 的结果也证实了上面对图 3.3(a) 的分析. 混沌时间序列是典型的不可逆序列,随着数据量的增加,计算出的 D_m 将不可避免地收敛到一个不为零的值. 从图 3.3(b) 可以看出,即使信息量很小 (在非常小的序列长度下),新方法在 $m=3$ 处计算出的 D_m 始终为 0.2485. D_m 随数据长度的变化而保持不变,这显然与正常的理解相反. 所以,在小的维度上可能会有一些偏差. 当 $m=4, 5, 6$ 时,新方法仍然显示出更合理的结果,并且在较小的数据集上都达到稳定值. 与分形布朗运动时间序列数据相比,混沌数据计算出的 D_m 明显更大,这也证明了新方法对判断其是否可逆的

识别能力较为强大.




图 3.4: 在长时间序列数据 (FBM 序列) 中, 当 $m=7$ 时, 采用新方法计算 D_m 的性能

Fig 3.4: The performance of D_m calculated by proposed new method when $m=7$ in long time series data (FBM sequence)

3.3 实证数据分析

为了进一步论证新方法的有效性, 这部分的内容首先分析了伦敦金银市场协会每日上午公布的黄金价格数据的波动性与金价系统的不可逆性之间的关系, 运用统计显著性分析和替代检验分析证明了新算法的性能可靠性. 并与传统水平可视图方法的结果进行了比较分析, 显示了所提方法的更为直观全面等优势. 最后将方法应用在股市收盘价格分析, 得到了鼓舞人心的结果.

3.3.1 黄金价格序列的不可逆性研究

研究的金价数据是 1968 年至 2021 年 LBMA(伦敦金银市场协会) 每日上午黄金定盘价, 相关黄金价格数据可在 <https://www.lbma.org.uk/prices-and-data/precious-metal-prices#/table> 中获取. 从 1968 年到 2021 年, 总共有 54 年的黄金价格发展. 根据世界经济的发展特点, 本实验将伦敦黄金市场 54 年的发展历程分为 1968-1985 年、1986-2003 年和 2004-2021 年三个时期. 本节以这三个时期的每日黄金定盘价为分析对象, 得出黄金价格发展的相关特征. 图 3.5(a)、图

3.5(b)、图 3.5(c) 分别显示了三个时期的每日黄金定盘价发展趋势, 图 3.6 显示了 1968 年至 2021 年整个时期的金价数据. 第一时期 (1968-1985 年) 数据的特点是, 首先是相对稳定的变化, 然后是明显的增长变化和快速的价格下降, 最后是数据相对显著的波动趋势. 第二个时期 (1986-2003 年), 数据变化相对平稳, 波动幅度较小, 总体数据波动格局较第一个时期更加单一. 第三个时期 (2004-2021 年), 总体数据呈现增长趋势, 并出现两次较大波动.




图 3.5: (a)、(b) 和 (c) 分别显示了 1968-1985 年、1986 - 2003 年和 2004-2021 年期间的黄金价格序列
Fig 3.5: (a),(b) and (c) show the gold price sequence for the 1968-1985, 19862003, and 2004-2021 periods,

respectively




图 3.6: 黄金价格数据在整个时期 (1968-2021) 的趋势

Fig 3.6: Trends in gold price data over the entire period (1968-2021)

(1) 基于序数网络的角度对金价数据波动分析

利用新方法和传统的 Bandt-Pompe 方法 (BP)，将四组不同时期的数据转换成相应的序数网络. 由于变换后的序数网络受嵌入维数 m 的影响，需要研究新方法和 BP 方法在不同 m 下生成的序数网络对四个时期金价特征的影响. 以 $m=3,4,5,6,7$ 生成相应的序数网络，得到的序数网络节点之间的差异如图 3.7 所示.




图 3.7: 不同 m 值下，新方法和 BP 方法转换的 4 个时期 (1968-1985、1986-2003、2004-2021 和 1968-2021) 的序数网络节点数

Fig 3.7: Number of ordinal network nodes converted by the new method and BP method in four periods (1968-1985, 1986-2003, 2004-2021 and 1968-2021) under different m values

从图 3.7 中可以看出，随着嵌入维数 m 的不断增加，同期变换的相应序数网络的节点数也在不断增加，说明增加 m 可以在时间序列数据中识别出更丰富的有序模式，从而研究数据更多的局部波动特征，这为本研究进行更深入地探索时间序列内部演化规律提供了可能. 此外，使用新方法构建的网络节点数量明显大于使用 BP 方法. 并且可以发现，对于相同的 m ，从第一期到第三期，序数网络对应的节点数是不断减少的，说明第一期 (1968-1985) 黄金价格数据波动频繁，数据没有明显的趋势. 造成这种不稳定变化的原因可能是 1968 - 1985 年全球经济发展水平相对较低，以及黄金市场发展水平不成熟. 许多因素的综合作用导致黄金价格的发展方向更加不确定. 与前两个时期 (1968-1985 年、1986-2003 年) 的序数网络相比，第三个时期 (2004-2021 年) 黄金价格序列对应的序数网络节点数始终是最小的，说明经过黄金市场 54 年的发展，黄金价格的影响机制更

表 3.3: 基于 BP 和新方法策略的各个时期节点数

Table 3.3: Number of nodes obtained in each period based on BP and new method strategy					
Dimension m	1968-1985	1986-2003	2004-2021	1968-2021	Strategy
m=3	6	6	6	6	BP
	13	13	12	13	new
m=4	24	24	24	24	BP
	75	65	58	75	new
m=5	120	120	120	120	BP
	441	305	247	475	new
m=6	646	650	629	709	BP
	1479	1062	863	1921	new
m=7	1918	2004	1867	3248	BP
	2819	2410	2125	5125	new

加成熟和完善,这使得黄金价格的变化更加规律,价格演变趋势更加稳定.将三个时期的金价数据作为一个整体来考虑,当 $m > 5$ 时,所构建的序数网络的节点数量远远大于单个时期的节点数量,这表明整体数据波动呈现出多样性特征,几乎涵盖了所有可能的有序模式.另一方面,也揭示了黄金价格的变异性特征.此外,新方法提取数据信息波动的能力总是优于 BP 方法,因为它总是比 BP 方法有更多的节点,这意味着暴露更多的特征.表 3.3 详细显示了新方法和 BP 方法在各时间段构建的序数网络节点数的确切变化.

(2) 新的序数网络框架下关于黄金价格不可逆性研究的完全平均散度熵分析

基于节点的出度转移概率和入度转移概率的差异,这一小节进一步利用新方法构建的序数网络和 BP 方法考虑三个时期对应的黄金价格时间序列的不可逆性分析,并结合三个时期的数据来度量整个黄金时间序列系统的不可逆性.采用不同 m 值并结合 Dm 探究同期不可逆性测度的准确性,利用相同 m 值结合 Dm 探究不同时期金价数据的不可逆性变化,所得结果如图 3.8 所示.不同场景下计算的 Dm 具体值如表 3.4 所示.值得一提的是,结果中没有对 Dm 进行归一化,因为归一化的散度熵值可能会增加或减少原始可逆性大小.保持数据的事实差异值有助于直接比较不可逆性程度.

表 3.4: 基于 BP 和新方法策略得到不同时期的 Dm

Table 3.4: Dm obtained from different periods based on BP and new method strategies					
Dimension m	1968-1985	1986-2003	2004-2021	1968-2021	Strategy
m=3	0	0	0	0	BP
	0.1572	0.0910	0.1151	0.1572	new
m=4	0	0	0	0	BP
	0.1821	0.0909	0.0895	0.1784	new
m=5	0.0703	0.0566	0.0957	0.0098	BP
	0.1486	0.1283	0.1147	0.1556	new
m=6	0.1647	0.1715	0.1878	0.1807	BP
	0.1056	0.1278	0.1494	0.1362	new
m=7	0.0923	0.0830	0.0823	0.1466	BP
	0.0442	0.0639	0.0654	0.0905	new




图 3.8: Dm 被计算通过将四个时期的黄金价格数据转换成相应的扩展序数网络和测量不同维度 m 下节点出度和入度转换概率分布的差异

Fig 3.8: Dm is calculated by converting gold price data from four periods into corresponding expanded ordinal networks and measuring the differences in the probability distribution of node out-degree and in-degree transition under different dimensions m

在第一个时期 (1968-1985)，随着嵌入维数 m 的增大，基于新方法构建的扩展序数网络计算的 Dm 呈现先增大后减小的趋势，当 m 为 4 时，Dm 达到峰值

0.1821. 当 $m=7$ 时, 所测时间序列的不可逆值仅为 0.0442. 这表明, 在将时间序列转换为相应的向量空间时, 虽然增加 m 确实可以通过研究了解更多的数据全局信息, 但也忽略了数据更多的局部波动信息, 以及数据的相对影响能力. 换句话说, 虽然从序数网络的角度来看, m 的增加确实了解了更多的有序模式, 但也导致了更多的无效模式, 即数据段中相对较大的信息隐藏了研究中真正需要掌握的信息. 然而, 基于传统的 BP 方法, 当 m 较小时 ($m=3, m=4$), 计算得到的 D_m 为 0, 从而得出黄金价格数据在第一期可逆的错误结论. 传统方法计算的 D_m 在 $m=6$ 时达到最大值 0.1647, 与新方法计算的最大值 0.1821 有显著差异. 这可能是由于 BP 方法对高维数据中波动信息的过多描述造成了冗余现象, 不能很好地反映数据的特征. 同时, 由于经典 BP 方法对模式分类处理粗糙, 在一定程度上隐藏了更多有意义的数据信息, 导致对不可逆问题的结论不准确. 新方法对信息的分类更加细致, 有效地解决了这一问题. 1968 年至 2021 年 (整个金价体系) 黄金价格数据的不可逆变化趋势也证实了本节的上述分析.

当 $m=3$ 和 $m=5$ 时计算的 D_m 值 (分别为 0.1572 和 0.1486) 几乎相等, 说明 $m=5$ 时计算的 D_m 已经可以适当地衡量该时间段序列数据的不可逆性的大小. BP 方法在小 m 时的性能仍然不理想, 但在 $m=6$ 时 D_m 值较大, 为 0.1807, 最后急剧下降到 0.1466, 说明 BP 方法的不稳定性很大. 在 1986 - 2003 年期间, 虽然与 $m=3$ 相比, $m=4$ 时考虑了更多的波动信息 (节点数从 13 个增加到 65 个), 但新方法的不可逆性值几乎没有变化, 说明使用 $m=3$ 和 $m=4$ 时, 第二个时期的不可逆性测量效果是一致的. BP 法也有同样的结论, 因为 D_m 等于 0. 而当 $m=5$ 时, D_m 的值迅速增大, 与 $m=6$ 时的值基本一致. 这表明, 新方法在 $m=5$ 和 $m=6$ 时一致地度量了 1986 - 2003 年黄金价格数据的不可逆性, 并且在小维度上获得了直观的结果. 同时, 当 $m=6$ 时, BP 方法的散度值较大, 为 0.1715. 从图 3.8 中不难发现, BP 方法在第一和第二周期的表现不是很直观. 在最近一段时间内, 基于扩展序数网络计算的 D_m 在不同 m 值下变化明显, 呈现先减小后增大再减小的趋势. 注意, $m=5$ 时的不可逆性值为 0.1147, 与 $m=3$ 时的 0.1151 略有不同. 因此, 2004 - 2021 年黄金价格序列的不可逆性值可能会在 0.1147 附近收敛. 2004 - 2021 年 BP 法计算的不可逆性值分别为 0 ($m=3,4$)、0.0957 ($m=5$)、0.1878 ($m=6$) 和 0.0823 ($m=7$). D_m 的跨度非常大, 上升和下降的趋势异常显著. 令人欣慰的是, BP 方法和新方法在 $m=6$ 时均达到最大值, 这表明新方法不仅改进了 BP 方法, 而且继承了 BP 方法的许多优点.




图 3.9: 四个时期在 $m=5$ 时的网络图: (a) 对应于 1968-1985, (b) 为 1986-2003, (c) 为 2004-2021, (d) 是整个时期 1968-2021

Fig 3.9: Network diagram of four periods at $m=5$: (a) corresponds to 1968-1985, (b) is 1986-2003, (c) is 2004-2021, and (d) is the entire period 1968-2021

其次, 在相同维数 m 条件下, 基于不同时期的两种策略 (新方法和 BP), 分析了数据不可逆性 D_m 的合理性. 由图 3.8 可以看出, 在 m 为 3、4、5 的相同网络转换机制下, 当黄金价格数据从第一时期发展到第二时期时, 新方法计算出的对应 D_m 显著减小; 然而, 在 $m=3$ 和 $m=4$ 的条件下, BP 方法保持相同的 D_m , 因为它错误地假设两个周期的时间数据是可逆的. D_m 在 $m=5,7$ 处的变化趋势与新方法很好地一致, 但较小的 D_m 使结果测量不可逆性不太直观, 难以发现数据中的显著差异. 当 $m=6,7$ 时, 新方法对应的从第一周期过渡到第二周期的 D_m 逐渐增大, 这与上面的分析结果相反. 新方法计算的 D_m 在 $m=6$ 时的变化趋势与新方法在 $m=6,7$ 时的变化趋势相同. 从两个时期的数据演变来看, 1968 - 1985 年的数据波动较为剧烈, 而 1986 - 2003 年的数据波动较为平缓. 由图 3.7 可以看出, 1968 - 1985 年的数据波动复杂度要远远大于 1986 - 2003 年的数据, 且前者的转换形式更多. $m=5$ 的结果既恰当地考虑了更多类型的数据变化模式, 又很好地度量了新方法计算的不可逆性程度. 1986 - 2003 年对应的黄金价格数据波

动模式类型数多于 2004-2021 年, 数据转换更为复杂多变. 因此, 对应的 D_m 应大于 2004-2021. 换句话说, 1986 - 2003 年黄金价格时间序列的不可逆性应该更大. $M=4,5$ 很好地解释了第二周期到第三周期数据转换的特征. BP 方法得出的结果显然与事实不符. 整个黄金市场从 1968 年到 2021 年的发展过程已经有 54 年了, 其复杂性和不可逆性应该大于单个时期的数据不可逆性. 因此, 从新方法的角度来看, 不同 m 值下计算的 D_m 也表现出这一特征 (除了 $m=6$). BP 方法仅在 $m=7$ 时反映上述特征, 因此新方法可能更适合测量不可逆方法.

根据以上不同角度的分析, 将 $m=5$ 时新方法计算得到的 D_m 视为各发展阶段金价数据的不可逆性, $D_m(1968-1985)=0.1486$, $D_m(1986-2003)=0.1283$, $D_m(2004-2021)=0.1147$, $D_m(1968-2021)=0.1556$. 为了反映不同时期数据的拓扑结构, 在图 3.9(a)、图 3.9(b)、图 3.9(c)、图 3.9(d) 中展示了 $m=5$ 时通过 Gephi 软件得到的四个时期的序数网络. 对比四个时间段的网络图, 不难看出图 3.9(d) 中的网络节点分布更加密集, 许多节点之间的转换更加复杂和频繁. 这是显而易见的, 因为它涵盖了三个时期的所有转换模式, 并且在数据相关性和影响关系方面更为复杂. 这样, 整个数据的不可逆性就得到了最大化. 1968-1985 年期间的网络节点类型和节点间的链接关系比其他两个时期更为多样化, 这也表明其对应系统中的要素关系变化更大, 不可逆 D_m 值自然增大. 图 3.9(b) 中节点对之间的粗边数大于图 3.9(c), 说明第二周期的数据不可逆性可能大于第三周期.

以上结论是可以解释的. 在第一阶段的初始阶段, 金价保持相对稳定, 但后来由于金融环境复杂, 价格开始缓慢上涨. 1978 年, 原油价格暴涨, 持续的高通货膨胀率导致黄金价格疯狂上涨, 甚至达到每盎司 843 美元. 这说明原油价格波动和通货膨胀的共同作用对黄金价格市场产生了较为深刻的影响, 导致第一期黄金价格数据具有较大的不可逆性. 1987 年美国股市崩盘, 导致黄金价格持续下跌, 一度跌至每盎司 252.9 美元. 但与第一期相比, 第二期的整体价格波动相对稳定, 使得整个时期的不可逆性小于第一期. 第三个时期, 黄金市场受到 2008 年次贷危机的严重冲击, 黄金价格大幅上涨. 直到 2011 年, 黄金价格才开始回落到每盎司 1300 美元的水平. 后来, 受到全球新冠肺炎疫情的影响, 黄金价格再次上涨至每盎司 2061.5 美元. 但与第二阶段相比, 第三阶段的价格上涨趋势明显, 波动模式相对单一, 因此相应数据的不可逆性小于第二阶段. 由于不确定影响因素比任何一个时期都多, 因此整个时期的不可逆性幅度为 0.1556, 因此 1968 - 2021 年期间的不可逆性最大.

表 3.5: 同一维数 m 下不同时期 Dm 值的标准差与均值的 95% 置信区间的统计分析

Table 3.5: Statistical analysis of the 95% confidence interval of the standard variance and mean of Dm values at

different periods under the same dimension m		
Dimension m	Std(Standard deviation)	CI(95%Confidence Interval)
$m=3$	0.0327751	[0.077972,0.182278]
$m=4$	0.0520155	[0.052457,0.217993]
$m=5$	0.0187380	[0.106984,0.166616]
$m=6$	0.0320103	[0.089939,0.191811]
$m=7$	0.0189759	[0.035805,0.096195]

(3) 统计学显著性检验和替代检验分析

为了揭示不同 m 值下计算的 Dm 之间的相关性, 以及数据的不可逆性程度与散度值之间的强相关性, 又对计算的 Dm 值和维度进行了统计显著性检验. 相关统计指标如表 3.5、表 3.6 所示.

表 3.5 的结果表明, 当 m 相同时, 由于计算的标准差较大, 不同时期的金价数据 Dm 存在显著差异. 这表明新方法的度量可以区分具有不同特征的数据系统. Dm 的大部分值落在 95% 置信区间内, 说明所提出的统计指标具有较高的信度. 表 3.6 中 $m=3$ 、4、5、6 之间的 p 值均大于 0.05, 说明较小的维度对 Dm 值的影响最小, 说明新策略计算 Dm 具有很好的稳健性. 但当 m 突然变为 7 时, 计算出的 p 值小于 0.05, 与其他维度差异显著. 这也证实了本章上述分析的正确性. 当 m 增大时, Dm 的值会显著降低, 从而影响新测度的精度. 因此, 合适的 m 值可以更准确地表征时间序列的不可逆性程度.

为了消除随机因素对方法性能的影响, 还增加了对实证数据进行维度为 $m=5$ (迭代 2000 次) 的代理检测实验, 得到的结果如图 3.10 所示. 并且还计算了相应代理检验的 p 值, 结果显示 p 值 =0.00, 表明新提的算法性能良好.

表 3.6: 基于最小显著差异的统计显著性分析结果

Table 3.6: Statistical significance analysis results based on Least-Significant Difference

(I)m	(J)m	p-value	CI(95%Confidence Interval)
m=3	m=4	0.831	[-0.055158,0.044958]
	m=5	0.780	[-0.056733,0.043383]
	m=6	0.654	[-0.060808,0.039308]
	m=7	0.015	[0.014067,0.114183]
m=4	m=3	0.831	[-0.044958,0.055158]
	m=5	0.947	[-0.051633,0.048483]
	m=6	0.813	[-0.055708,0.044408]
	m=7	0.010	[0.019167,0.119283]
m=5	m=3	0.780	[-0.043383,0.056733]
	m=4	0.947	[-0.048483,0.051633]
	m=6	0.865	[-0.054133,0.045983]
	m=7	0.009	[0.020742,0.120858]
m=6	m=3	0.654	[-0.039308,0.060808]
	m=4	0.813	[-0.044408,0.055708]
	m=5	0.865	[-0.045983,0.054133]
	m=7	0.006	[0.024817,0.124933]
m=7	m=3	0.015	[-0.114183,-0.014067]
	m=4	0.010	[-0.119283,-0.019167]
	m=5	0.009	[-0.120858,-0.020742]
	m=6	0.006	[-0.124933,-0.024817]




图 3.10: 图 (a)、图 (b)、图 (c)、图 (d) 为经验数据的替代检验结果 ($m=5$)

Fig 3.10: Graph (a), graph (b), graph (c) and graph (d) show surrogate test results of empirical data ($m=5$)

(4) 与 HVG(水平可视图) 方法的比较

第二章的预备知识中已详细展示了 HVG 的算法, 因此这部分将直接转化时间序列为复杂网络. 考虑 HVG 网络中节点的出度分布与入度分布的差异, 采用 D_m 进行量化, 可以有效区分可逆和不可逆平稳时间序列. 为了证明本文提出的方法在衡量不同发展时期黄金价格数据的不可逆性特征方面的优势, 在此将 HVG 方法与扩展序数网络方法进行了比较. 相关 D_m 值的结果如图 3.11 所示.

与图 3.8 计算的 D_m 相比, 可以看出 HVG 方法计算的 D_m 远小于本文方法计算的 D_m , 这说明将扩展序数网络与完全均值散度相结合在某种意义上放大了不可逆性, 使结果更加直观. 值得注意的是, 在第二周期向第三周期过渡期间, 基于 HVG 方法计算的散度值持续增大, 整个周期的不可逆性最小. 以上分析的黄金价格在不同时期的数据特征表明, HVG 在测量复杂多变的时间序列数据的不可逆性时可能存在一定的局限性, 根据扩展序数网络中节点出度和入度概率分布的差异来衡量黄金价格数据的不可逆性可能更合适.




图 3.11: 基于 HVG 网络的不同时期黄金价格不可逆性测度结果

Fig 3.11: Measurement results of irreversibility of gold price in different periods based on HVG network

3.3.2 不同股票数据的不可逆性分析

为了验证新方法的可信度, 这节又进行了另一个实验来估计具有较低尺度值和强随机性的股指数据的不可逆性. 选取 1993-2022 年期间的上证综合指数、标普 500 指数、DAX30 指数和恒生指数, 相关数据可在<https://gushitong.baidu.com/index/us-SPX>网站获取. 通过利用 BP 网络和新扩展的序数网络计算了四个股票指数在 1993-2002 年、2003 - 2012 年、2013-2022 年、1993-2022 年时期对应的散度 D_m , 比较了各股票指数在同一维度 m 下不同时期的 D_m 表现, 以及四个股票指数在不同维度 m 下同一时期的 D_m 变化. 结果如图 3.12 和图 3.13 所示.

从图 3.12 可以看出, 对于同一股票指数, 在低维数 ($m=3,4$) 下, BP 方法得到的 D_m 不大于新方法得到的 D_m , 说明新方法具有更直观的可比性, 且股票间差异显著. 随着 m 的增加 ($m=5,6,7$), 四种股票的走势大致相同, BP 方法计算的 D_m 值与新提出的方法非常接近, 说明 m 的增加可能导致两种方法的绩效状态趋于一致. 然而, 从图中仍然可以清楚地看出, 当 $m=5$ 时, 两种方法的值相差很大, 尽管它们的变化趋势相同. 在这四只股票中, 恒生指数和标准普尔 500 指数的 D_m 相对较大, 分别符合国际金融中心 and 世界经济大国的地位, 体现了

机遇与挑战并存.




图 3.12: 4 只股票各维度 m 的 D_m 随时间的变化 (红线为上证综合指数, 黑线为标普 500 指数, 绿线为 DAX30 指数, 蓝线为恒生指数). “1” 代表 1993-2002 年, “2” 代表 2003 - 2012 年, “3” 代表 2013-2022 年, “4” 代表 1993-2022 年整个时期. 实线表示提出的方法, 虚线表示 BP 策略

Fig 3.12: The variation of D_m over period for each dimension m of four stocks (The red line represents SSE composite Index, black line is S&P 500, and green line represents DAX30 Index, blue is Hang Seng Index.). ‘1’ represents the period 1993-2002, ‘2’ represents the period 2003-2012, and ‘3’ represents the period 2013-2022, and ‘4’ is the entire period 1993-2022. The solid line represents the proposed method, and the dashed line represents the BP strategy.

从图 3.13 可以看出, 在任意时期, 四只股票的 D_m 与 m 的走势惊人的相似, 这说明了股票市场之间的紧密联系和股票市场波动之间的强相关性. 而各个时期的 D_m 在 $m=6$ 时达到峰值, 在 $m=7$ 时迅速下降, 这可能说明在 $m=6$ 时可以更直观、更准确地估计各个股票市场系统的不可逆性. 当维度较小时 ($m=3,4$), 各股指的 D_m 存在显著差异, 且新方法计算的 D_m 值大于 BP 方法. 这表明当维数 m 较小时, 新方法对各种股票市场系统具有较好的判别能力.




图 3.13: 四条股票数据 (红线为上证综合指数, 黑线为标普 500 指数, 绿线为 DAX30 指数, 蓝线为恒生指数) 在一定时期内 D_m 随维度 m 变化的变化情况. “1” 为 1993-2002 年, “2” 为 2003-2012 年, “3” 为 2013-2022 年, “4” 为 1993-2022 年整个时期. 实线表示提出的方法, 虚线表示 BP 策略

Fig 3.13: The variation of D_m of four stock data (The red line represents SSE composite Index, black line is S&P 500, and green line represents DAX30 Index, blue is Hang Seng Index.) during a certain period with the change of dimension m . ‘1’ represents the period 1993-2002, ‘2’ represents the period 2003-2012, and ‘3’ represents the period 2013-2022, and ‘4’ is the entire period 1993-2022. The solid line represents the proposed method, and the dashed line represents the BP

3.4 本章小结

本章以拓展序数网络为背景, 利用完全平均散度熵而提出了一种用于分析时间序列不可逆性的新算法, 揭示了具有不同动态演化规律的数据特征. 拓展序数网络的构建将适当长度的数据段作为节点, 根据数据段与时间转换的影响关系创建节点之间的链接. 通过充分利用数据演化的动态信息来衡量不可逆性的程度. 在黄金价格数据方面, 根据 54 年的数据, 估算出各时期黄金市场发展的散度熵值. 结果表明, 1968 - 1985 年期间的不可逆性程度最高, 1986 - 2003 年期间的不可逆性程度次之, 2004 - 2021 年期间的不可逆性程度最低. 根据各阶段数据的不可逆性程度分析了一些特征. 也就是说, 数据越复杂, 其不可逆性程度越高; 数据波动越剧烈和无趋势, 相应的不可逆性越大. 与传统的 HVG 方法相

比,该方法具有直观、准确的优点. 股票价格反映了经济发展水平,是一种极其重要的数据类型. 利用本节提出的新方法,还对股票市场不同阶段的数据进行不可逆分析,得出不同国家或地区的股票市场之间存在相关性的结论. 该策略还具有一定的区分不同环境下股票指数的能力.

4 基于动态邓熵的时间序列数据异常点识别研究

4.1 引言

随着各类数据呈井喷形式出现在人们面前, 时间序列的异常数据检测成为一个重要的研究话题. 由于异常数据的干扰, 常常会对生产生活、科学研究等产生严重的后果, 从而精确识别并定位异常数据显得十分重要. 另外, 熵的理论自诞生起便得到了迅猛发展, 并发展了一系列不同类型的熵应用在时间序列数据异常的检测工作中. 然而, 存在于现实世界中的各种系统常常产生大量规律复杂的数据, 异常数据藏于正常观测数据中较为隐秘, 导致单一熵的理论工具很难将其检测出来. 基于以上分析, 本章提出了一种新的熵—动态邓熵, 用于识别含噪声、混沌特征且具有周期性背景的复杂数据中出现的各类异常行为和含有较大不确定性异常信息的数据. 动态邓熵具备了邓熵和排列分布熵的优点, 在某种程度上克服了单一熵的局限性, 成为了一种更为优秀的融合熵. 这一章节内容首先介绍动态邓熵的详细算法, 包含了新的熵理论融合规则、归一化过程; 其次为了验证新熵的理论方法的有效性, 模拟了多种复杂异常数据的检测识别实验并运用扰动风暴时间指数数据准确识别出因风暴活动发生而导致异常数据的位置. 新方法在周期性背景下的信号局部异常点检测实验中取得了较大的成功, 进一步推广了熵的应用领域.

4.2 理论模型的构建

这一节将介绍如何将邓熵与排列分布熵进行融合的算法理论, 通过融合规则构建、新熵算法实现、多组复杂异常情形的数值模拟实验验证, 构建了动态邓熵的理论方法. 利用了对比的研究方法, 将新的熵与邓熵、动态香农熵进行识别率比较分析, 证明了动态邓熵在识别异常数据中具有较强的检测能力.

4.2.1 动态邓熵的理论模型

对于具有异常行为的时间序列信号, 异常不仅会影响或干扰局部信号段的信息分布, 而且会显著改变全局信号的复杂性和不确定性. 本节将邓熵与排列分布熵相结合, 生成动态邓熵 (DyE_d). 动态邓熵进一步扩展了描述全局信息的能

力, 减少了局部变化的信息容量, 其定义为

$$DE_d = \frac{E_d}{PDE_n} \quad (4.1)$$

其中 E_d 为邓熵, PDE_n 是排列分布熵 (permuted distribution entropy). 由公式 (4.1) 可知, 动态邓熵是一个既考虑信号局部波动特性又考虑信号全局分布特性的新熵. 因此, 结合滑动窗口技术, 并计算每个窗口对应的 DE_d , 然后将每个窗口的 DE_d 归一化, 即有

$$DyE_d = \frac{DE_d - \min(DE_d)}{\max(DE_d) - \min(DE_d)} \quad (4.2)$$

需要说明的是, 由于使用动态邓熵检测异常往往需要与滑动窗口技术相结合, 因此式 (4.2) 通常针对的是每个窗口的数据, 而不是整个时间序列的数据.

从式子 (4.2) 中很容易知道, DyE_d 是一个介于 0 和 1 之间的测度. 结合滑动窗口技术和一些常见的做法, 如果使用一个变量作为检测指标, 该变量在不同的环境或条件下必须是不同的或变化的. 此外, 如果信号中不包含异常信号, 那么 DyE_d 必须在某个极小的区间值内波动, 或者各窗口之间的 DyE_d 差异非常小. 因此, 在使用 DyE_d 检测异常信号时, 不可避免地要设置一定的阈值. 本文实验产生的信号各不相同, 无法统一确定固定阈值. 下面用两个例子来详细说明所提出的方法.

算例一: 假设有一组随机序列 $\{x_i, i = 1, 2, \dots, 20\}$, 由 MATLAB R2021a 的内置函数 `randn` 生成. 详细的 $\{x_i\}$ 表示为: $\{x_i, i = 1, 2, \dots, 20\} = \{-0.1807, 0.0458, -0.0638, 0.6113, 0.1093, 1.8140, 0.3120, 1.8045, -0.7231, 0.5265, -0.2603, 0.6001, 0.5939, -2.1860, -1.3270, -1.4410, 0.4018, 1.4702, -0.3268, 0.8123\}$. 然后以随机序列 $\{x_i, i = 1, 2, \dots, 20\}$ 为例计算其动态邓熵 (DyE_d).

首先, 采用直方图法计算邓熵和排列分布熵 (PDE_n); 根据 Sturges 规则^[96], 随机数组 $\{x_i, i = 1, 2, \dots, 20\}$ 被分成 5 个 bins, 即 $m = \text{round}(1 + \log_2 20) = 5$, 这里使用了 `round` 函数. 然后再对数据 $\{x_i, i = 1, 2, \dots, 20\}$ 进行分组. 由于所有数据的跨度是 $\max(x_i, i = 1, 2, \dots, 20) - \min(x_i, i = 1, 2, \dots, 20) = 4$, 每个 bin 相应的数据跨度为 $\frac{4}{5}$. 从而, 五个 bins 的数据范围为 $[-2.1860, -1.386), [-1.386, -0.586), [-0.586, 0.214), [0.214, 1.014), [1.014, 1.814]$. 然后计数 $\{x_i, i = 1, 2, \dots, 20\}$ 落在每个 bin 范围内的数据个数, 分别为 2、2、6、7、3. 因此, 每个 bin 的被选择概率计算为 $P_1 = \frac{2}{20} = 0.1, P_2 = \frac{2}{20} = 0.1, P_3 = \frac{6}{20} = 0.3, P_4 = \frac{7}{20} = 0.35, P_5 = \frac{3}{20} = 0.15$. 由于在计算邓熵时考虑了每个状态的基数大小, 因此邓熵可由式 (2.9) 得

到: $E_d = -0.1 \times \log(\frac{0.1}{2_2-1}) - 0.1 \times \log(\frac{0.1}{2_2-1}) - 0.3 \times \log(\frac{0.3}{2_6-1}) - 0.35 \times \log(\frac{0.35}{2_7-1}) - 0.15 \times \log(\frac{0.15}{2_3-1}) = 4.9237$.

然后计算 $PDEn$. 首先, 重构 20 个数据的相空间 (嵌入维数设为 5, 延迟时间设为 1), 得到由 16 个向量组成的空间, 第一个向量 $X_1 = (-0.1807, 0.0458, -0.0638, 0.6113, 0.1093, 0.1093)$, 第二个向量 $X_2 = (0.0458, -0.0638, 0.6113, 0.1093, 1.8140)$, ..., 最后一个向量 $X_{16} = (-1.4410, 0.4018, 1.4702, -0.3268, 0.8123)$. 然后根据表 2.1 中的规则, 得到这 16 个向量对应的状态向量. 显然, 第一个向量的状态向量是 $Y_1 = (0, 2, 1, 4, 3)$, 第二个向量是 $Y_2 = (1, 0, 3, 2, 4)$, ..., 最后一个向量的状态向量是 $Y_{16} = (0, 2, 4, 1, 3)$. 根据两个向量的切比雪夫距离公式, 相应地可以计算出 16 个向量 ($Y_1, Y_2, \dots, Y_{16}$) 中任意两个向量之间的距离. 例如, Y_1 和 Y_2 之间的距离为 $Dis(Y_1, Y_2) = \max(|0-1|, |2-0|, |1-3|, |4-2|, |3-4|) = 2$, 其他任意两个向量之间的距离也以此方法计算. 通过分析知道任意两个向量之间的距离只能是 0,1,2,3,4 中的一个. 最后统计每个距离值出现次数并计算相应的比例, 根据公式 (2.5) 得到 $PDEn = 1.3895$.

由式 (4.1) 可知, $DyE_d = \frac{E_d}{PDEn} = \frac{4.9237}{1.3895} = 3.5435$. 显然, 动态邓熵大于 $PDEn$, 但小于邓熵. 在本例中, 由于数据的随机性和不确定性, 邓熵在测量系统的不确定性和复杂性方面显示出优势, 因此邓熵的值最大. $PDEn$ 不擅长掌握全局信息, 但它对局部单个数据进行了详细的描述, 从而显示出最小值. 动态邓熵既没有过度扩展全局不确定性信息的测量能力, 也没有忽略局部信息的唯一性, 因此它小于邓熵而远大于 $PDEn$, 对数据的描述更加合理.

算例二: 假设 $\{y_i, i = 1, 2, \dots, 20\}$ 是周期函数 $\sin(t)(t = 1, 2, \dots, 20)$ 生成的时间序列信号的序列. 通过方程式 (2.5)、(2.9)、(4.1), 容易算得 $E_d = 4.8117$, $PDEn = 1.5449$, $DyE_d = \frac{E_d}{PDEn} = 3.1146$. 与前一组数据的动态邓熵相比, 两种动态邓熵的计算结果大致相同, 而第二组数据的动态邓熵值较小. 原因是第一组数据是由随机函数生成的, 第二组数据是由正弦函数生成的. 因此, 第二组数据比第一组数据更有规律, 第二组数据的复杂性也比第一组数据小. 此外, 邓熵描述了数据的全局信息, 而忽略了数据的局部波动特征. 动态邓熵综合考虑了全局信息和局部信息, 是描述数据特征的较为完整的度量.

4.2.2 算法实现

本章通过融合多种熵的途径提出了动态邓熵，新熵结合滑窗技术对复杂时间序列的局部异常数据进行识别，具体使用详情如算法 1 所示。

Algorithm 1 动态邓熵的算法

Input: 时间序列 $\{x_i, i = 1, 2, \dots, N\}$; 滑动窗长度 w ; 滑动步长 L ;

Output: DyE_d ;

- 1: 时间序列被划分的窗口数为 $\lceil \frac{N-w}{L} \rceil + 1$;
 - 2: for $i=1$ to $\lceil \frac{N-w}{L} \rceil + 1$ do;
 - 3: 根据式 (2.9) 计算邓熵 E_d ;
 - 4: 基于式 (2.5) 计算排列分布熵 (PDE_n);
 - 5: 由式 (4.1) 计算 DE_d ;
 - 6: end for
 - 7: 根据公式 (4.2) 对获得的 $\lceil \frac{N-w}{L} \rceil + 1$ 个 DE_d 值进行归一化;
-

4.2.3 数值模拟

在本节中，进行了一些数值实验来证明所提出方法的有效性。实施了六组具有周期性的背景信号，验证了该方法的检测效果。每组信号的长度为 10000。每组异常信号在 3001 ~ 4000 之间进行叠加。原始信号和异常信号类型如表 4.1 所示。

在表 4.1 中，GWN 表示高斯白噪声信号，由 MATLAB R2021a 的内置函数 $wgn(m, n, P)$ 产生。由于本文生成 10000 个数据点，因此使用函数 wgn 生成信号，其中 $m = 1, n = 10000$ ，高斯白噪声信号强度 $P = 0$ 。设置滑动窗口技术的窗口大小为 125，滑动步长为 125。每组实验产生 80 个 $DyEd$ ，用散点图表示，观察其变化特征和趋势。由于在 3001 到 4000 之间加入了异常信号，所以在每次实验中编号为 25、26、27、28、29、30、31、32 的窗口所计算的 $DyEd$ 值得到了更多的关注。当然，还计算了所有窗口的 E_d 和 $DySE_n$ 进行对比分析。此外，每个

熵检测实验的阈值是基于前 8 个最大熵值中的最小值. 这是可以理解的. 由于每次实验中只有 8 个异常窗口, 所以如果所设置的异常窗口所对应的熵与其他正常窗口的熵明显不同, 则可以认为所使用的熵检测方法是有效的.

表 4.1: 六组信号类型

Table 4.1: Six signal types

Experiment label	Signal type(original signal)	Abnormal signal category
I	$\sin t$	Local shuffle
II	$\sin t + 0.2 * GWN$	$\sin(i), i = randn$
III	$\sin t + logistic\ map(a = 4) + 0.2 * GWN$	$\sin(i), i = randn$
IV	$\sin t + 0.2 * GWN$	$\sin(2i), i \in [1, 1000]$
V	$\sin t + logistic\ map(a = 4)$	$\sin(2i), i \in [1, 1000]$
VI	$\sin t + logistic\ map(a = 4) + 0.2 * GWN$	$\sin(2i), i \in [1, 1000]$

为了比较邓熵、动态香农熵和动态邓熵对异常信号识别的效果, 设置一个识别率 η , 即

$$\eta = \frac{N_0}{N} \tag{4.3}$$

式中, N_0 为识别出的异常窗口数, N 为异常窗口总数.




图 4.1: 图 (a) 为 $\sin(t)$ 生成的原始信号, 图 (b) 为实验 I 中信号区间 $[3001, 4000]$ 重新排列后的信号
Fig 4.1: Graph (a) is the original signal generated by $\sin(t)$ and graph (b) shows the signal after rearrangement of the signal interval $[3001, 4000]$ in experiment I

在实验 I 中, $\text{sint}(t = 1, 2, \dots, 10000)$ 作为背景信号的生成函数. 然后, 将 3001 ~ 4000 中的 1000 个信号随机排列, 将重排信号视为异常信号. 原始信号和异常信号如图 4.1 所示, E_d 、 $DySE_n$ 和 DyE_d 如图 4.2 所示. 如图 4.2(a) 所示, 阈值设为 15.9088. 很明显, 只有 3 个异常窗口 (25、26、29) 在阈值线以上, 其他异常窗口都在阈值线以下. E_d 的识别率 η 为 0.375. 相反, $DySE_n$ 方法可以清楚地区分异常信号和正常信号. 在图 4.2(b) 中, 阈值为 0.706502, $DySE_n$ 的识别率 $\eta = 1$. 可以看出, $DySE_n$ 对异常检测是成功的. 与 $DySE_n$ 一样, DyE_d 也表现出了出色的识别效果, 如图 4.2(c) 所示. 阈值线 0.414425 以上均为异常窗口, 正常信号窗口均在阈值线以下. 而 DyE_d 的识别率 η 也等于 1. 与 E_d 相比, $DySE_n$ 和 DyE_d 的识别率 η 相等. 从表 4.2 可以看出, $DySE_n$ 和 DyE_d 对这种异常信号的识别效果一样好, E_d 的效果稍差. 图 4.3 是以任意两个窗口对应的 DyE_d 差的绝对值为构成元素的距离矩阵的可视化图. 两个大的白色条准确地显示异常信号所在的窗口位置.




图 4.2: 图 (a)、图 (b)、图 (c) 分别为实验 I 中 E_d 、 $DySE_n$ 和 DyE_d 的结果

Fig 4.2: Graph (a), graph (b) and graph (c) are the result of E_d , $DySE_n$ and DyE_d respectively in experiment I




图 4.3: 可视化实验 I 中 80 个窗口中任意两个窗口之间的 DyE_d 距离矩阵

Fig 4.3: Visualize the matrix of DyE_d distance between any two windows of 80 windows in experiment I

表 4.2: 实验 I 结果
Table 4.2: The result of experiment I

检测方法	前 8 个最大熵值对应窗口序号	识别率 η
E_d	29,26,25,43, 40,49,15,46	0.375
$DySE_n$	30,28,27,32,31,25,26,29	1
DyE_d	29,26,25,32,31,27,30,28	1

实验 II 的背景信号由 $\sin(t = 1, 2, \dots, 10000)$ 函数加上 $0.2 * \text{GWN}$ 产生, $\sin(i)(i = \text{randn})$ 产生异常区间信号. 原始信号图像和局部异常信号图像如图 4.4 所示. 图 4.5(a) 是 80 个窗口 E_d 值的散点图, 其中阈值为 14.87. E_d 的识别率 η 为 0.75. 使用 $DySE_n$ 方法识别异常区间的效果图如图 4.5(b) 所示. 以阈值线 0.449638(对应窗口 2) 为参考对象, 其他正常信号的熵远小于阈值. $DySE_n$ 的识别率 η 也为 0.75. 因此, $DySE_n$ 的识别效果与 E_d 大致相同. 使用新方法识别异常窗口, 结果如图 4.5(c) 所示. 异常信号的 DyE_d 在 $[0.468839, 1]$ 区间内, 正常信号的 DyE_d 在区间 $[0, 0.427686]$ 中. 显然, 这两个信号是完全隔离的, 没有交集. DyE_d 的识别率 η 达到 1. 三种熵法识别异常的结果如表 4.3 所示. 从表 4.3 可以看出, 与 E_d 和 $DySE_n$ 相比, DyE_d 是一种更好的异常识别方法. 同样, 将实验 II 中 DyE_d 值的距离矩阵可视化, 如图 4.6 所示. 异常的窗口被两条白条清晰地标示出来.

表 4.3: 实验 II 结果
Table 4.3: The result of experiment II

检测方法	前 8 个最大熵值对应窗口序号	识别率 η
E_d	30,29,27,31,44,26,25,33	0.75
$DySen$	32,28,26,25,31,27,57,2	0.75
$DyEd$	30,31,29,27,26,25,28,32	1




图 4.4: 图 (a) 是由 $\sin(t)$ 函数加 $0.2 * \text{GWN}$ 生成的原始信号，图 (b) 是在实验 II 的信号区间 $[3001, 4000]$ 中叠加 1000 个 $\sin(\text{randn})$ 后的信号

Fig 4.4: Graph (a) is original signal generated by $\sin(t)$ function plus $0.2 * \text{GWN}$ and graph (b) shows the signal after 1000 $\sin(\text{randn})$ are superimposed in the signal interval $[3001, 4000]$ in experiment II




图 4.5: 图 (a)、图 (b)、图 (c) 分别为实验 II 中 E_d 、 $DySE_n$ 和 DyE_d 的结果

Fig 4.5: Graph (a), graph (b) and graph (c) are the result of E_d , $DySE_n$ and DyE_d respectively in experiment II




图 4.6: 可视化实验 II 中 80 个窗口中任意两个窗口之间的 DyE_d 距离矩阵

Fig 4.6: Visualize the matrix of DyE_d distance between any two windows of 80 windows in experiment II

$Sint$ 、logistic map ($a = 4$) 和 $0.2 \times GWN$ 构成实验 III 的背景信号, 由 $\sin(i)(i = randn)$ 产生的 1000 个数据叠加在原始信号的 3001 和 4000 之间. 两种信号图如图 4.7 所示. E_d 、 $DySE_n$ 和 DyE_d 的结果如图 4.8 所示. 将窗口 54 对应的值 (15.597) 设为图 4.8(a) 中的阈值, E_d 的识别率 η 为 0.75. 在图 4.8(b) 中, 将窗口 14 对应的 0.52973 设置为阈值, $DySE_n$ 的识别率 η 为 0.5. 可以看出, $DySE_n$ 识别异常的能力比 E_d 差. 各窗口的 DyE_d 值如图 4.8(c) 所示. 正态信号的 DyE_d 分布比较集中, 大部分窗口集中在区间 $[0, 0.216234]$. 以异常窗口 25 对应的 $DyE_d(0.33826)$ 作为阈值, 从新熵的散点图中可以看出, 异常窗口与正常窗口的区别大致很好, DyE_d 的识别率达到 0.875. 与表 4.4 中的 E_d 和 $DySE_n$ 相比, DyE_d 优于上述两种方法, 新方法更具有识别异常的较好能力. 据此, DyE_d 的距离矩阵可视化如图 4.9 所示.

表 4.4: 实验 III 结果

Table 4.4: The result of experiment III

检测方法	前 8 个最大熵值对应窗口序号	识别率 η
E_d	30,26,32,27,31,29,54	0.75
$DySen$	25,28,69,27,6,72,31,14	0.5
$DyEd$	30,26,32,27,31,29,76,25	0.875




图 4.7: 图 (a) 是由 $\sin(t)$ 、logistic map ($a = 4$) 和 $0.2 * \text{GWN}$ 生成的原始信号, 图 (b) 是在实验 III 的信号区间 $[3001, 4000]$ 中叠加 $1000 \sin(\text{randn})$ 后的信号

Fig 4.7: Graph (a) is original signal generated by $\sin(t)$, logistic map ($a = 4$) and $0.2 * \text{GWN}$ and graph (b) shows the signal after $1000 \sin(\text{randn})$ are superimposed in the signal interval $[3001, 4000]$ in experiment III




图 4.8: 图 (a)、图 (b)、图 (c) 分别为实验 III 中 E_d 、 $DySE_n$ 和 DyE_d 的结果

Fig 4.8: Graph (a), graph (b) and graph (c) are the result of E_d , $DySE_n$ and DyE_d respectively in experiment III




图 4.9: 可视化实验 III 中 80 个窗口中任意两个窗口之间的 DyE_d 距离矩阵

Fig 4.9: Visualize the matrix of DyE_d distance between any two windows of 80 windows in experiment III

实验 IV 的原始信号生成函数与实验 II 相同, 但异常信号是由 $\sin(2i)$ 生成的, $i = 1, 2, \dots, 1000$. 原始信号和加入异常信号后的信号图像如图 4.10 所示. 如图 4.11(a) 所示, 阈值设为 15.1261(对应窗口 70), 很明显, 除了窗口 26 以外, 所有异常窗口都在阈值线以上, E_d 的识别率 $\eta = 0.875$, 说明该方法能很好地检测出异常信号. 如图 4.11(b) 所示, 除窗口 40(0.5958) 外, 所有正常信号窗口均小于阈值 (0.536242, 对应窗口 39). $DySE_n$ 的识别率 η 为 0.75, 与前两种方法比较, $DySE_n$ 的识别结果是令人满意的. 如图 4.11(c) 所示, 阈值 (0.643033(对应窗口 26)) 线清晰地将正常窗口与异常窗口分开. 正常信号与异常信号的区别是明显的, 它们都在各自的范围内浮动, DyE_d 的识别率 η 达到 1. 将结果汇总在表 4.5 中, 动态邓熵明显优于前两种方法. 从图 4.12 中所示的距离矩阵对应可视化图也可以看出新方法的有效性.

表 4.5: 实验 IV 结果
Table 4.5: The result of experiment IV

检测方法	前 8 个最大熵值对应窗口序号	识别率 η
E_d	27,31,32,30,25,29,28,70)	0.875
$DySEn$	26,28,29,25,30,32,40,39	0.75
DyE_d	27,31,32,30,25,29,28,26	1




图 4.10: 图 (a) 是由 $\sin(t)$ 函数加上 $0.2 * \text{GWN}$ 生成的原始信号，图 (b) 显示了 $\sin(2i)(i = 1, 2, \dots, 1000)$ 在实验 IV 中叠加在信号区间 $[3001, 4000]$ 之后的信号

Fig 4.10: Graph (a) is the original signal generated by $\sin(t)$ function plus $0.2 * \text{GWN}$ and graph (b) shows the signal after $\sin(2i)(i = 1, 2, \dots, 1000)$ are superimposed in the signal interval $[3001, 4000]$ in experiment IV




图 4.11: 图 (a)、图 (b)、图 (c) 分别为实验 IV 中 E_d 、 $DySE_n$ 和 DyE_d 的结果

Fig 4.11: Graph (a), graph (b) and graph (c) are the result of E_d , $DySE_n$ and DyE_d respectively in experiment IV




图 4.12: 可视化实验 IV 中 80 个窗口中任意两个窗口之间的 DyE_d 距离矩阵

Fig 4.12: Visualize the matrix of DyE_d distance between any two windows of 80 windows in experiment IV

实验 V 的原始信号和加入异常后的信号如图 4.13 所示. 原始信号由 $\sin t$ 和 logistic 映射 ($a = 4$) 生成, 而 $\sin(2i)(i = 1, 2, \dots, 1000)$ 产生异常信号. E_d 、 $DySE_n$ 和 DyE_d 结果如图 4.14 所示. 图 4.14(a) 中的阈值取 14.8771, 容易知道 E_d 的识别率 $\eta = 0.75$. 再看图 4.14(b) 中的 $DySE_n$ 的识别率 η 等于 0.875, 显然 $DySE_n$ 对异常信号的识别灵敏度略高于 E_d . 如图 4.14(c) 所展示的 DyE_d 计算结果, 异常信号对应窗口的 DyE_d 除窗口 29(0.590168) 外, 均高于阈值 (0.620339(对应窗口 71)) 线. 与 $DySE_n$ 方法相比, 大于或等于阈值的异常窗数相等, DyE_d 的识别率 η 也达到 0.875. 由表 4.6 可知, 该异常数据中动态邓熵的识别效果与动态香农熵相当, 但同时优于邓熵. 基于 DyE_d 的距离矩阵如图 4.15 所示, 证明了新方法的有效性.

表 4.6: 实验 V 结果

Table 4.6: The result of experiment V

检测方法	前 8 个最大熵值对应窗口序号	识别率 η
E_d	25,28,31,26,32,71,27,54	0.75
$DySen$	29,27,26,30,31,32,28,80	0.875
DyE_d	25,28,31,26,32,27,30,71	0.875




图 4.13: 图 (a) 是由 $\sin(t)$ 加上 logistic 映射 ($a = 4$) 生成的原始信号, 图 (b) 是在实验 V 中将 $\sin(2i)(i = 1, 2, \dots, 1000)$ 叠加在区间 $[3001, 4000]$ 后的信号

Fig 4.13: Graph (a) is original signal generated by $\sin(t)$ plus logistic map ($a = 4$) and graph (b) shows the signal after $\sin(2i)(i = 1, 2, \dots, 1000)$ are superimposed in the signal interval $[3001, 4000]$ in experiment V




图 4.14: 图 (a)、图 (b)、图 (c) 分别为实验 V 中 E_d 、 $DySE_n$ 和 DyE_d 的结果

Fig 4.14: Graph (a), graph (b) and graph (c) are the result of E_d , $DySE_n$ and DyE_d respectively in experiment V




图 4.15: 可视化实验 V 中 80 个窗口中任意两个窗口之间的 DyE_d 距离矩阵

Fig 4.15: Visualize the matrix of DyE_d distance between any two windows of 80 windows in experiment V

作为本节最后一个数值实验, 实验 VI 中原始信号的生成函数与实验 III 一致, 异常信号由 $\sin(2i)(i = 1, 2, \dots, 1000)$ 生成. 它们的信号图如图 4.16 所示, 并且三种熵定位异常信号的散点图如图 4.17 所示. 取图 4.17(a) 中窗口 32 的 $E_d(15.9881)$ 为阈值, E_d 的识别率 $\eta = 0.625$. 与 E_d 的散点图相比, $DySE_n$ 有些紊乱, 正常信号和异常信号的 $DySE_n$ 混杂在一起. 从图 4.17(b) 的效果来看, $DySE_n$ 的识别率 η 等于 0.125, E_d 识别异常的能力高于 $DySE_n$. 在新方法的散点图中, 取图 4.17(c) 中窗口 30 对应的 $DyE_d(0.610834)$ 作为阈值. 从表 4.7 可以看出, DyE_d 的识别率 η 为 0.875, 在这类异常数据检测中, DyE_d 的效果是最好的. 本实验中 DyE_d 的距离矩阵可视化如图 4.18 所示.

表 4.7: 实验 VI 结果

Table 4.6: The result of experiment VI

检测方法	前 8 个最大熵值对应窗口序号	识别率 η
E_d	25,26,38,18,27,31,37,32	0.625
$DySen$	29,79,66,55,5,71,39,32	0.125
DyE_d	25,26,31,27,32,28,38,30	0.875




图 4.16: 图 (a) 是由 $Sin(t)$ 、logistic 映射 ($a = 4$) 和 $0.2 * GWN$ 生成的原始信号，图 (b) 显示了在实验 VI 中将 $Sin(2i)(i = 1, 2, \dots, 1000)$ 叠加在区间 $[3001, 4000]$ 之后的信号

Fig 4.16: Graph (a) is original signal generated by $Sin(t)$, logistic map($a=4$) and $0.2 * GWN$ and graph (b) shows the signal after $sin(2i)(i = 1, 2, \dots, 1000)$ are superimposed in the signal interval $[3001, 4000]$ in experiment VI




图 4.17: 图 (a)、图 (b)、图 (c) 分别为实验 VI 中 E_d 、 $DySE_n$ 和 DyE_d 的结果

Fig 4.17: Graph (a), graph (b) and graph (c) are the result of E_d , $DySE_n$ and DyE_d respectively in experiment VI




图 4.18: 可视化实验 VI 中 80 个窗口中任意两个窗口之间的 DyE_d 距离矩阵

Fig 4.18: Visualize the matrix of DyE_d distance between any two windows of 80 windows in experiment VI

4.2.4 结果分析

在六组实验中, 分别利用 Deng 熵、动态 Shannon 熵和动态 Deng 熵来识别数据中的异常信号, 并利用识别率 η 来评价三种熵对异常的检测能力. 三种熵法的六组实验结果汇总在图 4.19 所示. 从图 4.19 可以看出, 动态 Deng 熵是最好的, 动态 Shannon 熵和 Deng 熵对局部异常的识别能力基本相同. 从动态邓熵的表达式看, 它是以邓熵为分子, PDEn 为分母的分数. 与香农熵相比, 邓熵考虑了每个焦点元素 a 中可能存在的非空状态的数量, 从更详细、更全面的角度描述了信息的不确定性. 基于直方图计算邓熵, 在计算邓熵时, 不仅考虑了整个数据的信息, 而且考虑了将数据分成若干类后, 每一类非空子类别的最大数目. PDEn 是描述信息数据局部波动的量. 它不考虑每个数据点的实际值大小, 而是以比较其大小关系的状态向量作为考虑对象, 或者简单地考虑数据的波动形状. 此外, 实验的对象是具有周期性背景的数据. 实验结果表明, 该方法是有效的.

进一步分析表明, 异常信号越不规则, PDEn 越小, 动态邓熵越大.




图 4.19: 三种熵值方法的异常识别效果比较

Fig 4.19: Comparison of anomaly recognition effects of three entropy methods

需要注意的是, 虽然在这六组数值实验中, 异常数据被统一地设置在了 [3001,4000] 的范围内, 也就是说, 实验前就知道了异常值所在的窗口 (即使数据不需要做熵值检测实验). 然而, 在计算动态邓熵和确定阈值时, 不仅要看异常数据窗口的动态邓熵, 还要对所有窗口的动态邓熵进行综合观察和比较. 由于异常数据窗口的动态邓熵值与无异常行为窗口对应的熵值存在明显差异, 从而很容易可以确定异常数据的位置. 也就是说, 给定一个包含异常数据的时间序列, 利用滑窗技术并计算对应的熵值, 通过比较各窗口的动态邓熵差异, 新方法可以快速定位出异常数据所在的窗口. 此外, 检测到的数据还应满足一定的规律性, 如一定的周期性背景.

4.3 实证数据应用

为了验证该方法识别异常数据的有效性, 利用测量地磁活动的扰动风暴时间指数进行了验证. 相关时间序列可在世界地磁数据中心 (https://wdc.kugi.kyoto-u.ac.jp/dst_final/index.html) 免费获取. 选取了 1989 年 1 月 20 日至 5 月 4 日的扰动风暴时间指数数据集. 在此期间, 数据每天采样 24 次 (每小时一次), 共 105 天. 1989 年 3 月 13 日, 发生了一次异常强烈的磁

暴，如图 4.20 所示. 利用动态邓熵来确定磁暴的准确位置.




图 4.20: 1989 年 1 月 20 日至 5 月 4 日的扰动风暴时间指数数据集

Fig 4.20: Disturbance storm time index data set for the Period from January 20th, 1989 to May 4th, 1989




图 4.21: 扰动风暴时间指数资料 20 个窗口的动态邓熵

Fig 4.21: Dynamic Deng entropy of 20 windows of disturbance storm time index data

需要注意的是，实证实验中使用的滑动窗宽度仍为 125，滑动步长为 125，与之前的数值模拟实验中保持一致. 并且在 5 月 4 日这一天只使用了前 4 个小时的数据，剔除了之后 4 个小时的数据，所以数据集的大小为 2500. 利用动态邓

熵方法对磁暴活动引起的一系列扰动风暴时间指标异常数据进行识别,得到的 20 个 DyE_d 值散点图如图 4.21 所示. 窗口 11 数据对应的动态邓熵值达到 1, 远远大于其他任何窗口对应的动态邓熵值. 窗口 1 的动态熵达到 0.677257, 窗口 8 和窗口 10 的动态熵分别达到 0.627413 和 0.384242. 值得注意的是, 磁暴发生在 1989 年 3 月 13 日, 正好在窗口 11. 显然, 新熵法准确地识别了磁暴活动的位置, 为进一步探索环地磁场活动规律提供了良好的方法.

4.4 本章小结

具有高复杂性和高不确定性信息的时间序列异常检测是一个难题. 从序列数据的整体来看, 数据中混杂着混沌信号、白噪声和周期信号, 使得系统隐藏的信息极其复杂; 考虑到局部范围数据的特点, 数据的随机排列使得单个数据具有不确定性. 基于以上两个方面, 本文利用 Deng 熵和 PDEn 形成一种新的融合熵, 称为 DyE_d . 在数值模拟实验中, 新熵的异常识别率大于 0.875, 多次达到 1. 动态 Shannon 熵的识别效果极不稳定, 甚至其识别率下降到 0.125, 且整体识别效果也呈下降趋势. 邓熵的识别效果不高, 最大识别率仅为 0.875. 并以扰动风暴时间指数为实例验证了新熵的识别效果, 结果表明动态邓熵能较好地检测磁暴发生的数据位置. 动态邓熵的提出为现实生活中的异常检测提供一个新的视角, 进一步丰富了异常检测的理论方法, 为生产生活及科学研究在异常信号检测问题中提供了更多的选择.

5 总结和展望

5.1 论文工作总结

近年来,随着熵理论的蓬勃发展和大数据时代的到来,利用熵方法来研究时间序列数据的性质吸引着多数研究者的兴趣.本文基于熵的理论,对时间序列的不可逆性和异常性质进行了研究.由于用于完全平均散度熵计算的概率分布较难获取,本文提出了一种拓展序数网络的节点出入度分布的新算法来研究时间序列的不可逆性.新方法结合了网络理论的科学知识,将数据的空间拓扑属性和数值性质同时考虑,以一种更为合理的方式对数据不可逆性性质进行了度量判断.另外,单一熵对数据描述的不足和侧重性,本文融合了多种熵的优势提出了动态邓熵的新理论,并用于时间序列的异常性质研究.所提出的动态邓熵新理论方法在复杂时间序列的多类异常数据情形中取得了较高的识别率,为时间序列数据研究工作诸如预测、聚类等作了重要的奠基.时间序列的不可逆性和异常性是数据分析的两个重要研究方向,本文基于完全平均散度熵和动态邓熵对时序数据进行了研究,对拓展熵的研究理论和时间序列的性质分析具有重要意义,巩固了熵在时序数据的应用联系.本文的贡献概括为以下两点:

(1) 提出了一种基于扩展序数网络背景下利用完全平均散度熵描述时间序列不可逆性的新方法.

论文的第三章运用完全平均散度熵揭示了时间序列波动性与不可逆性的紧密联系,设计了一种新的方法来获取表征时序数据和逆时序数据的信息分布概率.传统度量策略多依赖于统计理论中的假设检验,或侧重于考虑数据之间的局部大小关系,而忽略了数据拓扑的空间信息.该章节方法的主要内容为数据网络化、获取分布信息、计算完全平均散度熵,其中数据网络化是该方法的创新要点.数据网络化过程中改进了传统 Bandt-Pompe 符号化方法忽视数据段相等情况的不足,从而提出了更为完备化的序数符号模式转换规则,使得对时间序列振动信息掌握得更为全面.通过新符号模式规则转换的拓展序数网络拥有更丰富的空间拓扑结构,如节点之间的关系更复杂,网络结构更多样丰富.新转换方法计算的完全平均散度熵在数值上表现了更直观的效果,对数据特征分析的结果也更为准确、合理,获得了复杂和高波动性的数据系统具有高度不可逆性的重要结论.

(2) 提出了一种融合了多种熵优点的新的熵方法—动态邓熵.

论文第四章充分利用了邓熵和排列分布熵的各自优点, 创新性地将两者组合在一起并形成了新的熵, 动态邓熵. 传统基于熵对时间序列进行异常识别的方法大都侧重于数据某方面的单一性质, 如考虑对整体数据分布信息有改变的香农熵方法, 或对数据波动的波形有改变的排列分布熵方法. 邓熵是一种描述复杂性更为全面的证据熵, 在对时间序列数据的全局信息描述中比香农熵更为准确优秀. 动态邓熵不仅拥有邓熵对复杂信息刻画的能力, 还具备了排列分布熵对数据局部波动灵敏识别的能力, 在对复杂时间序列的异常值识别效果上要优于动态香农熵和邓熵. 将新方法在模拟数据的多组异常实验中进行验证, 获得了较高的识别率. 并且本文还对其进行实际数据例子验证, 动态邓熵对发生磁暴的位置点准确识别出来. 动态邓熵的提出为时间序列异常检测提供了新的路径, 推动了熵在时序数据中的分析研究.

5.2 未来展望

本文主要基于熵的理论工具对时间序列的不可逆性和异常进行数据分析研究, 从而对数据的相关性质进行深入挖掘. 根据本文所做的研究内容, 未来的研究工作主要有以下两方面:

(1) 基于序数网络对时间序列的预测工作还不足, 未来将考虑利用扩展序数网络结合熵建立适当的预测模型, 以可靠地预测时序数据.

(2) 对动态邓熵的相关性质还有待研究, 将展开针对更广泛数据的异常识别的广义动态邓熵方法进行探索.

参考文献

- [1] Sagioglu S, Sinanc D. Big data: A review[C]//2013 international conference on collaboration technologies and systems (CTS). IEEE, 2013: 42-47.
- [2] Fan J, Han F, Liu H. Challenges of big data analysis[J]. National science review, 2014, 1(2): 293-314.
- [3] Hamilton J D. Time series analysis[M]. Princeton university press, 2020.
- [4] 孙红雨, 王长耀, 牛铮等. 中国地表植被覆盖变化及其与气候因子关系——基于 NOAA 时间序列数据分析 [J]. 遥感学报, 1998, (03): 204-210.
- [5] 易丹辉, 王燕. 应用时间序列分析 [M]. 中国人民大学出版社, 2019.
- [6] 王燕. 时间序列分析 [M]. 中国人民大学出版社, 2020.
- [7] 徐晓岭, 王磊. 统计学 [M]. 人民邮电出版社, 2015.
- [8] Brockwell P J, Davis R A. Time series: theory and methods[M]. Springer science & business media, 1991.
- [9] Hann E C, Overa S, Harland-Dunaway M, et al. A hybrid inorganic-biological artificial photosynthesis system for energy-efficient food production[J]. Nature food, 2022, 3(6): 461-471.
- [10] Vasiljeva I E, Pishkalo M I. History of sunspot research and forecast of the maximum of solar cycle 25[J]. Kinematics and Physics of Celestial Bodies, 2021, 37(4): 200-211.
- [11] Jiang B, Li J, Yao Q. Autoregressive networks[J]. Journal of Machine Learning Research, 2023, 24(227): 1-69.
- [12] Zhang W, Lin Z, Liu X. Short-term offshore wind power forecasting-A hybrid model based on Discrete Wavelet Transform (DWT), Seasonal Autoregressive Integrated Moving Average (SARIMA), and deep-learning-based Long Short-Term Memory (LSTM)[J]. Renewable Energy, 2022, 185: 611-628.
- [13] Madera M, Marcek D. Intelligence in Finance and Economics for Predicting High-Frequency Data[J]. Mathematics, 2023, 11(2): 454.
- [14] Silva A B S, Araújo A C M, Frias P G, et al. Auto-Regressive Integrated Moving Average Model (ARIMA): conceptual and methodological aspects and applicability in infant mortality[J]. Revista Brasileira de Saúde Materno Infantil, 2021, 21: 647-656.
- [15] Engle R F. Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation[J]. Econometrica: Journal of the econometric society, 1982: 987-1007.
- [16] 翁非. 石油价格冲击与中国经济增长: 基于三变量 VAR 模型的研究 [J]. 统计与决策, 2006, (11): 84-86.
- [17] Zhu J, Wei D. Analysis of stock market based on visibility graph and structure entropy[J].

- Physica A: Statistical Mechanics and its Applications, 2021, 576: 126036.
- [18] Clausius R. I. on the moving force of heat, and the laws regarding the nature of heat itself which are deducible therefrom[J]. The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science, 1851, 2(8): 1-21.
- [19] Shannon C E. The Bell System technical journal.[J]. Journal of the Franklin Institute, 1938, 196(4):519-520.
- [20] Pincus, Steve. Approximate entropy (ApEn) as a complexity measure[J]. Chaos, 1998, 5(1):110-117.
- [21] Golshani L, Pasha E, Yari G. Some properties of Rényi entropy and Rényi entropy rate[J]. Information Sciences, 2009, 179(14): 2426-2433.
- [22] Bandt C, Pompe B. Permutation entropy: a natural complexity measure for time series[J]. Physical review letters, 2002, 88(17): 174102.
- [23] Fadlallah B, Chen B, Keil A, et al. Weighted-permutation entropy: A complexity measure for time series incorporating amplitude information[J]. Physical Review E, 2013, 87(2): 022911.
- [24] Xiong Y, Gao J, Yang Y, et al. Classifying driving fatigue based on combined entropy measure using EEG signals[J]. International Journal of Control and Automation, 2016, 9(3): 329-338.
- [25] Deng Y. Deng entropy[J]. Chaos, Solitons & Fractals, 2016, 91: 549-553.
- [26] Wang D, Gao J, Wei D. A new belief entropy based on Deng entropy[J]. Entropy, 2019, 21(10): 987.
- [27] Song X, Xiao F. Combining time-series evidence: A complex network model based on a visibility graph and belief entropy[J]. Applied Intelligence, 2022, 52(9): 10706-10715.
- [28] Lacasa L, Luque B, Ballesteros F, et al. From time series to complex networks: The visibility graph[J]. Proceedings of the National Academy of Sciences, 2008, 105(13): 4972-4975.
- [29] 祝嘉, 向长城. 基于有限穿越可视图的股票数据研究 [J]. 湖北民族大学学报 (自然科学版), 2020, 38(03): 283-289.
- [30] Gao Z, Jin N. Complex network from time series based on phase space reconstruction[J]. Chaos: An Interdisciplinary Journal of Nonlinear Science, 2009, 19(3).
- [31] Zhang X, Wen S, Yan L, et al. A hybrid-convolution spatial-temporal recurrent network for traffic flow prediction[J]. The Computer Journal, 2024, 67(1): 236-252.
- [32] Tian F, Wang D, Wu Q, et al. An empirical study on network conversion of stock time series based on STL method[J]. Chaos: An Interdisciplinary Journal of Nonlinear Science, 2022, 32(10).
- [33] Peng K, Shang P. Characterizing ordinal network of time series based on complexity-entropy curve[J]. Pattern Recognition, 2022, 124: 108464.
- [34] 祝嘉. 基于可视图和结构熵的时序数据研究 [D]. 湖北民族大学, 2021.

- [35] 邵俊杰, 李莹, 孙凤霞等. 水-岩反应过程中离子浓度变化特征实验研究及其对地震异常成因的启示 [J]. 地震研究, 2022, 45(02): 187-198.
- [36] Wang P, Gu C, Yang H, et al. Characterizing systems by multi-scale structural complexity[J]. Physica A: Statistical Mechanics and its Applications, 2023, 609: 128358.
- [37] Maldonado C, Negrete N M. Irreversibility indices as discriminators of heart conditions from Electrocardiographic signals[J]. Physica A: Statistical Mechanics and its Applications, 2024: 129584.
- [38] Wei D, Wei B, Hu Y, et al. A new information dimension of complex networks[J]. Physics Letters A, 2014, 378(16-17): 1091-1094.
- [39] Zhang H, Lan X, Wei D, et al. Self-similarity in complex networks: from the view of the hub repulsion[J]. Modern Physics Letters B, 2013, 27(28): 1350201.
- [40] Wang B, Zhu J, Wei D. The self-similarity of complex networks: from the view of degree-degree distance[J]. Modern Physics Letters B, 2021, 35(18): 2150331.
- [41] Yao W, Yao W, Yao D, et al. Shannon entropy and quantitative time irreversibility for different and even contradictory aspects of complex systems[J]. Applied Physics Letters, 2020, 116(1).
- [42] Fodor É, Jack R L, Cates M E. Irreversibility and biased ensembles in active matter: Insights from stochastic thermodynamics[J]. Annual Review of Condensed Matter Physics, 2022, 13: 215-238.
- [43] Zanin M, Papo D. Algorithmic approaches for assessing irreversibility in time series: Review and comparison[J]. Entropy, 2021, 23(11): 1474.
- [44] Li J, Shang P, Zhang X. Time series irreversibility analysis using Jensen-Shannon divergence calculated by permutation pattern[J]. Nonlinear Dynamics, 2019, 96(4): 2637-2652.
- [45] Usman S M, Khalid S, Bashir Z. Epileptic seizure prediction using scalp electroencephalogram signals[J]. Biocybernetics and Biomedical Engineering, 2021, 41(1): 211-220.
- [46] Martínez J H, Herrera-Diestra J L, Chavez M. Detection of time reversibility in time series by ordinal patterns analysis[J]. Chaos: An Interdisciplinary Journal of Nonlinear Science, 2018, 28(12).
- [47] Wang Z, Shang P, Shang B. Time irreversibility analysis and abnormality detection based on Riemannian geometry for complex time series[J]. Communications in Nonlinear Science and Numerical Simulation, 2023, 117: 106985.
- [48] Goldberger A L, Amaral L A N, Hausdorff J M, et al. Fractal dynamics in physiology: alterations with disease and aging[J]. Proceedings of the national academy of sciences, 2002, 99(suppl_1): 2466-2472.
- [49] Xia J, Shang P, Wang J, et al. Classifying of financial time series based on multiscale entropy and multiscale time irreversibility[J]. Physica A: Statistical Mechanics and Its Applications,

- 2014, 400: 151-158.
- [50] Abellán-Aynés O, López-Plaza D, Martínez-Aranda L M, et al. Inter-stroke steadiness: a new kinematic variable related to 200m performance in young canoeists[J]. Sports Biomechanics, 2022: 1-13.
- [51] Valencia J F, Vallverdu M, Schroeder R, et al. Complexity of the short-term heart-rate variability[J]. IEEE Engineering in Medicine and Biology Magazine, 2009, 28(6): 72-78.
- [52] Porta A, Casali K R, Casali A G, et al. Temporal asymmetries of short-term heart period variability are linked to autonomic regulation[J]. American Journal of Physiology-Regulatory, Integrative and Comparative Physiology, 2008, 295(2): R550-R557.
- [53] Guzik P, Piskorski J, Krauze T, et al. Heart rate asymmetry by Poincaré plots of RR intervals[J]. 2006.
- [54] Costa M, Goldberger A L, Peng C K. Broken asymmetry of the human heartbeat: loss of time irreversibility in aging and disease[J]. Physical review letters, 2005, 95(19): 198102.
- [55] Martínez-Flores C. Shannon entropy and Fisher information for endohedral confined one-and two-electron atoms[J]. Physics Letters A, 2021, 386: 126988.
- [56] Kullback S, Leibler R A. On information and sufficiency[J]. The annals of mathematical statistics, 1951, 22(1): 79-86.
- [57] Manning C, Schutze H. Foundations of statistical natural language processing[M]. MIT press, 1999.
- [58] Acosta-Tripailao B, Pastén D, Moya P S. Applying the horizontal visibility graph method to study irreversibility of electromagnetic turbulence in non-thermal plasmas[J]. Entropy, 2021, 23(4): 470.
- [59] Vo T T, Nguyen T K. The roles of the reversibility and irreversibility of capillary bonds on the impact dynamics of agglomerates[J]. Acta Geotechnica, 2023, 18(1): 217-233.
- [60] Lacasa L, Nunez A, Roldán É, et al. Time series irreversibility: a visibility graph approach[J]. The European Physical Journal B, 2012, 85: 1-11.
- [61] Choudhary G I, Aziz W, Fränti P. Detection of time irreversibility in interbeat interval time series by visible and nonvisible motifs from horizontal visibility graph[J]. Biomedical Signal Processing and Control, 2020, 62: 102052.
- [62] 刘鑫. 基于复杂网络理论的心电时间序列自回归模型研究 [J]. 复旦大学, 2014.
- [63] 尹玲, 尹京苑, 孙宪坤. 利用高频 GPS 时间序列进行地震预警研究 [J]. 国际地震动态, 2018(8):1.
- [64] Lakshmi S S, Tiwari R K. Model dissection from earthquake time series: A comparative analysis using modern non-linear forecasting and artificial neural network approaches[J]. Computers & Geosciences, 2009, 35(2):191-204.

- [65] 厉雨静, 程宗毛. 时间序列模型在股票价格预测中的应用 [J]. 商场现代化, 2011(33):3.
- [66] Hu M, Wang Y, Feng X, et al. Robust Anomaly Detection for Time-series Data[J].2022.
- [67] Cook A, Misirli G, Fan Z. Anomaly Detection for IoT Time-Series Data: A Survey[J].2019.
- [68] Fox A J. Outliers in time series[J]. Journal of the Royal Statistical Society: Series B(Methodological), 1972, 34(3): 350-363.
- [69] Kadri F, Harrou F, Chaabane S, et al. Seasonal ARMA-based SPC charts for anomaly detection: Application to emergency department systems[J]. Neurocomputing, 2016, 173: 2102-2114.
- [70] Zhang G P, Qi M. Neural network forecasting for seasonal and trend time series[J]. European journal of operational research, 2005, 160(2): 501-514.
- [71] Chou J S, Telaga A S. Real-time detection of anomalous power consumption[J]. Renewable and Sustainable Energy Reviews, 2014, 33: 400-411.
- [72] Liu C L, Hsiao W H, Tu Y C. Time series classification with multivariate convolutional neural network[J]. IEEE Transactions on Industrial Electronics, 2018, 66(6): 4788-4797.
- [73] Kim T Y, Cho S B. Web traffic anomaly detection using C-LSTM neural networks[J].Expert Systems with Applications, 2018, 106: 66-76.
- [74] Karim F, Majumdar S, Darabi H, et al. LSTM fully convolutional networks for time series classification[J]. IEEE access, 2017, 6: 1662-1669.
- [75] Thies S, Molnár P. Bayesian change point analysis of Bitcoin returns[J]. Finance Research Letters, 2018, 27: 223-227.
- [76] Arlot S, Celisse A, Harchaoui Z. A kernel multiple change-point algorithm via model selection[J]. Journal of machine learning research, 2019, 20(162).
- [77] Hido S, Tsuboi Y, Kashima H, et al. Statistical outlier detection using direct density ratio estimation[J]. Knowledge and information systems, 2011, 26: 309-336.
- [78] Feuz K D, Cook D J, Rosasco C, et al. Automated detection of activity transitions for prompting[J]. IEEE transactions on human-machine systems, 2014, 45(5): 575-585.
- [79] Desobry F, Davy M, Doncarli C. An online kernel change detection algorithm[J]. IEEE Transactions on Signal Processing, 2005, 53(8): 2961-2974.
- [80] Charakopoulos A, Karakasidis T. Backward Degree a new index for online and offline change point detection based on complex network analysis[J]. Physica A: Statistical mechanics and its applications, 2022, 604: 127929.
- [81] Jaakkola T, Meila M, Jebara T. Maximum Entropy Discrimination[J]. Advances in neural information processing systems, 2004, 12.
- [82] Tao R, Zhao X, Li W, et al. Hyperspectral Anomaly Detection by Fractional Fourier Entropy [J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing,

- 2019, PP(99):1-10.
- [83] Garland J, Jones T, Neuder M, et al. Anomaly Detection in Paleoclimate Records using Permutation Entropy[J]. Entropy, 2018, 20(12).
- [84] Li Y, Lei M, Liu P, et al. A Novel Framework for Anomaly Detection for Satellite Momentum Wheel Based on Optimized SVM and Huffman-Multi-Scale Entropy[J]. Entropy, 2021(8).
- [85] Timcenko V, Gajin S. Machine learning enhanced entropy-based network anomaly detection [J]. Advances in Electrical and Computer Engineering, 2021, 21(4): 51-60.
- [86] Wang G, Wei D, Li X, et al. A novel method for local anomaly detection of time series based on multi entropy fusion[J]. Physica A: Statistical Mechanics and its Applications, 2023, 615: 128593.
- [87] Komazec T, Gajin S. Analysis of flow-based anomaly detection using Shannon' s entropy[C]//2019 27th Telecommunications Forum (TELFOR). IEEE, 2019: 1-4.
- [88] He J, Liu J, Shang P, et al. Dynamic Shannon entropy (DySEn): a novel method to detect the local anomalies of complex time series[J]. Nonlinear Dynamics, 2021, 104(4): 4007-4022.
- [89] Benettin G, Galgani L, Strelcyn J M. Kolmogorov entropy and numerical experiments[J]. Physical Review A, 1976, 14(6): 2338.
- [90] Li W, Shen X, Li Y, et al. Improved multivariate multiscale sample entropy and its application in multi-channel data[J]. Chaos: An Interdisciplinary Journal of Nonlinear Science, 2023, 33(6).
- [91] Deka B, Deka D. An improved multiscale distribution entropy for analyzing complexity of real-world signals[J]. Chaos, Solitons & Fractals, 2022, 158: 112101.
- [92] Dai Y, He J, Wu Y, et al. Generalized entropy plane based on permutation entropy and distribution entropy analysis for complex time series[J]. Physica A: Statistical Mechanics and its Applications, 2019, 520: 217-231.
- [93] Takens F. Detecting strange attractors in turbulence[C]//Dynamical Systems and Turbulence, Warwick 1980: proceedings of a symposium held at the University of Warwick 1979/80. Berlin, Heidelberg: Springer Berlin Heidelberg, 2006: 366-381.
- [94] Cardoso-Pereira I, Borges J B, Barros P H, et al. Leveraging the self-transition probability of ordinal patterns transition network for transportation mode identification based on GPS data[J]. Nonlinear Dynamics, 2022, 107(1): 889-908.
- [95] Staniek M, Lehnertz K. Parameter selection for permutation entropy measurements[J]. International Journal of Bifurcation and Chaos, 2007, 17(10): 3729-3733.
- [96] Scott D W. Averaged shifted histogram[J]. Wiley Interdisciplinary Reviews: Computational Statistics, 2010, 2(2): 160-164.